دانشگاه صنعتی شریف
دانشکده‌ی مهندسی کامپیوتر

یادگیری ماشین

پاییز و زمستان ۱۴۰۴

استاد: علی شریفی زارچی

گردآورندگان: ارشیا یوسف نیا - بنیامین قنبری - زهرا رحمانی - علی باوفا - کیهان هدایی

تمرین اول | موضوع | مهلت ارسال: ۳۰ آبان

- مهلت ارسال پاسخ تا ساعت روز مشخص‌شده است.
- در طول ترم، برای هر تمرین می‌توانید تا ۵ روز تأخیر مجاز داشته باشید و در مجموع حداکثر ۱۵ روز تأخیر مجاز خواهید داشت. توجه داشته باشید که تأخیر در تمرین‌های عملی و تئوری به صورت جداگانه محاسبه می‌شود و مجموع تأخیر هر دو نباید بیشتر از ۱۵ روز شود. پس از اتمام زمان مجاز، دو روز اضافی برای آپلود غیرمجاز در نظر گرفته شده است که در این بازه، به ازای هر ساعت تأخیر، ۲ درصد از نمره تمرین کسر خواهد شد.
- همکاری و هم‌فکری شما در انجام تمرین مانعی ندارد اما پاسخ ارسالی هر کس حتما باید توسط خود او نوشته شده باشد.
- در صورت هم‌فکری و یا استفاده از هر منابع خارج درسی، نام هم‌فکران و آدرس منابع مورد استفاده برای حل سوال مورد نظر را ذکر کنید.
- لطفا تصویری واضح از پاسخ سوالات نظری بارگذاری کنید. در غیر این صورت پاسخ شما تصحیح نخواهد شد.

سوالات نظری (۱۰۰ نمره)

۱. (۱۰ نمره) درستی و نادرستی گزاره‌های زیر را همراه یک استدلال کوتاه بیان کنید.

(الف) اگر داده‌ها خطی قابل تفکیک نباشند، هیچ راه‌حلی برای SVM به صورت soft-margin نداریم.

این گزاره نادرست است. در واقع، اگر داده‌ها خطی قابل‌تفکیک نباشند، دقیقاً در همین حالت است که Soft-Margin SVM معرفی و قابل‌حل می‌شود. ایدهٔ اصلی افزودن متغیرهای سست‌پذیر ξ_i است تا اجازه داده شود برخی نمونه‌ها وارد مارجین شوند یا حتی اشتباه طبقه‌بندی شوند. مسئلهٔ بهینه‌سازی به صورت زیر قابل‌حل باقی می‌ماند:

$$\min_{\mathbf{w}, b, \xi} \quad \frac{۱}{۲}\|\mathbf{w}\|^۲ + C\sum_{i=۱}^{N}\xi_i$$

$$\text{s.t.} \quad y_i(\mathbf{w}^\top x_i + b) \geq ۱ - \xi_i, \qquad \xi_i \geq ۰.$$

به دلیل وجود ξ_i، حتی زمانی که داده‌ها قابل‌تفکیکِ خطی نباشند نیز همواره یک راه‌حل وجود دارد، چون نقض قیود توسط ξ_i جذب می‌شود. بنابراین عبارت داده‌شده صحیح نیست.

(ب) برای یک مجموعه داده که نویز زیادی دارد یعنی تعداد زیادی از دادگان برچسب نادرست دارند، استفاده از جنگل تصادفی به طور کلی بهتر از boosted decision trees است.

این گزاره درست است. اگر مجموعه‌داده دارای نویز زیاد باشد (به‌ویژه زمانی که تعداد قابل‌توجهی از نمونه‌ها برچسب نادرست دارند) مدل‌های Forest Random معمولاً مقاوم‌تر از Trees Decision Boosted هستند. علت آن است که:

- در Boosting، هر تکرار تلاش می‌کند خطاهای مرحلهٔ قبل را جبران کند؛ بنابراین اگر تعدادی برچسب اشتباه باشند، الگوریتم بیش‌ازحد روی آنها تمرکز می‌کند و دچار **overfitting به نویز** می‌شود.
- اما Forest Random مبتنی‌بر تجمیع درخت‌های کاملاً تصادفی است و هر درخت تنها بخشی از داده‌ها را می‌بیند؛ بنابراین **اثر نویز و برچسب‌های غلط میان درخت‌ها پخش می‌شود** و مدل به‌طور کلی **پایدارتر** است.

در نتیجه برای داده‌های با نویز زیاد، Forest Random به‌طور معمول عملکرد بهتری از Boosting دارد.

(پ) در روش bagging در استفاده از درخت تصمیم‌گیری، معمولاً n درخت که واریانس زیاد و بایاس کمی دارند انتخاب می‌کنیم و نتیجه نهایی با یک اجماع از نتیجه آن‌ها به دست می‌آید.

در روش Bagging با استفاده از درخت‌های تصمیم، معمولاً n درخت که دارای واریانس زیاد و بایاس کم هستند، روی نمونه‌های Bootstrap آموزش داده می‌شوند. از آنجایی که درخت تصمیم مدلی با واریانس بالا است، میانگین‌گیری از خروجی این n درخت باعث کاهش چشمگیر واریانس کلی مدل می‌شود، در حالی که بایاس تقریباً بدون تغییر باقی می‌ماند. نتیجهٔ نهایی با تجمیع (میانگین‌گیری یا رأی‌گیری) از خروجی درخت‌ها به‌دست می‌آید.

(ت) در تجزیه واریانس‌ـبایاس، استفاده از یک مدل بسیار پیچیده بر روی داده محدود، معمولاً در ابتدا به بایاس کم و واریانس بالا منجر می‌شود.

در تجزیهٔ Bias–Variance استفاده از یک مدل بسیار پیچیده بر روی داده‌های محدود معمولاً به **بایاس کم** و **واریانس بالا** منجر می‌شود. زیرا مدل پیچیده توانایی بالایی برای برازش دقیق داده‌های آموزش دارد (که موجب کاهش بایاس می‌شود)، اما نسبت به نوسانات داده بسیار حساس است و با تغییر جزئی در داده‌های ورودی، خروجی مدل نیز تغییر زیادی می‌کند (که بیانگر واریانس بالا است).

(ث) الگوریتم پرسپترون تضمین می‌کند که برای هر مجموعه داده‌ای که به صورت خطی قابل تفکیک باشند، پس از تعداد محدودی گام به یک راه‌حل همگرا می‌شود.

الگوریتم پرسپترون تضمین می‌کند که اگر یک مجموعه‌داده به‌صورت خطی قابل تفکیک باشد، آنگاه این الگوریتم پس از تعداد محدودی گام به یک راه‌حل همگرا می‌شود. این نتیجه مبتنی بر قضیهٔ همگرایی پرسپترون است که بیان می‌کند وجود یک مرز تصمیم خطی با حاشیهٔ مثبت، باعث می‌شود خطای آموزش در نهایت به صفر برسد و بردار وزن‌ها در تعداد گام محدود تثبیت شود.

۲. (۱۵ نمره) روش تخمین چگالی در $k$nn برآوردی از چگالی یک نقطه از فضای ویژگی‌ها را نسبت به چگالی k همسایهٔ نزدیک‌تر می‌دهد. نشان دهید که مدل چگالی $k$nn را می‌توان یک توزیع نامناسب دید. این موضوع چه اهمیتی دارد و چه نتیجه‌ای می‌دهد؟

توزیع نامناسب (improper distribution) توزیعی است که انتگرال‌گیری روی آن روی کل بازه واگرا خواهد شد.[۱]

راهنمایی: برای محاسبهٔ $\mathbb{P}(\mathbf{x}_i)$، کره‌ای کوچک با مرکزیت خود آن نقطه در نظر بگیرید و شعاع را تا دربرگرفتن k نقطه افزایش دهید. افزون بر این، کره را چنان کوچک فرض کنید که $\mathbb{P}(\mathbf{x}_i)$ در آن به تقریب ثابت باشد.

در روش تخمین چگالی به‌کمک k-NN برای هر نقطه x یک کره با مرکز x در نظر می‌گیریم که دقیقاً شامل k همسایهٔ نزدیک آن باشد. اگر شعاع این کره را با $r_k(x)$ نشان دهیم، برآورد چگالی به‌صورت زیر است:

$$\hat{p}(x) = \frac{k}{n\, V_d(r_k(x))},$$

که در آن $V_d(r)$ حجم کره‌ای با شعاع r در بعد d است. حال اگر مقدار k ثابت نگه داشته شود اما نقطهٔ x در نواحی با چگالی‌های متفاوت قرار گیرد، حجم کرهٔ لازم برای یافتن k همسایه تغییر می‌کند. در نواحی پرت و کم‌نمونه، برای یافتن k همسایه لازم است کره بسیار بزرگ شود و بنابراین:

$$V_d(r_k(x)) \to \infty \quad \Rightarrow \quad \hat{p}(x) \to ۰.$$

این نکته نشان می‌دهد که برآورد چگالی k-NN انتگرال‌پذیر روی کل فضا نیست؛ بنابراین یک توزیع نامناسب - im distribution proper به‌وجود می‌آورد. زیرا اگر انتگرال چگالی را روی کل فضا حساب کنیم:

$$\int_{\mathbb{R}^d} \hat{p}(x)\, dx \neq ۱,$$

و در حالت کلی حتی ممکن است بی‌نهایت یا کوچکتر از ۱ شود.

۳. (۱۵ نمره) فرض کنید یک تابع رگرسیون $h(\mathbf{x})$ داریم که برای هر بردار ورودی $\mathbf{x}$ برچسب $y = h(\mathbf{x})$ را به آن نسبت می‌دهد. از دادگان آموزش استفاده کرده‌ایم و m مدل پیش‌بینی‌کننده آموزش داده‌ایم که آن‌ها را با $\hat{h}_1(\mathbf{x}), \hat{h}_2(\mathbf{x}), \ldots, \hat{h}_m(\mathbf{x})$ نشان می‌دهیم. اکنون قرار دهید:

$$\hat{H}_m(\mathbf{x}) = \frac{1}{m}\sum_{i=1}^{m} \hat{h}_i(\mathbf{x})$$

ثابت کنید که:

$$\mathbb{E}_{\mathbf{x}}\left[(\hat{H}_m(\mathbf{x}) - h(\mathbf{x}))^2\right] \leq \frac{1}{m}\sum_{i=1}^{m} \mathbb{E}_{\mathbf{x}}\left[(\hat{h}_i(\mathbf{x}) - h(\mathbf{x}))^2\right]$$

مفهوم این حکم چیست؟

واضح است که:

$$\hat{H}_m(x) - h(x) = \frac{1}{m}\sum_{i=1}^{m}\left(\hat{h}_i(x) - h(x)\right).$$

حال اگر از طرفین مربع بگیریم:

$$\left(\hat{H}_m(x) - h(x)\right)^2 = \left(\frac{1}{m}\sum_{i=1}^{m} a_i(x)\right)^2,$$

که در آن $a_i(x) = \hat{h}_i(x) - h(x)$ است. با استفاده از نابرابری Jensen برای تابع محدب $f(z) = z^2$ داریم:

$$\left(\frac{1}{m}\sum_{i=1}^{m} a_i(x)\right)^2 \leq \frac{1}{m}\sum_{i=1}^{m} a_i(x)^2.$$

بنابراین:

$$\left(\hat{H}_m(x) - h(x)\right)^2 \leq \frac{1}{m}\sum_{i=1}^{m}\left(\hat{h}_i(x) - h(x)\right)^2.$$

اکنون نسبت به x امید ریاضی می‌گیریم:

$$\mathbb{E}_x\left[\left(\hat{H}_m(x) - h(x)\right)^2\right] \leq \frac{1}{m}\sum_{i=1}^{m}\mathbb{E}_x\left[\left(\hat{h}_i(x) - h(x)\right)^2\right].$$

■ **مفهوم حکم:** این نابرابری بیان می‌کند که **میانگین‌گیری از چند مدل، خطا را کاهش می‌دهد**. به‌طور دقیق‌تر، متوسط گرفتن از چند پیش‌بینی‌کننده مستقل باعث کاهش واریانس خطا می‌شود (اثر میانگین‌گیری گروهی). به همین دلیل روش‌هایی مانند Bagging و Random Forest، عملکرد بهتری دارند:

میانگین خطای مدل‌ها $\leq$ خطای مدل میانگین.

۴. (۱۰ نمره) به سوالاتی که در ادامه آمده‌اند با بیان توضیحات کامل پاسخ دهید.

(الف) یک مدل Random Forest روی تعداد زیادی داده برای یک مسئلهٔ دسته‌بندی آموزش داده‌ایم. میزان خطای مدل روی دادگان آموزشی پایین است ولی روی دادگان آزمون خطای زیادی گزارش شده است. دو دلیل برای این مشکل بیان کنید و برای هر کدام راه‌حلی بگویید.

مدل روی داده‌های آموزش خطای پایینی دارد اما روی داده‌های آزمون خطای زیادی گزارش شده است. این پدیده نشان‌دهندهٔ **overfitting** است. دو دلیل اصلی برای بروز این رفتار عبارت‌اند از:

۱. **درخت‌های بسیار عمیق:** هر یک از درخت‌های جنگل تصادفی اگر عمق زیادی داشته باشند، می‌توانند به‌طور کامل داده‌های آموزش را حفظ کنند و الگوهای نویزی و غیرواقعی را نیز یاد بگیرند. در نتیجه، اگرچه دقت آموزش بسیار بالا است، ولی مدل روی داده‌های جدید تعمیم‌پذیری ضعیفی دارد.

۲. **عدم وجود تنوع کافی بین درخت‌ها:** اگر تعداد ویژگی‌ها در انتخاب تصادفی کم نباشد یا داده‌ها تنوع کافی نداشته باشند، آنگاه درخت‌ها بسیار شبیه یکدیگر می‌شوند. وقتی درخت‌ها بسیار هم‌بسته باشند،

$$\mathrm{Var}\left(\frac{۱}{m}\sum h_i(x)\right) \approx \mathrm{Var}(h_i(x))$$

و مزیت اصلی Random Forest که کاهش واریانس است از بین می‌رود. نبودِ تنوع باعث می‌شود مدل روی آموزش خوب عمل کند اما روی آزمون ضعیف شود.

راه‌حل‌ها برای هر مشکل: وقتی یک مدل روی داده‌های آموزش خطای بسیار کمی دارد اما روی داده‌های آزمون دچار خطای زیاد می‌شود، این رفتار را می‌توان با تحلیل بایاس–واریانس توضیح داد. اگر برای یک درخت منفرد $\hat{h}_i(x)$ داشته باشیم

$$\mathbb{E}\Big[(\hat{h}_i(x)-h(x))^۲\Big] = \underbrace{\big(\mathbb{E}[\hat{h}_i(x)]-h(x)\big)^۲}_{\mathrm{Bias}^۲} + \underbrace{\mathrm{Var}(\hat{h}_i(x))}_{\mathrm{Var}} + \sigma_\varepsilon^۲,$$

آنگاه میانگین‌گیری از m درخت به‌صورت $\bar{H}_m(x) = \frac{۱}{m}\sum_{i=۱}^m \hat{h}_i(x)$ واریانس را تنها در صورتی کاهش می‌دهد که هم‌بستگی بین درخت‌ها پایین باشد. زیرا:

$$\mathrm{Var}(\bar{H}_m(x)) = \frac{۱}{m}\mathrm{Var}(\hat{h}_i(x)) + \left(۱-\frac{۱}{m}\right)\mathrm{Cov}(\hat{h}_i(x),\hat{h}_j(x)).$$

اگر هر درخت به‌دلیل عمق زیاد یا پیچیدگی بالا واریانس بزرگی داشته باشد، یا اینکه درخت‌ها به‌دلیل استفاده از ویژگی‌های مشابه یا نمونه‌های تقریباً یکسان دارای هم‌بستگی بالا باشند، آنگاه مقدار Cov بزرگ شده و بخش اصلی واریانس کاهش نمی‌یابد. در چنین شرایطی مدل روی داده‌های آموزش عملکرد عالی دارد زیرا بایاس نزدیک به صفر است، اما روی داده‌های آزمون واریانسِ باقی‌مانده بسیار زیاد است و همین موجب overfitting می‌شود. راه‌حل‌ها نیز به‌صورت اصولی عبارت‌اند از کاهش واریانس تک‌درخت‌ها از طریق محدود کردن پیچیدگی (مثلاً کاهش عمق مؤثر یا افزایش حداقل تعداد نقاط لازم برای تقسیم)، کاهش هم‌بستگی بین درخت‌ها از طریق افزایش میزان تصادفی‌سازی در انتخاب ویژگی‌ها یا نمونه‌ها، افزایش تعداد درخت‌ها برای کوچک کردن جمله‌ی $\frac{۱}{m}\mathrm{Var}(\hat{h}_i)$، و در نهایت افزایش اندازهٔ دادهٔ آموزشی که هر دو جملهٔ واریانس و هم‌بستگی را کاهش می‌دهد. به‌طور خلاصه، مسئله ناشی از غالب شدن واریانس در خطای تعمیم است و راه‌حل‌ها نیز همگی از منظر ریاضی کاهش واریانس یا کاهش هم‌بستگی در مدل‌های تجمیعی را هدف قرار می‌دهند.

(ب) فرض کنید دادگان $\mathbf{X} = \{\mathbf{x}_i\}_{i=۱}^n$ با میانگین و واریانس $\mu, \sigma^۲$ داده شده‌اند. بگیرید:

$$\mathbf{z}_m = \frac{۱}{m}\Big(\sum_{i=۱}^m \mathbf{a}_i\Big)$$

که در آن $\mathbf{a}_i$ ها تصادفی و متمایز از $\mathbf{X}$ گزینش شده‌اند. میانگین و واریانس $\mathbf{z}_m$ را بیابید. اکنون بیان کنید مجموعه دادگان $\{\mathbf{z}_m\}$ چه خوبی و بدی‌هایی نسبت به $\mathbf{X}$ دارد و در چه شرایطی استفاده از آن برای آموزش مناسب است.

امید ریاضی متغیر z_m برابر است با:

$$\mathbb{E}[z_m] = \frac{۱}{m}\sum_{i=۱}^m \mathbb{E}[a_i] = \mathbb{E}[a_i]$$

واریانس z_m نیز چون a_i ها مستقل‌اند، برابر است با:

$$\mathrm{Var}(z_m) = \frac{۱}{m^۲}\sum_{i=۱}^{m}\mathrm{Var}(a_i) = \frac{\sigma_a^۲}{m}$$

مشاهده می‌کنیم که با زیاد شدن m، واریانس z_m کاهش پیدا می‌کند. بنابراین مجموعه‌ی $\{z_m\}$ هر چه m بزرگ‌تر باشد **پایدارتر و قابل اعتمادتر** است. نتیجه این است که اگر بخواهیم نسبت به مجموعه‌داده‌ی X یک معیار یا شاخص (مانند میانگین، احتمال، خطا و ...) بسازیم، استفاده از میانگین‌گیری‌های مشابه z_m زمانی مناسب است که:

- نمونه‌های مورد استفاده مستقل باشند،
- میانگین ثابت باشد،
- مقدار m به اندازه‌ی کافی بزرگ باشد تا واریانس کوچک شود.

در چنین شرایطی، z_m یک تخمین **کم‌واریانس و قابل اتکاء** نسبت به X خواهد بود.

۵. (۱۰ نمره) به سوالاتی که در ادامه آمده‌اند با بیان توضیحات کامل پاسخ دهید.

(الف) با توجه به تابع سیگموید به سوالات زیر پاسخ دهید.

- مشتق تابع سیگموید را بدست آورید (تمامی مراحل به طور کامل نوشته شود).
- تابع سیگموید و مشتق آن را رسم کنید. از نمودار بدست آمده کمک بگیرید و به طور شهودی توضیح دهید که مشکل تابع سیگموید در بروز رسانی وزن‌ها با کاهش گرادیان چیست.

تابع سیگموید به صورت زیر تعریف می‌شود:

$$\sigma(x) = \frac{۱}{۱+e^{-x}}.$$

برای مشتق آن، تابع را به صورت توان‌دار می‌نویسیم:

$$\sigma(x) = (۱+e^{-x})^{-۱}.$$

مشتق می‌گیریم:

$$\frac{d}{dx}\sigma(x) = -(۱+e^{-x})^{-۲}(-e^{-x}) = \frac{e^{-x}}{(۱+e^{-x})^۲}.$$

از طرفی:

$$\sigma(x) = \frac{۱}{۱+e^{-x}}, \qquad ۱-\sigma(x) = \frac{e^{-x}}{۱+e^{-x}},$$

بنابراین:

$$\boxed{\sigma'(x) = \sigma(x)\big(۱-\sigma(x)\big)}.$$

مقدار مشتق برای $\sigma(x) \approx ۰$ تقریباً صفر است. در نتیجه وقتی ورودی‌ها بسیار بزرگ یا بسیار کوچک شوند، گرادیان در شبکه‌های عصبی تقریباً ناپدید می‌شود و به‌روزرسانی وزن‌ها کند یا متوقف می‌گردد. بیشترین مقدار مشتق در $\sigma(x) = \frac{۱}{۲}$ رخ می‌دهد و برابر $\frac{۱}{۴}$ است. در ادامه نمودار تابع سیگموید و مشتق آن رسم شده است.

اشباع سیگموید (نزدیک به صفر یا یک شدن خروجی) باعث کوچک شدن مشتق و مشکل Vanishing Gradient در یادگیری می‌شود. به همین دلیل در شبکه‌های عمیق معمولاً از توابعی مانند ReLU استفاده می‌شود.

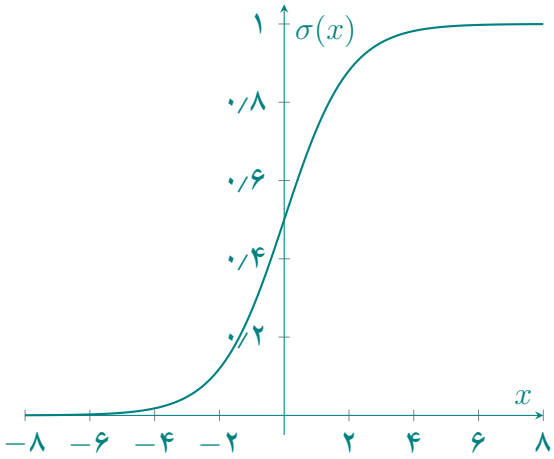

شکل ۱: تابع سیگموید

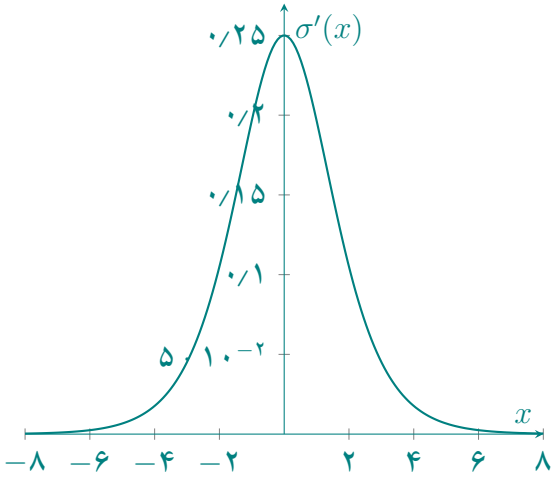

شکل ۲: مشتق تابع سیگموید

(ب) چرا رگرسیون لجستیک که با الگوریتم کاهش گرادیان آموزش داده می‌شود، بعضی وقت‌ها که دادگان تقریباً به طور خطی قابل تفکیک هستند، کند همگرا می‌شود؟

اگر داده‌ها تقریباً به طور خطی قابل تفکیک باشند، رگرسیون لجستیک در فرآیند آموزش تلاش می‌کند احتمال جداسازی کامل کلاس‌ها را بیشینه کند. در این حالت برای قرار دادن مرز تصمیم در ناحیهٔ کاملاً صحیح، الگوریتم گرادیان وزن‌ها را به سمت بی‌نهایت افزایش می‌دهد. زیرا برای نمونه‌های در نزدیکی مرز، تابع سیگموید مقدار مشتق بسیار کوچکی دارد:

$$\sigma'(x) = \sigma(x)\big(۱ - \sigma(x)\big) \approx ۰,$$

و در نتیجه گرادیان تابع هزینه نیز بسیار کوچک می‌شود. وقتی گرادیان کوچک باشد، گام‌های به‌روزرسانی وزن‌ها در الگوریتم کاهش گرادیان بسیار آهسته می‌شوند:

$$w := w - \eta \nabla L(w), \qquad \nabla L(w) \approx ۰ \Rightarrow \Delta w \text{ کوچک می‌شود}.$$

بنابراین اگر داده‌ها تقریباً خطی و قابل تفکیک باشند، رگرسیون لجستیک برای نزدیک شدن به مرز تصمیم بهینه، وزن‌ها را بسیار آهسته اصلاح می‌کند و فرآیند همگرایی کند خواهد شد.

(ج) در یک مسئلهٔ طبقه‌بندی چندکلاسه با K کلاس، به‌جای استفاده از چندین مدل دودویی، می‌توان از یک مدل چندکلاسه استفاده کرد. نشان دهید که اگر به همهٔ بردارهای پارامتر $\theta_1, \theta_2, \ldots, \theta_K$ یک بردار ثابت $\mathbf{c}$ اضافه کنیم، مقادیر احتمالات تغییری نمی‌کنند.

در یک مدل چندکلاسه با تابع softmax احتمال تعلق نمونه‌ی x به کلاس k برابر است با:

$$p(y = k \mid x) = \frac{\exp(\theta_k^\top x)}{\sum_{j=1}^{K} \exp(\theta_j^\top x)}.$$

حال فرض کنید یک بردار ثابت c را به تمام بردارهای پارامتر اضافه کنیم:

$$\theta'_k = \theta_k + c \qquad \forall k.$$

احتمال جدید به صورت زیر خواهد بود:

$$p'(y = k \mid x) = \frac{\exp\left((\theta_k + c)^\top x\right)}{\sum_{j=1}^{K} \exp\left((\theta_j + c)^\top x\right)}.$$

در نتیجه:

$$p'(y = k \mid x) = \frac{\exp(\theta_k^\top x)\ \exp(c^\top x)}{\sum_{j=1}^{K} \exp(\theta_j^\top x)\ \exp(c^\top x)}.$$

از آنجا که $\exp(c^\top x)$ یک ضریب مشترک در صورت و مخرج است، حذف می‌شود:

$$p'(y = k \mid x) = \frac{\exp(\theta_k^\top x)}{\sum_{j=1}^{K} \exp(\theta_j^\top x)} = p(y = k \mid x).$$

۶. (۱۵ نمره) به سوالاتی که در ادامه آمده‌اند با بیان توضیحات کامل پاسخ دهید.

(الف) برای یک مجموعه binary classification به صورت $(\mathbf{x}_i, y_i)$ که $y_i \in \{+1, -1\}$ مسئله hard-margin[2] را در نظر بگیرید که به صورت مسئله بهینه‌سازی

$$\min \left\{ \frac{1}{2} \|\mathbf{w}\|^2 \right\} \quad s.t. \quad y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1$$

تعریف می‌شود.

- توضیح دهید چرا Geometric Margin مربوط به این classifier برابر با

$$\gamma = \min_i \frac{y_i(\mathbf{w}^\top \mathbf{x}_i + b)}{\|\mathbf{w}\|}$$

است.

- چرا با کاهش دادن $\frac{1}{2}\|\mathbf{w}\|^2$ با توجه به شروط داده شده، این margin افزایش می‌یابد؟

در مسئله SVM، برای هر داده‌ی (x_i, y_i)، مقدار

$$y_i(w^T x_i + b)$$

را **functional margin** می‌نامیم. اما **فاصله‌ی اقلیدسی** نقطه x_i از مرز تصمیم‌گیری $w^T x + b = 0$ برابر است با:

$$\frac{|w^T x_i + b|}{\|w\|}.$$

از آنجا که $y_i \in \{+۱, -۱\}$ و $y_i(w^T x_i + b)$ همواره نامنفی است (اگر داده جداپذیر باشد و در حالت marginal)، داریم:

$$\frac{|w^T x_i + b|}{\|w\|} = \frac{y_i(w^T x_i + b)}{\|w\|}.$$

این مقدار، **geometri margin** برای نقطه i ام است. حال **geometric margin کل مجموعه داده** (در حالت hard margin) به صورت حداقل فاصله‌ی نقطه‌ها از ابرصفحه تعریف می‌شود:

$$\gamma = \min_{i=۱,\dots,m} \frac{y_i(w^T x_i + b)}{\|w\|}.$$

در فرمول مسئله بهینه‌سازی اولیه SVM با hard، margin شرط

$$y_i(w^T x_i + b) \geq ۱$$

برای همه i برقرار است. اگر این شرط را بر $\|w\|$ تقسیم کنیم، داریم:

$$\frac{y_i(w^T x_i + b)}{\|w\|} \geq \frac{۱}{\|w\|}.$$

پس:

$$\gamma = \min_i \frac{y_i(w^T x_i + b)}{\|w\|} \geq \frac{۱}{\|w\|}.$$

در حالت بهینه (وقتی داده جداپذیر خطی است و مدل درست آموزش دیده)، برای نقاط **support vector**،

$$y_i(w^T x_i + b) = ۱$$

برقرار است، بنابراین:

$$\gamma = \frac{۱}{\|w\|}.$$

قسمت دوم: چرا کاهش $\|w\|^۲$ باعث افزایش margin می‌شود؟ از آنجا که

$$\gamma = \frac{۱}{\|w\|}$$

در حالت بهینه، واضح است که هرچه $\|w\|$ کوچک‌تر باشد، γ بزرگ‌تر می‌شود. در مسئله بهینه‌سازی، تابع هدف

$$\min \frac{۱}{۲}\|w\|^۲$$

(که در واقع $\frac{۱}{r}\|w\|^۲$ با $r = ۲$ است) را در نظر می‌گیریم. کاهش $\|w\|^۲$ مستقیماً $\|w\|$ را کاهش می‌دهد، در نتیجه $\gamma = ۱/\|w\|$ افزایش می‌یابد.

دلیل هندسی: هنجار $\|w\|$ معیاری از شیب ابرصفحه است. اگر $\|w\|$ کوچک شود، ابرصفحه تغییر جهت کمتری دارد و فاصله‌ی نقاط support vector از آن بیشتر می‌شود (چون $۱/\|w\|$ رابطه عکس با $\|w\|$ دارد). بنابراین، مینیمم کردن $\|w\|^۲$ در عین رعایت شرط‌های جداسازی، باعث بیشینه‌شدن **حاشیه‌ی هندسی** می‌گردد.

(ب) فرض کنید مدل Linear Regression را داریم:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}, \qquad \boldsymbol{\epsilon} \sim \mathcal{N}(۰, \sigma\mathbf{I})$$

- فرم بسته‌ای برای تخمین‌گر least squares برای پارامتر $\boldsymbol{\beta}$ به دست آورید.
- نشان دهید که این تخمین‌گر unbiased است و ماتریس covariance آن را نیز به دست آورید.

تخمین‌گر کمترین مربعات برای β از حل مسئلهٔ بهینه‌سازی زیر بدست می‌آید:

$$\hat{\beta}_{\text{LS}} = \arg\min_{\beta} \|y - X\beta\|^{۲}.$$

با مشتق‌گیری نسبت به β و مساوی قرار دادن با صفر، نتیجهٔ زیر حاصل می‌شود:

$$\boxed{\hat{\beta}_{\text{LS}} = (X^T X)^{-۱} X^T y}$$

به شرط آنکه $X^T X$ وارون‌پذیر باشد.

برای اثبات نااریب بودن این تخمینگر، داریم:

$$\mathbb{E}[\hat{\beta}_{\text{LS}}] = \mathbb{E}\left[(X^T X)^{-۱} X^T y\right].$$

جایگذاری مدل $y = X\beta + \varepsilon$:

$$\mathbb{E}[\hat{\beta}_{\text{LS}}] = (X^T X)^{-۱} X^T \mathbb{E}[X\beta + \varepsilon].$$

از آنجا که $X\beta$ قطعی است و $\mathbb{E}[\varepsilon] = ۰$:

$$\mathbb{E}[X\beta + \varepsilon] = X\beta.$$

پس:

$$\mathbb{E}[\hat{\beta}_{\text{LS}}] = (X^T X)^{-۱} X^T X\beta.$$

چون

$$(X^T X)^{-۱} X^T X = I,$$

در نتیجه:

$$\boxed{\mathbb{E}[\hat{\beta}_{\text{LS}}] = \beta.}$$

پس میزان بایاس برابر است با:

$$\mathbb{E}[\hat{\beta}_{\text{LS}}] - \beta = \beta - \beta = ۰$$

۷. (۱۰ نمره) همان‌طور که می‌دانید اعتبارسنجی متقاطع[۳] با حذف یک نمونه یا LOOCV را می‌توان بدین گونه نشان داد:

$$e(S_n) = \frac{1}{n}\sum_{i=1}^{n}\left(y_i - \hat{f}_{-i}(\mathbf{x}_i)\right)^2$$

که در آن $S_n = \{(\mathbf{x}_1, y_1), \ldots, (\mathbf{x}_n, y_n)\}$ (مجموعه داده‌های آموزش)، $S_n^{-i} = S_n \backslash \{(\mathbf{x}_i, y_i)\}$ (مجموعه داده‌ها پس از حذف نمونهٔ iام)، و $\hat{f}_{-i}$ مدل آموزش‌دیده روی S_n^{-i} می‌باشند.

(الف) با فرض اینکه فقط نمونهٔ اول حذف شده است، خطا به شکل

$$e_1(S_n) = \left(y_1 - \hat{f}_{-1}(\mathbf{x}_1)\right)^2$$

است. نشان دهید:

$$\mathbb{E}\left[e_1(S_n)\right] = \mathbb{E}\left[\left(y - \hat{f}_{S_{n-1}}(\mathbf{x})\right)^2\right]$$

که در آن $(\mathbf{x}, y)$ یک نمونهٔ تصادفی از توزیع داده‌هاست و $\hat{f}_{S_{n-1}}$ مدل آموزش‌دیده روی S_{n-1} است.

چون تمام نمونه‌ها i.i.d هستند، متغیرهای تصادفی زیر از نظر توزیعی یکسان‌اند:

$$(x_1, y_1) \stackrel{d}{=} (x, y),$$

و مدل $\hat{f}_{-1}$ که روی $S_n^{-1} = \{(x_2, y_2), \ldots, (x_n, y_n)\}$ آموزش دیده، از نظر توزیعی با مدلی که روی هر مجموعه‌ی دیگر شامل $n-1$ نمونه‌ی i.i.d آموزش دیده باشد، یکسان است. بنابراین:

$$(x_1, y_1, \hat{f}_{-1}) \stackrel{d}{=} (x, y, \hat{f}_{S_{n-1}}).$$

با استفاده از نتیجه بالا:

$$(y_1, \hat{f}_{-1}) \stackrel{d}{=} (y, \hat{f}_{S_{n-1}})$$

و در نتیجه:

$$\mathbb{E}\left[(y_1 - \hat{f}_{-1}(x_1))^2\right] = \mathbb{E}\left[(y - \hat{f}_{S_{n-1}}(x))^2\right].$$

پس:

$$\boxed{\mathbb{E}[e_1(S_n)] = \mathbb{E}\left[(y - \hat{f}_{S_{n-1}}(x))^2\right]}$$

(ب) با استفاده از نتیجهٔ بالا، نشان دهید که:

$$\mathbb{E}\left[e(S_n)\right] = \mathbb{E}\left[\left(y - \hat{f}_{S_{n-1}}(\mathbf{x})\right)^2\right]$$

طبق تعریف، خطای LOOCV برابر است با

$$e(S_n) = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{f}_{-i}(x_i))^2.$$

اکنون امید ریاضی آن را می‌گیریم:

$$\mathbb{E}[e(S_n)] = \frac{1}{n}\sum_{i=1}^{n}\mathbb{E}\left[(y_i - \hat{f}_{-i}(x_i))^2\right].$$

به‌دلیل i.i.d بودن نمونه‌ها، متغیرهای تصادفی

$$(y_i, \hat{f}_{-i}), \quad i = 1, \ldots, n$$

همگی از نظر توزیعی یکسان‌اند؛ بنابراین تمام جملات جمع امید ریاضی یک مقدار دارند. پس:

$$\mathbb{E}[e(S_n)] = \mathbb{E}\Big[(y_۱ - \hat{f}_{-۱}(x_۱))^۲\Big].$$

در قسمت (الف) نشان داده شد که:

$$\mathbb{E}\Big[(y_۱ - \hat{f}_{-۱}(x_۱))^۲\Big] = \mathbb{E}\Big[(y - \hat{f}_{S_{n-۱}}(x))^۲\Big],$$

که در آن (x, y) یک مشاهده‌ی جدید i.i.d و $\hat{f}_{S_{n-۱}}$ مدل آموزش‌دیده روی $n-۱$ نمونه است. بنابراین نتیجه می‌گیریم:

$$\boxed{\mathbb{E}[e(S_n)] = \mathbb{E}\big[(y - \hat{f}_{S_{n-۱}}(x))^۲\big].}$$

۸. (۱۵ نمره) جدول دادگان زیر را برای یک مسئلهٔ دسته‌بندی غذا در نظر بگیرید:

دما	اندازه	مزه	خوشایندی
گرم	کوچک	شور	خیر
سرد	بزرگ	شیرین	خیر
سرد	بزرگ	شیرین	خیر
سرد	کوچک	ترش	بله
گرم	کوچک	ترش	بله
گرم	بزرگ	شور	خیر
گرم	بزرگ	ترش	بله
سرد	کوچک	شیرین	بله
سرد	کوچک	شیرین	بله
گرم	بزرگ	شور	خیر

(الف) آنتروپی[۴] اولیه ستون مربوط به خوشایند بودن غذا چند است؟

شمارش توزیع کلاس‌ها

- «**بله**»: ۵ مورد (ردیف‌های ۴، ۵، ۷، ۸، ۹)
- «**خیر**»: ۵ مورد (ردیف‌های ۱، ۲، ۳، ۶، ۱۰)

تعداد کل نمونه‌ها برابر است با $n = ۱۰$. محاسبه احتمالات:

$$p_{\text{بله}} = \frac{۵}{۱۰} = ۰/۵$$

$$p_{\text{خیر}} = \frac{۵}{۱۰} = ۰/۵$$

فرمول آنتروپی:

$$H(S) = -p_{\text{بله}} \log_۲(p_{\text{بله}}) - p_{\text{خیر}} \log_۲(p_{\text{خیر}})$$
$$H(S) = -۰/۵ \cdot \log_۲(۰/۵) - ۰/۵ \cdot \log_۲(۰/۵)$$
$$H(S) = -۰/۵ \cdot (-۱) - ۰/۵ \cdot (-۱)$$
$$H(S) = ۰/۵ + ۰/۵ = ۱$$

(ب) فرض کنید ویژگی مزه را ریشهٔ درخت گرفته‌ایم، اکنون information gain[۵] مربوط به این ویژگی را مشخص کنید.

فرمول محاسبه IG برابر است با:

$$IG(S,A) = H(S) - \sum_{v \in \text{Values}(A)} \frac{|S_v|}{|S|} H(S_v)$$

محاسبه Information Gain برای ویژگی "مزه"

- **شور**: ۳ نمونه (ردیف‌های ۱، ۶، ۱۰) - همه «خیر»
- **شیرین**: ۴ نمونه (ردیف‌های ۲، ۳، ۸، ۹) - ۲ «بله»، ۲ «خیر»
- **ترش**: ۳ نمونه (ردیف‌های ۴، ۵، ۷) - همه «بله»

محاسبه آنتروپی برای هر مقدار:

- **شور**: $H(S_{\text{شور}}) = ۰$ (همه یک کلاس)
- **شیرین**: $H(S_{\text{شیرین}}) = -\frac{۲}{۴}\log_۲(\frac{۲}{۴}) - \frac{۲}{۴}\log_۲(\frac{۲}{۴}) = ۱$
- **ترش**: $H(S_{\text{ترش}}) = ۰$ (همه یک کلاس)

محاسبه Information Gain:

$$IG(S,\text{مزه}) = ۱ - \left[\frac{۳}{۱۰} \times ۰ + \frac{۴}{۱۰} \times ۱ + \frac{۳}{۱۰} \times ۰\right] = ۰/۶$$

(پ) درخت تصمیم کامل را برای اجرای پیش‌بینی رسم کنید و همه محاسبات و مراحل را بیاورید.

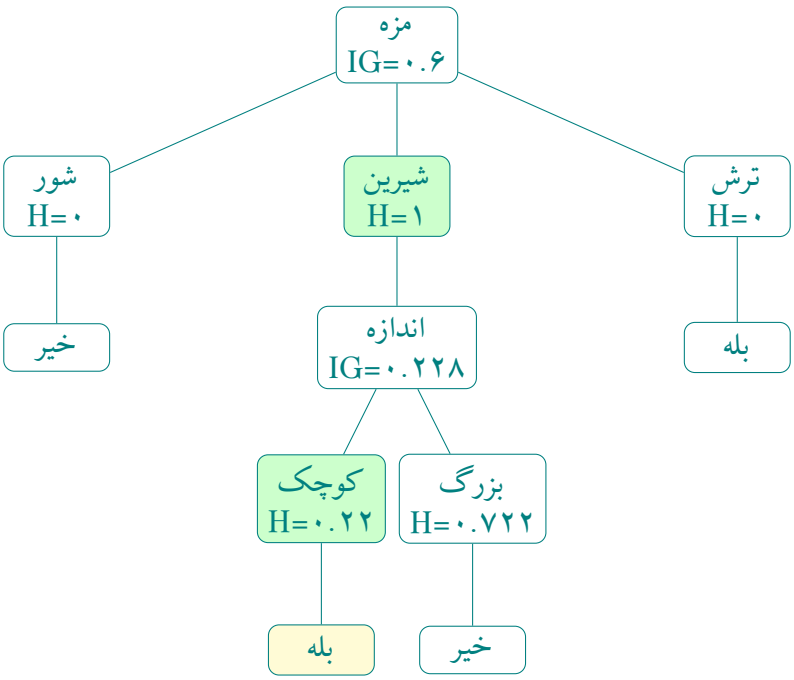

محاسبه Gain Information برای ویژگی "اندازه"

- **کوچک**: ۵ نمونه (ردیف‌های ۱، ۴، ۵، ۸، ۹) - ۴ «بله»، ۱ «خیر»
- **بزرگ**: ۵ نمونه (ردیف‌های ۲، ۳، ۶، ۷، ۱۰) - ۱ «بله»، ۴ «خیر»

محاسبه آنتروپی برای هر مقدار:

- **کوچک**:

$$H(S_{\text{کوچک}}) = -\frac{۴}{۵}\log_۲\left(\frac{۴}{۵}\right) - \frac{۱}{۵}\log_۲\left(\frac{۱}{۵}\right) = ۰/۷۲۲$$

- **بزرگ**:

$$H(S_{\text{بزرگ}}) = -\frac{۱}{۵}\log_۲\left(\frac{۱}{۵}\right) - \frac{۴}{۵}\log_۲\left(\frac{۴}{۵}\right) = ۰/۷۲۲$$

محاسبه Information Gain:

$$IG(S, \text{اندازه}) = ۱ - \left[\frac{۵}{۱۰} \times ۰/۷۷۲ + \frac{۵}{۱۰} \times ۰/۷۷۲\right]$$

$$IG(S, \text{اندازه}) = ۱ - [۰/۳۸۶ + ۰/۳۸۶] = ۱ - ۰/۷۷۲ = ۰/۲۲۸$$

محاسبه Gain Information برای ویژگی "دما"

- **گرم**: ۵ نمونه (ردیف‌های ۱، ۵، ۶، ۷، ۱۰) - ۲ «بله»، ۳ «خیر»
- **سرد**: ۵ نمونه (ردیف‌های ۲، ۳، ۴، ۸، ۹) - ۳ «بله»، ۲ «خیر»

محاسبه آنتروپی برای هر مقدار:

- **گرم:**

$$H(S_{\text{گرم}}) = -\frac{۲}{۵}\log_۲\left(\frac{۲}{۵}\right) - \frac{۳}{۵}\log_۲\left(\frac{۳}{۵}\right) = ۰/۹۷۱$$

- **سرد:**

$$H(S_{\text{سرد}}) = -\frac{۳}{۵}\log_۲\left(\frac{۳}{۵}\right) - \frac{۲}{۵}\log_۲\left(\frac{۲}{۵}\right) = ۰/۹۷۱$$

محاسبه Information Gain:

$$IG(S, \text{دما}) = ۱ - \left[\frac{۵}{۱۰} \times ۰/۹۷۱ + \frac{۵}{۱۰} \times ۰/۹۷۱\right]$$

$$IG(S, \text{دما}) = ۱ - [۰/۴۸۵۵ + ۰/۴۸۵۵] = ۱ - ۰/۹۷۱ = ۰/۰۲۹$$

(ت) اگر یک غذا شیرین، کوچک، و سرد باشد، پیش‌بینی ما با درخت قسمت قبل چه خواهد بود؟

مراحل پیش‌بینی در درخت تصمیم:

۱. **ریشه درخت: مزه**
غذا «شیرین» است $\rightarrow$ به شاخه «شیرین» می‌رویم

۲. **در سطح دوم: اندازه**
غذا «کوچک» است $\rightarrow$ به شاخه «کوچک» می‌رویم

۳. **در سطح سوم: دما**
غذا «سرد» است ← به شاخه «سرد» می‌رویم

۴. **برگ نهایی:**
در شاخه سرد، کلاس «بله» قرار دارد

(ث) یک نمونه bootstrap[۶] از دادگان جدول گرفته و درخت تصمیم‌گیری را دوباره بسازید.

مراحل نمونه‌گیری Bootstrap

نمونه‌گیری Bootstrap روشی است که در آن از داده‌های اصلی با جایگزینی نمونه‌گیری می‌شود. در این نمونه‌گیری ممکن است:

- برخی نمونه‌ها چند بار انتخاب شوند
- برخی اصلاً انتخاب نشوند
- درخت تصمیم متنوع‌تر شود

نمونه‌گیری زیر انجام شده است:

$$B = [۱, ۳, ۴, ۴, ۵, ۷, ۸, ۹, ۱۰, ۱۰]$$

جدول داده‌های Bootstrap

شماره	دما	اندازه	مزه	خوشایندی	تکرار
۱	گرم	کوچک	شور	خیر	۱ بار
۳	سرد	بزرگ	شیرین	خیر	۱ بار
۴	سرد	کوچک	ترش	بله	۲ بار
۵	گرم	کوچک	ترش	بله	۱ بار
۷	گرم	بزرگ	ترش	بله	۱ بار
۸	سرد	کوچک	شیرین	بله	۱ بار
۹	سرد	کوچک	شیرین	بله	۱ بار
۱۰	گرم	بزرگ	شور	خیر	۲ بار

توزیع کلاس‌ها

- بله: ۶ نمونه
- خیر: ۴ نمونه

محاسبه آنتروپی اولیه

$$H(S) = -\frac{۶}{۱۰}\log_۲\left(\frac{۶}{۱۰}\right) - \frac{۴}{۱۰}\log_۲\left(\frac{۴}{۱۰}\right)$$

$$H(S) = -۰/۶۰ \times (-۰/۷۳۷) - ۰/۴۰ \times (-۱/۳۲۲)$$

$$H(S) = ۰/۴۴۲ + ۰/۵۲۹ = ۰/۹۷۱$$

محاسبه IG ویژگی «مزه»

شور : ۳(همه خیر) نمونه $\Rightarrow H = ۰$

شیرین : ۳(۲ بله، ۱ خیر) نمونه

$$H = -\frac{۱}{۳}\log_۲\left(\frac{۱}{۳}\right) - \frac{۲}{۳}\log_۲\left(\frac{۲}{۳}\right) = ۰/۹۱۸$$

$$\text{ترش : ۵(همه بله) نمونه} \Rightarrow H = ۰$$

$$IG(S, \text{مزه}) = ۰/۹۷۱ - \left[\frac{۳}{۱۰}(۰) + \frac{۲}{۱۰}(۰/۹۱۸) + \frac{۵}{۱۰}(۰)\right]$$

$$IG(S, \text{مزه}) = ۰/۹۷۱ - ۰/۱۸۴ = ۰/۷۸۷$$

محاسبه IG ویژگی «اندازه»

$$S_{\text{کوچک}} : \text{۶(۱ خیر، ۵ بله) نمونه}$$

$$H = -\frac{۵}{۶}\log_۲\left(\frac{۵}{۶}\right) - \frac{۱}{۶}\log_۲\left(\frac{۱}{۶}\right) = ۰/۶۴۹$$

$$S_{\text{بزرگ}} : \text{۴(۳ خیر، ۱ بله) نمونه}$$

$$H = -\frac{۱}{۴}\log_۲\left(\frac{۱}{۴}\right) - \frac{۳}{۴}\log_۲\left(\frac{۳}{۴}\right) = ۰/۸۱۱$$

$$IG(S, \text{اندازه}) = ۰/۹۷۱ - [۰/۶۰(۰/۶۴۹) + ۰/۴۰(۰/۸۱۱)]$$

$$IG(S, \text{اندازه}) = ۰/۹۷۱ - ۰/۷۱۴ = ۰/۲۵۷$$

محاسبه IG ویژگی «دما»

$$S_{\text{گرم}} : \text{۵(۳ خیر، ۲ بله) نمونه} \Rightarrow H = ۰/۹۷۱$$

$$S_{\text{سرد}} : \text{۵(۱ خیر، ۴ بله) نمونه} \Rightarrow H = ۰/۷۲۲$$

$$IG(S, \text{دما}) = ۰/۹۷۱ - [۰/۵۰(۰/۹۷۱) + ۰/۵۰(۰/۷۲۲)]$$

$$IG(S, \text{دما}) = ۰/۹۷۱ - ۰/۸۴۶ = ۰/۱۲۵$$

درخت تصمیم Bootstrap

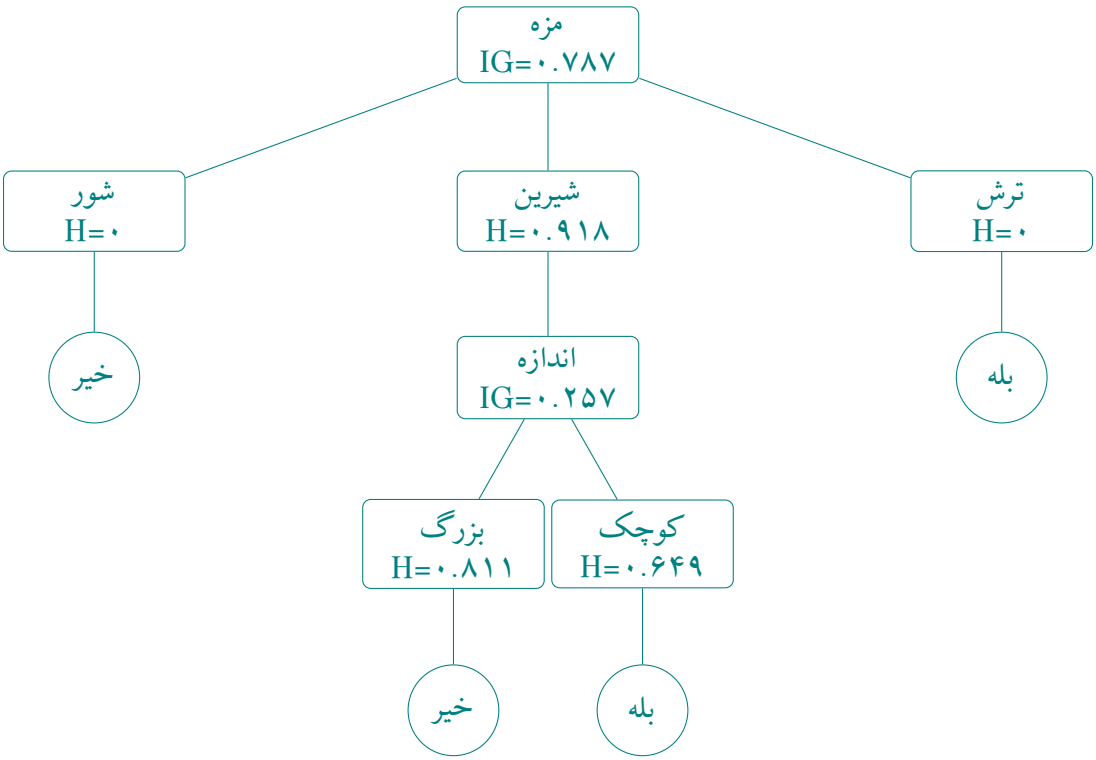

مقایسه با درخت اصلی

درخت اصلی	Bootstrap
آنتروپی اولیه = ۱	آنتروپی اولیه = ۰.۹۷۱
IG مزه = ۰.۶	IG مزه = ۰.۷۸۷
شیرین: ۴ نمونه (۲ بله، ۲ خیر)	شیرین: ۳ نمونه (۲ بله، ۱ خیر)
ترش: ۴ نمونه (همه بله)	ترش: ۵ نمونه (همه بله)
شور: ۳ نمونه (همه خیر)	شور: ۳ نمونه (همه خیر)

نتیجه‌گیری

Bootstrap باعث تغییر توزیع نمونه‌ها و ایجاد تنوع در ساخت درخت می‌شود. در این نمونه:

- ویژگی «مزه» همچنان بهترین ویژگی است.
- توزیع کلاس‌ها تغییر کرده است.
- آنتروپی شاخه شیرین تغییری نکرده است.
- این تنوع اساس Forest Random است.