دانشگاه صنعتی شریف
دانشکده‌ی مهندسی کامپیوتر

یادگیری ماشین
پاییز و زمستان ۱۴۰۴
استاد: علی شریفی زارچی
گردآورندگان:

تمرین دوم | موضوع | مهلت ارسال: ۱۷ آذر

سوالات نظری (۱۰۰ نمره)

۱. (۱۵ نمره) در هر مورد انتخاب خود را همراه با استدلال مختصر بیان کنید.

- کدام یک از موارد زیر مزایای معمولی هستند که ممکن است شما را ترغیب کند تا قبل از آموزش یک طبقه‌بندی‌کننده Classifier، داده‌ها را با PCA پیش‌پردازش کنید؟ (گزینه‌های صحیح را انتخاب کنید)

(آ) PCA تمایل دارد بایاس الگوریتم طبقه‌بندی شما را کاهش دهد.

نادرست است. در واقع PCA یک روش کاهش ابعاد بدون ناظر است که تنها ساختار واریانس داده‌ها را در نظر می‌گیرد و هیچ آگاهی از مرزهای طبقه‌بندی ندارد. به‌کارگیری PCA معمولاً باعث **افزایش بایاس** و **کاهش واریانس** مدل می‌شود، زیرا ابعاد کم‌اهمیت حذف شده و مدل ساده‌تر می‌گردد. به طور کلی حذف اطلاعات ممکن است بایاس را افزایش دهد.

(ب) از PCA می‌توان برای جلوگیری از بیش‌برازش (Overfitting) استفاده کرد.

درست است. کاهش ابعاد با PCA باعث حذف مؤلفه‌هایی می‌شود که سهم ناچیزی در واریانس داده دارند و اغلب دربردارندهٔ نویز هستند. این فرایند مدل طبقه‌بندی را ساده‌تر کرده و **واریانس مدل** را کاهش می‌دهد، در نتیجه احتمال **پیش‌برازش** کمتر می‌شود. بنابراین، استفاده از PCA به‌عنوان یک روش مؤثر برای کاهش Overfitting شناخته می‌شود.

(ج) PCA تمایل دارد واریانس الگوریتم طبقه‌بندی شما را کاهش دهد.

درست است. کاهش ابعاد از طریق PCA باعث حذف ویژگی‌های کم‌اهمیت و نویزی می‌شود و در نتیجه مدل طبقه‌بندی پیچیدگی کمتری خواهد داشت. این ساده‌سازی معمولاً منجر به **کاهش واریانس** مدل و افزایش توان تعمیم‌دهی آن می‌شود.

(د) از PCA می‌توان برای جلوگیری از کم‌برازش (Underfitting) استفاده کرد.

نادرست است. PCA با کاهش ابعاد، مدل را ساده‌تر می‌کند و در نتیجه معمولاً **بایاس را افزایش** و **واریانس را کاهش** می‌دهد. ساده‌تر شدن مدل نه‌تنها کم‌برازش را از بین نمی‌برد، بلکه حتی می‌تواند **به کم‌برازش بیشتر** منجر شود، زیرا اطلاعات موجود در برخی ابعاد حذف می‌شود. بنابراین از PCA برای جلوگیری از Underfitting استفاده نمی‌شود.

- گزاره‌های صحیح در مورد تحلیل مؤلفه‌های اصلی PCA را انتخاب کنید.

(آ) PCA یک الگوریتم خوشه‌بندی است.

نادرست. PCA یک روش کاهش ابعاد بدون‌ناظر است و هیچ ارتباطی با خوشه‌بندی ندارد.

(ب) PCA ویژگی‌هایی تولید می‌کند که ترکیبات خطی از ویژگی‌های ورودی هستند.

درست .تمام مؤلفه‌های اصلی، ترکیبات خطی از متغیرهای اولیه‌اند.

(ج) مؤلفه‌های اصلی طوری انتخاب می‌شوند که واریانس داده‌ها را به حداکثر برسانند.

درست. اولین مؤلفه اصلی بیشترین واریانس را دارد و مؤلفه‌های بعدی نیز به ترتیب بیشترین واریانس با قید عمودبودن را حفظ می‌کنند.

(د) مختصات اصلی همان مقادیر ویژهٔ ماتریس کوواریانس نمونه هستند.

نادرست. مقادیر ویژه میزان واریانس هر مؤلفهٔ اصلی را بیان می‌کنند، اما مختصات اصلی برابرند با تصویر داده‌ها روی بردارهای ویژه (eigenvectors).

- گزاره‌های صحیح دربارهٔ خوشه‌بندی k-means را انتخاب کنید.

(آ) k-means تضمین می‌کند که خوشه‌هایی را پیدا کند که تابع هزینه را کمینه کنند.

نادرست. الگوریتم k-means تنها تضمین می‌کند به یک کمینهٔ محلی همگرا شود، نه لزوماً کمینهٔ سراسری. در واقع k-means تضمین نمی‌کند که global minimum خوشه‌بندی را پیدا کند. بلکه فقط تضمین می‌کند که تابع هزینه در هر تکرار کاهش می‌یابد و الگوریتم در نهایت به یک نقطهٔ بهینهٔ محلی همگرا می‌شود.

(ب) در خروجی، هر دو خوشه توسط یک مرز تصمیم خطی جدا شده‌اند.

درست. مرکزهای خوشه‌ها نقاط را به‌وسیلهٔ نزدیک‌ترین مرکز تفکیک می‌کنند و نتیجه مرزهای تصمیم خطی (صفحات جداکننده) است. در الگوریتم ، هر نقطه به خوشه‌ی i نسبت داده می‌شود اگر فاصله‌ی آن تا مرکز μ_i کمتر از فاصله‌اش تا مرکز هر μ_j باشد:

$$x \in C_i \quad \Longleftrightarrow \quad \|x-\mu_i\|^۲ < \|x-\mu_j\|^۲.$$

رابطه‌ی زیر نشان می‌دهد که نقاطی که دقیقاً بین دو مرکز قرار می‌گیرند یک مرز خطی را تشکیل می‌دهند:

$$\|x-\mu_i\|^۲ = \|x-\mu_j\|^۲$$

با بسط این رابطه، به یک معادله‌ی خطی در x می‌رسیم:

$$۲(\mu_j-\mu_i)^\top x = \|\mu_j\|^۲ - \|\mu_i\|^۲,$$

بنابراین مرز تصمیم یک اَبَرصفحه‌ی خطی (Hyperplane) است.

(ج) امکان کرنلایز کردن k-means وجود ندارد.

هرچند k-means کلاسیک را نمی‌توان به‌صورت مستقیم کرنلایز کرد، اما نسخه‌ای با عنوان kernel k-means وجود دارد که یک **الگوریتم متفاوت** محسوب می‌شود. در k-means استاندارد، تابع هزینه بر پایه‌ی فاصله‌ی اقلیدسی تعریف می‌شود:

$$J = \sum_{i=۱}^{k} \sum_{x \in C_i} \|x-\mu_i\|^۲,$$

که تنها در فضای ورودی و با مراکز خوشه μ_i قابل محاسبه است؛ بنابراین الگوریتم ذاتاً خطی بوده و امکان کرنلایز شدن مستقیم آن وجود ندارد. اما در kernel k-means داده‌ها ابتدا با یک نگاشت $\phi(x)$ به فضای ویژگیِ پُربُعد منتقل می‌شوند و تابع هزینه به‌صورت زیر تعریف می‌شود:

$$J_{\text{kernel}} = \sum_{i=۱}^{k} \sum_{x \in C_i} \|\phi(x)-m_i\|^۲,$$

که در آن m_i میانگین خوشه در فضای کرنل است. با استفاده از kernel trick داریم:

$$K(x,y) = \langle \phi(x), \phi(y) \rangle,$$

می‌توان این هزینه را بدون محاسبه‌ی ϕ و تنها با مقادیر کرنل محاسبه کرد. به‌این‌ترتیب، kernel k-means یک نسخه‌ی تعمیم‌یافته است و نه کرنلایزکردنِ مستقیمِ k-means استاندارد؛ زیرا مراکز خوشه در فضای ورودی وجود خارجی ندارند و حد و مرزهای تصمیم دیگر خطی نخواهند بود.

(د) از دید آماری بهینه‌سازی k-means را با فرض پیشین گوسی روی میانگین‌ها و با استفاده از تخمین حداکثر درست‌نمایی توجیه می‌کنند.

درست. k-means را می‌توان به‌عنوان حالت خاصی از مدل مخلوط گاوسی (GMM) با کوواریانس‌های کروی و برابر، و تخمین پارامترها از طریق بیشینه‌سازی درست‌نمایی تفسیر کرد. فرض کنید داده‌ها $X = \{x_n\}_{n=1}^N \subset \mathbb{R}^d$ با مدل زیر تولید شده‌اند:

$$p(x_n \mid z_n = i, \mu_i) = \mathcal{N}(x_n \mid \mu_i, \sigma^2 I), \qquad P(z_n = i) = \frac{1}{K},$$

یعنی هر خوشه توسط یک توزیع گوسی کروی isotropic gaussian با واریانس مشترک σ^2 و وزن‌های برابر تولید می‌شود. با در نظر گرفتن تخصیص قطعی z_n و گرفتن لگاریتم درست‌نمایی کلی داریم:

$$\log p(X \mid Z, \{\mu_i\}) = -\frac{1}{2\sigma^2} \sum_{i=1}^{K} \sum_{n:z_n=i} \|x_n - \mu_i\|^2 + \text{const.}$$

بنابراین بیشینه‌سازیِ لگاریتمِ درست‌نمایی نسبت به $\{\mu_i\}$ متناظر است با کمینه‌سازی مجموع مربعات فاصله‌ها:

$$J(\{\mu_i\}, Z) = \sum_{i=1}^{K} \sum_{n:z_n=i} \|x_n - \mu_i\|^2,$$

که دقیقاً همان تابع هزینهٔ است.

- گزاره‌های صحیح دربارهٔ زمان اجرای الگوریتم k-means برای n نقطه با d ویژگی را انتخاب کنید.

(آ) مرحله به‌روزرسانی میانگین خوشه‌ها می‌تواند در زمان $\mathcal{O}(nd)$ اجرا شود.

درست. به‌روزرسانی میانگین خوشه‌ها شامل محاسبه میانگین برای هر خوشه است و در بدترین حالت تمام داده‌ها بررسی می‌شوند؛ بنابراین پیچیدگی زمانی آن برابر است با: $O(nd)$

(ب) افزایش k همیشه زمان اجرا را افزایش می‌دهد.

نادرست. افزایش k معمولاً زمان اجرا را افزایش می‌دهد، اما همیشه این‌گونه نیست؛ زیرا ممکن است تعداد تکرارهای الگوریتم کاهش یابد یا داده‌ها به‌گونه‌ای باشند که تغییر محسوسی رخ ندهد.

(ج) مرحلهٔ تخصیص خوشه‌ها می‌تواند در زمان $\mathcal{O}(nkd)$ اجرا شود.

درست. مرحله تخصیص داده‌ها به خوشه‌ها شامل محاسبه فاصله هر نقطه از هر مرکز خوشه است: $O(nkd)$

(د) الگوریتم k-means حداکثر در زمان $\mathcal{O}(nkd)$ اجرا می‌شود.

درست. پیچیدگی زمانی هر تکرار الگوریتم برابر است با: $O(nkd)$ و چون تعداد تکرارها معمولاً ثابت یا کوچک در نظر گرفته می‌شود، بیشینه زمان اجرای کلی: $O(nkd)$

۲. (۲۰ نمره) به سوالاتی که در ادامه آمده‌اند با بیان توضیحات کامل پاسخ دهید.

(آ) ثابت کنید الگوریتم k-means همگرا می‌شود.

هدف الگوریتم k-means کمینه کردن مجموع مربعات فاصله‌ها از مراکز خوشه است:

$$J = \sum_{i=1}^{k} \sum_{x \in C_i} \|x - \mu_i\|^2,$$

که در آن C_i خوشهٔ i و μ_i میانگین نقاط در آن خوشه است.

گام‌های الگوریتم

۱. **(Assignment) اختصاص:** هر نقطه به نزدیک‌ترین مرکز خوشه اختصاص می‌یابد.

۲. **(Update) به‌روزرسانی:** مراکز خوشه‌ها به میانگین نقاط اختصاص‌یافته به آن‌ها تغییر می‌کنند.

گام اختصاص: هر نقطه به خوشه‌ای با کمترین فاصله اختصاص داده می‌شود، بنابراین:

$$\|x - \mu_{\text{جدید}}\|^{۲} \leq \|x - \mu_{\text{قبلی}}\|^{۲},$$

و در نتیجه مجموع مربعات فاصله‌ها افزایش نمی‌یابد:

$$J_{\text{پس از اختصاص}} \leq J_{\text{قبل از اختصاص}}$$

گام به‌روزرسانی: میانگین خوشه به گونه‌ای انتخاب می‌شود که مجموع مربعات فاصله‌ها را کمینه کند:

$$\mu_i = \arg\min_{\mu} \sum_{x \in C_i} \|x - \mu\|^{۲}$$

پس:

$$J_{\text{پس از به‌روزرسانی}} \leq J_{\text{قبل از به‌روزرسانی}}$$

- هر تکرار الگوریتم (اختصاص + به‌روزرسانی) مقدار تابع هدف را کاهش می‌دهد یا ثابت نگه می‌دارد.
- تابع هدف $J \geq ۰$ است و بنابراین الگوریتم به مقداری همگرا می‌شود.
- همچنین، با توجه به اینکه تعداد حالات تخصیص خوشه‌ها (k^n) محدود است، الگوریتم حتماً در تعداد محدودی گام متوقف می‌شود.

(ب) با یک مثال عددی نشان دهید که الگوریتم k-means نسبت به داده‌های outlier مقاوم نیست. سپس با ارائه یک اصلاح ad-hoc سعی کنید مقاومت این روش را در شرایط حضور outlierها بهبود دهید. در رابطه با مزایا و معایب این تغییر بحث کنید.

مثال عددی برای اثبات حساسیت kmeans به outlier:
برای سادگی یک دیتاست یک بعدی را در نظر می‌گیریم:

$$X = \{۰, ۰, ۱, ۱, ۱۰\}, \qquad k = ۲.$$

فرض کنید مراکز اولیه را $\mu_۱^{(۰)} = ۰,\ \mu_۲^{(۰)} = ۱$ قرار دهیم. گام تخصیص (assignment) و به‌روزرسانی (update) را یک بار اجرا می‌کنیم:

- تخصیص نقاط به نزدیک‌ترین مرکز:

$$C_۱ = \{۰, ۰\}, \qquad C_۲ = \{۱, ۱, ۱۰\}.$$

(نقطه ۱۰ به مرکز ۱ نزدیک‌تر است: $|۱۰ - ۱| = ۹ < |۱۰ - ۰| = ۱۰$.)

- به‌روزرسانی میانگین‌ها:

$$\mu_۱ = \text{mean}(C_۱) = \frac{۰ + ۰}{۲} = ۰, \qquad \mu_۲ = \text{mean}(C_۲) = \frac{۱ + ۱ + ۱۰}{۳} = \frac{۱۲}{۳} = ۴.$$

نتیجه: مرکز خوشه دوم از ۱ به ۴ منتقل شده — یعنی حضور یک outlier (نقطه‌ی ۱۰) میانگین خوشه را به‌طور چشمگیری تغییر داده است. اگر بخواهیم بدون آن outlier عمل کنیم (مثلاً فرض کنیم آن را حذف کنیم) آنگاه:

$$C'_۲ = \{۱, ۱\} \quad \Rightarrow \quad \mu'_۲ = \frac{۱+۱}{۲} = ۱,$$

که بسیار معقول‌تر است. این نشان می‌دهد kmeans به‌خاطر استفاده از میانگین (که تابعی حساس به مقادیر دورافتاده است) نسبت به هاoutlier آسیب‌پذیر است.

یک اصلاح ad-hoc

در هر تکرار، قبل از محاسبهٔ میانگین هر خوشه، درصد یا تعداد کمی از نقاطی را که بیشترین فاصله را از مرکز خوشهٔ مربوطه دارند، «قلم‌گیری» (trim) می‌کنیم و تنها از بقیهٔ نقاط برای محاسبهٔ میانگین استفاده می‌کنیم. یعنی الگوریتم در هر تکرار:

۱. هر نقطه را به نزدیک‌ترین مرکز اختصاص می‌دهد (همان $O(nkd)$ تخصیص).

۲. برای هر خوشه j:

(آ) محاسبهٔ فواصل نقاط عضو C_j تا مرکز موقت μ_j.

(ب) حذف r نقطه با بزرگ‌ترین فاصله (یا حذف کسری α از نقاط با بزرگ‌ترین فواصل).

(ج) محاسبهٔ میانگین جدید μ_j با استفاده از نقاط باقیمانده.

۳. تکرار تا همگرایی.

اگر در مثال بالا $r = ۱$ (یعنی یک نقطه با بیشترین فاصله را در هر خوشه حذف کنیم)، در خوشهٔ دوم نقطهٔ ۱۰ حذف می‌شود و میانگین خوشهٔ دوم به ۱ برمی‌گردد — همان نتیجهٔ دلخواه را می‌گیریم.

پیچیدگی زمانی: هر تکرار، علاوه بر هزینهٔ تخصیص $O(nkd)$، در هر خوشه لازم است نقاط بر اساس فاصله مرتب یا حداقل r بزرگ‌ترین فواصل انتخاب شوند. با یک پیاده‌سازی ساده خواهیم داشت:

$$\text{هزینه هر تکرار} = O(nkd) + O\Big(\sum_j |C_j| \log |C_j|\Big) \le O(nkd + n \log n).$$

مزایا

- **افزایش پایداری در برابر outliers**: حذف برخی نقاط دورافتاده باعث می‌شود مراکز به نماینده‌های اصلی تراکم داده‌ها نزدیک‌تر بمانند.
- **ساده و قابل‌پیاده‌سازی:** پیاده‌سازی نسبتاً ساده است و از تغییرات بنیادین در الگوریتم جلوگیری می‌کند.
- **قابلیت تنظیم:** پارامتر r یا α قابل تنظیم است تا میزان robustness را کنترل کنیم.

معایب

- **نیاز به تعیین پارامتر اضافی:** انتخاب مقدار بهینهٔ r یا α غیربدیهی است و ممکن است به داده بستگی داشته باشد.
- **خطر حذف نقاط مفید:** اگر پارامتر خیلی بالا انتخاب شود، نقاط واقعیِ متعلق به خوشه‌های کوچک یا مرزها ممکن است حذف شوند و خوشه‌ها تحریف شوند.
- **افزایش هزینهٔ محاسباتی:** علی‌رغم ساده‌بودن، محاسبهٔ فواصل و انتخاب بزرگ‌ترین‌ها هزینهٔ اضافی ایجاد می‌کند.

- **عدم تضمین بهینهٔ جهانی:** مانند kmeans استاندارد، همگرایی به مینیمم محلی است و trimming پارامتر جدیدی به فضا اضافه می‌کند که ممکن است رفتار ناخواسته ایجاد کند.

(ج) الگوریتم‌های k-means و DBSCAN را از حیث مقاومت نسبت به داده‌های outlier مقایسه کنید.

الگوریتم k-means نسبت به داده‌های پرت حساس است. دلیل آن این است که k-means از **میانگین نقاط خوشه** به‌عنوان مرکز استفاده می‌کند و بنابراین داده‌های پرت می‌توانند مرکز خوشه را جابه‌جا کنند و نتایج خوشه‌بندی را به شدت تحت تأثیر قرار دهند. در مقابل، الگوریتم DBSCAN مبتنی بر تراکم نقاط است. نقاطی که تعداد همسایه کافی در شعاع مشخص ϵ نداشته باشند، به خوشه‌ها اختصاص داده نمی‌شوند و نویز (noise) علامت‌گذاری می‌شوند. به همین دلیل، DBSCAN نسبت به داده‌های پرت مقاومت بالایی دارد و نتایج خوشه‌بندی آن تحت تأثیر داده‌های پرت نیست.

۳. (۱۵ نمره) مجموعه نمونه زیر از شش نقطه $\mathbf{X}_i \in \mathbb{R}^۲$ را در نظر بگیرید:

$$\left\{\begin{pmatrix}۰\\۰\end{pmatrix}, \begin{pmatrix}۰\\۱\end{pmatrix}, \begin{pmatrix}۱\\۰\end{pmatrix}, \begin{pmatrix}۱\\۲\end{pmatrix}, \begin{pmatrix}۲\\۱\end{pmatrix}, \begin{pmatrix}۲\\۲\end{pmatrix}\right\}$$

(آ) میانگین نقاط نمونه را محاسبه کرده و ماتریس طرح متمرکز (Centered Design Matrix) را بنویسید.

(ب) تمام مؤلفه‌های اصلی را بیابید و آن‌ها را به صورت بردار واحد بنویسید.

(الف) میانگین و ماتریس طرح متمرکز

میانگینِ نقاط:

$$\bar{X} = \frac{۱}{۶}\sum_{i=۱}^{۶} X_i = (۱, ۱).$$

ماتریس دادهٔ اولیه را به صورت $X \in \mathbb{R}^{۶\times ۲}$ و ماتریس متمرکز را X_c می‌نامیم (هر سطر یک نمونه):

$$X = \begin{pmatrix} ۰ & ۰ \\ ۰ & ۱ \\ ۱ & ۰ \\ ۱ & ۲ \\ ۲ & ۱ \\ ۲ & ۲ \end{pmatrix}, \qquad X_c = X - ۱\bar{X}^\top = \begin{pmatrix} -۱ & -۱ \\ -۱ & ۰ \\ ۰ & -۱ \\ ۰ & ۱ \\ ۱ & ۰ \\ ۱ & ۱ \end{pmatrix}.$$

(ب) مؤلفه‌های اصلی به‌صورت بردار واحد

ابتدا ماتریس کوواریانس (با تقسیم بر $n-۱$) را محاسبه می‌کنیم:

$$S = \frac{۱}{۵}X_c^\top X_c = \frac{۱}{۵}\begin{pmatrix} ۴ & ۲ \\ ۲ & ۴ \end{pmatrix}.$$

چندجمله‌ای مشخصه برابر است با دترمینان $\det(S-\lambda I) = ۰$. بنابراین:

$$\det\left(\begin{pmatrix} \frac{۴}{۵}-\lambda & \frac{۲}{۵} \\ \frac{۲}{۵} & \frac{۴}{۵}-\lambda \end{pmatrix}\right) = ۰.$$

دترمینان را محاسبه می‌کنیم:

$$\left(\frac{۴}{۵}-\lambda\right)^۲ - \left(\frac{۲}{۵}\right)^۲ = ۰.$$

عبارت داخل را باز می‌کنیم تا چندجمله‌ای درجهٔ دوم به‌دست آید:

$$\lambda^{۲} - \frac{۸}{۵}\lambda + \frac{۱۶}{۲۵} - \frac{۴}{۲۵} = ۰ \quad \Longrightarrow \quad \lambda^{۲} - \frac{۸}{۵}\lambda + \frac{۱۲}{۲۵} = ۰.$$

از فرمول حل معادلهٔ درجهٔ دوم استفاده می‌کنیم:

$$\lambda = \frac{\frac{۸}{۵} \pm \sqrt{\left(\frac{۸}{۵}\right)^{۲} - ۴ \cdot ۱ \cdot \frac{۱۲}{۲۵}}}{۲} = \frac{\frac{۸}{۵} \pm \sqrt{\frac{۶۴}{۲۵} - \frac{۴۸}{۲۵}}}{۲} = \frac{\frac{۸}{۵} \pm \sqrt{\frac{۱۶}{۲۵}}}{۲}.$$

از آن‌جا که $\sqrt{\frac{۱۶}{۲۵}} = \frac{۴}{۵}$، داریم:

$$\lambda = \frac{\frac{۸}{۵} \pm \frac{۴}{۵}}{۲}.$$

دو ریشهٔ حاصل می‌شوند:

$$\lambda_{۱} = \frac{\frac{۸}{۵} + \frac{۴}{۵}}{۲} = \frac{\frac{۱۲}{۵}}{۲} = \frac{۶}{۵}, \qquad \lambda_{۲} = \frac{\frac{۸}{۵} - \frac{۴}{۵}}{۲} = \frac{\frac{۴}{۵}}{۲} = \frac{۲}{۵}.$$

مقادیر ویژهٔ ماتریس S به‌صورت زیر هستند:

$$\boxed{\lambda_{۱} = \frac{۶}{۵}, \qquad \lambda_{۲} = \frac{۲}{۵}}$$

ابتدا ماتریس $S - \lambda_{۱} I$ را تشکیل می‌دهیم:

$$S - \lambda_{۱} I = \begin{pmatrix} \frac{۴}{۵} - \frac{۶}{۵} & \frac{۲}{۵} \\ \frac{۲}{۵} & \frac{۴}{۵} - \frac{۶}{۵} \end{pmatrix} = \begin{pmatrix} -\frac{۲}{۵} & \frac{۲}{۵} \\ \frac{۲}{۵} & -\frac{۲}{۵} \end{pmatrix}.$$

حل دستگاه:

$$\begin{pmatrix} -\frac{۲}{۵} & \frac{۲}{۵} \\ \frac{۲}{۵} & -\frac{۲}{۵} \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} ۰ \\ ۰ \end{pmatrix}.$$

از معادلهٔ اول:

$$-\frac{۲}{۵}x + \frac{۲}{۵}y = ۰ \quad \Longrightarrow \quad y = x.$$

پس یک بردار ویژه (قبل از نرمال‌سازی):

$$u_{۱} = \begin{pmatrix} ۱ \\ ۱ \end{pmatrix}.$$

نرمال‌سازی:

$$\|u_{۱}\| = \sqrt{۱^{۲} + ۱^{۲}} = \sqrt{۲}, \qquad u_{۱}^{(\mathrm{norm})} = \frac{۱}{\sqrt{۲}} \begin{pmatrix} ۱ \\ ۱ \end{pmatrix}.$$

تشکیل ماتریس:

$$S - \lambda_{۲} I = \begin{pmatrix} \frac{۴}{۵} - \frac{۲}{۵} & \frac{۲}{۵} \\ \frac{۲}{۵} & \frac{۴}{۵} - \frac{۲}{۵} \end{pmatrix} = \begin{pmatrix} \frac{۲}{۵} & \frac{۲}{۵} \\ \frac{۲}{۵} & \frac{۲}{۵} \end{pmatrix}.$$

حل دستگاه:

$$\frac{۲}{۵}x + \frac{۲}{۵}y = ۰ \quad \Longrightarrow \quad x + y = ۰ \quad \Longrightarrow \quad y = -x.$$

پس یک بردار ویژه (قبل از نرمال‌سازی):

$$u_۲ = \begin{pmatrix} ۱ \\ -۱ \end{pmatrix}.$$

نرمال‌سازی:

$$\|u_۲\| = \sqrt{۱^۲ + (-۱)^۲} = \sqrt{۲}, \qquad u_۲^{(\text{norm})} = \frac{۱}{\sqrt{۲}} \begin{pmatrix} ۱ \\ -۱ \end{pmatrix}.$$

بنابراین بردارهای ویژهٔ نرمال‌شدهٔ ماتریس S عبارت‌اند از:

$$\boxed{u_۱ = \frac{۱}{\sqrt{۲}} \begin{pmatrix} ۱ \\ ۱ \end{pmatrix}, \qquad u_۲ = \frac{۱}{\sqrt{۲}} \begin{pmatrix} ۱ \\ -۱ \end{pmatrix}}$$

(ج) اگر فقط از یک مؤلفه استفاده کنیم، کدام ترجیح دارد؟ الگوریتم PCA از چه اطلاعاتی برای ترجیح یکی بر دیگری استفاده می‌کند؟ از منظر بهینه‌سازی، چرا آن یکی را ترجیح می‌دهیم؟

در مسئلهٔ حاضر، ماتریس کوواریانس به‌صورت زیر به‌دست آمده است:

$$S = \begin{pmatrix} \frac{۴}{۵} & \frac{۲}{۵} \\ \frac{۲}{۵} & \frac{۴}{۵} \end{pmatrix},$$

و مقادیر ویژهٔ آن عبارت‌اند از:

$$\lambda_۱ = \frac{۶}{۵}, \qquad \lambda_۲ = \frac{۲}{۵}.$$

هر مقدار ویژه نشان‌دهندهٔ مقدار **واریانسی** است که مؤلفهٔ متناظر با آن در داده‌ها توضیح می‌دهد. بنابراین مؤلفه‌ای که مقدار ویژهٔ بزرگ‌تری داشته باشد، **اطلاعات بیشتری از داده حفظ می‌کند**. چون:

$$\lambda_۱ > \lambda_۲,$$

پس مؤلفهٔ اول که بردار ویژهٔ آن:

$$u_۱ = \frac{۱}{\sqrt{۲}} \begin{pmatrix} ۱ \\ ۱ \end{pmatrix}$$

است، **به عنوان مؤلفهٔ اصلی برتر انتخاب می‌شود**. این مؤلفه بیشترین واریانس ممکن را در داده‌ها حفظ می‌کند. الگوریتم PCA برای انتخاب مؤلفه‌ها از **مقادیر ویژهٔ ماتریس کوواریانس** استفاده می‌کند. معیار PCA این است که:

مؤلفهٔ بهتر $\iff$ مقدار ویژهٔ بزرگ‌تر.

زیرا مقدار ویژهٔ بزرگ‌تر یعنی:

واریانس بیشتر $\implies$ اطلاعات بیشتر.

بنابراین مؤلفه‌ای که واریانس بیشتری را پوشش دهد، در رتبهٔ بالاتری قرار می‌گیرد. PCA از یک مسئلهٔ بهینه‌سازی به‌دست می‌آید. برای یافتن اولین مؤلفهٔ اصلی، الگوریتم جهت u را طوری انتخاب می‌کند که:

$$\max_{\|u\|=۱} \; u^\top S u$$

که در آن:

- S ماتریس کوواریانس داده است،
- u بردار جهت مؤلفهٔ اصلی،

- قید $\|u\| = ۱$ به این دلیل است که تنها جهت اهمیت دارد و نه طول بردار.

این مسئلهٔ بهینه‌سازی **دقیقاً** با بردار ویژهٔ متناظر با بزرگ‌ترین مقدار ویژه حل می‌شود. بنابراین جهت بهینه (مؤلفهٔ اول):

$$u_۱ = \arg\max_{\|u\|=۱} u^\top S u.$$

ازآنجاکه:

$$\lambda_۱ = \frac{۶}{۵}$$

بزرگ‌ترین مقدار ویژه است، پس $u_۱$ بهترین جهت از نظر حفظ واریانس و بهینه‌سازی است.

(د) بردار تصویر هر یک از نقاط (نه نقاط متمرکز شده) را بر روی مؤلفهٔ اصلی ترجیحی محاسبه کنید.

بردار مؤلفهٔ اصلی اول برابر است با

$$u_۱ = \frac{۱}{\sqrt{۲}} \begin{pmatrix} ۱ \\ ۱ \end{pmatrix}.$$

برای هر نقطه‌ی X_i، ضریب تصویر روی $u_۱$ برابر است با

$$s_i = u_۱^\top X_i,$$

و بردار تصویر برابر است با

$$\hat{X}_i = s_i\, u_۱$$

X_i	$s_i = u_۱^\top X_i$	$\hat{X}_i = s_i\, u_۱$
$(۰, ۰)$	۰	$(۰, ۰)$
$(۰, ۱)$	$\frac{۱}{\sqrt{۲}}$	$\left(\frac{۱}{۲}, \frac{۱}{۲}\right)$
$(۱, ۰)$	$\frac{۱}{\sqrt{۲}}$	$\left(\frac{۱}{۲}, \frac{۱}{۲}\right)$
$(۱, ۲)$	$\frac{۳}{\sqrt{۲}}$	$\left(\frac{۳}{۲}, \frac{۳}{۲}\right)$
$(۲, ۱)$	$\frac{۳}{\sqrt{۲}}$	$\left(\frac{۳}{۲}, \frac{۳}{۲}\right)$
$(۲, ۲)$	$\frac{۴}{\sqrt{۲}}$	$(۲, ۲)$

۴. (۲۰ نمره) به سوالاتی که در ادامه آمده‌اند با بیان توضیحات کامل پاسخ دهید.

(آ) در دسته‌ای از مسائل تخمین پارامتر، با مدل‌هایی رو به رو هستیم که خروجی‌های آن، علاوه بر مجموعه‌ای از نمونه‌های مشاهده‌شده ($\mathbf{X}$)، شامل مجموعه‌ای از اطلاعات نهان ($\mathbf{Z}$) نیز می‌باشد. حضور پارامتر جدید $\mathbf{Z}$ به عنوان یک مجهول، باعث می‌شود تکنیک‌هایی نظیر MLE در این مسائل قابل استفاده نباشد. الگوریتم EM برای پاسخ به این چالش، مسئله را به دو مرحله تقسیم می‌کند. در هر گام t:

۱. ابتدا پارامترهای توزیع $\boldsymbol{\theta}^{(t)}$ ثابت در نظر گرفته می‌شود و امید ریاضی تابع log likelihood نسبت به توزیع شرطی $\mathbb{P}(\mathbf{Z} \mid \mathbf{X}, \boldsymbol{\theta}^{(t)})$ به دست می‌آید.

۲. سپس همانند روش‌های پیشین تخمین پارامتر، پارامترهایی که مقدار به‌دست‌آمده را بیشینه کنند، به عنوان پارامترهای جدید انتخاب می‌شوند.

یکی از مهم‌ترین کاربردهای این مدل‌سازی، تخمین پارامترهای توزیع‌های مخلوط است؛ به این صورت که تعلق نمونه‌ها به هر مؤلفه توسط پارامتر نهان $\mathbf{Z}$ مدل‌سازی می‌شود.
توزیع مخلوط زیر را در نظر بگیرید:

$$\mathbb{P}(X) = \alpha\lambda_1 e^{-\lambda_1 X} + (1-\alpha)\lambda_2 e^{-\lambda_2 X}$$

فرض کنید نمونه‌های $\{X_1, \dots, X_n\} \overset{iid}{\sim} \mathbb{P}(X)$ را در اختیار داریم و می‌خواهیم با EM پارامترهای $\alpha, \lambda_1, \lambda_2$ را تخمین بزنیم. اگر متغیر نهان Z_i به صورت زیر تعریف شود:

$$Z_i = \begin{cases} 0 & X_i \text{ comes from the first component of } \mathbb{P}(X) \\ 1 & X_i \text{ comes from the second component of } \mathbb{P}(X) \end{cases}$$

تابع complete-data log likelihood که به شکل $\log \mathbb{P}(X_1, Z_1, \dots, X_n, Z_n \mid \lambda_1, \lambda_2, \alpha)$ تعریف می‌شود را بیابید.

تابع likelihood log کامل:

$$\ell_c(\lambda_1, \lambda_2, \alpha) = \sum_{i=1}^{n} \log \mathbb{P}(X_i, Z_i \mid \lambda_1, \lambda_2, \alpha)$$

توزیع توأم برای هر مشاهده:

$$\mathbb{P}(X_i, Z_i) = [\alpha\lambda_1 e^{-\lambda_1 X_i}]^{Z_i} \cdot [(1-\alpha)\lambda_2 e^{-\lambda_2 X_i}]^{1-Z_i}$$

با گرفتن لگاریتم داریم:

$$\begin{aligned} \log \mathbb{P}(X_i, Z_i) = {} & Z_i[\log\alpha + \log\lambda_1 - \lambda_1 X_i] \\ & + (1-Z_i)[\log(1-\alpha) + \log\lambda_2 - \lambda_2 X_i] \end{aligned}$$

$$\ell_c(\lambda_1, \lambda_2, \alpha) = \sum_{i=1}^{n} [Z_i(\log\alpha + \log\lambda_1 - \lambda_1 X_i) + (1-Z_i)(\log(1-\alpha) + \log\lambda_2 - \lambda_2 X_i)] \quad (1)$$

یا به صورت باز شده:

$$\begin{aligned} \ell_c = {} & \left(\sum_{i=1}^{n} Z_i\right) \log(\alpha\lambda_1) + \left(\sum_{i=1}^{n}(1-Z_i)\right) \log((1-\alpha)\lambda_2) \\ & - \lambda_1 \sum_{i=1}^{n} Z_i X_i - \lambda_2 \sum_{i=1}^{n}(1-Z_i) X_i \end{aligned} \quad (2)$$

(ب) امید ریاضی تابع complete-data log likelihood را نسبت به متغیرهای نهان محاسبه کنید (در محاسبات خود به مقدار $\mathbb{E}\left[Z_i \mid X_i, \alpha^{(t)}, \lambda_1^{(t)}, \lambda_2^{(t)}\right]$ نیاز خواهید داشت و باید آن را محاسبه کنید)

باید امید ریاضی تابع likelihood log کامل را نسبت به توزیع شرطی Z_i محاسبه کنیم:

$$Q(\lambda_1, \lambda_2, \alpha \mid \lambda_1^{(t)}, \lambda_2^{(t)}, \alpha^{(t)}) = \mathbb{E}_{Z_i|X_i,\theta^{(t)}}[\ell_c]$$

ابتدا احتمال پسین را با استفاده از قانون بیز محاسبه می‌کنیم:

$$\gamma_i^{(t)} := \mathbb{P}(Z_i = 1 \mid X_i, \theta^{(t)}) = \frac{\alpha^{(t)}\lambda_1^{(t)}e^{-\lambda_1^{(t)}X_i}}{\alpha^{(t)}\lambda_1^{(t)}e^{-\lambda_1^{(t)}X_i} + (1-\alpha^{(t)})\lambda_2^{(t)}e^{-\lambda_2^{(t)}X_i}}$$

بنابراین:

$$\mathbb{E}[Z_i \mid X_i, \theta^{(t)}] = \gamma_i^{(t)}$$
$$\mathbb{E}[1 - Z_i \mid X_i, \theta^{(t)}] = 1 - \gamma_i^{(t)}$$

$$\begin{aligned} Q(\lambda_1, \lambda_2, \alpha \mid \theta^{(t)}) = &\sum_{i=1}^{n} \gamma_i^{(t)}(\log\alpha + \log\lambda_1 - \lambda_1 X_i) \\ &+ \sum_{i=1}^{n}(1-\gamma_i^{(t)})(\log(1-\alpha) + \log\lambda_2 - \lambda_2 X_i) \end{aligned} \tag{3}$$

(ج) روابط به‌روزرسانی پارامترهای λ_1 و α را استخراج کنید. (برای سادگی، مقدار مرحلهٔ قبل را $\gamma_i^{(t)}$ بنامید.)

در M گام، باید تابع Q را نسبت به پارامترها ماکسیمم کنیم. قسمت مربوط به α در Q:

$$Q_\alpha = \sum_{i=1}^{n}\gamma_i^{(t)}\log\alpha + \sum_{i=1}^{n}(1-\gamma_i^{(t)})\log(1-\alpha)$$

مشتق می‌گیریم و برابر صفر قرار می‌دهیم:

$$\frac{\partial Q_\alpha}{\partial\alpha} = \sum_{i=1}^{n}\frac{\gamma_i^{(t)}}{\alpha} - \sum_{i=1}^{n}\frac{1-\gamma_i^{(t)}}{1-\alpha} = 0$$

$$\boxed{\alpha^{(t+1)} = \frac{1}{n}\sum_{i=1}^{n}\gamma_i^{(t)}} \tag{4}$$

قسمت مربوط به λ_1:

$$Q_{\lambda_1} = \sum_{i=1}^{n}\gamma_i^{(t)}(\log\lambda_1 - \lambda_1 X_i)$$

مشتق می‌گیریم:

$$\frac{\partial Q_{\lambda_1}}{\partial\lambda_1} = \sum_{i=1}^{n}\gamma_i^{(t)}\left(\frac{1}{\lambda_1} - X_i\right) = 0$$

$$\boxed{\lambda_1^{(t+1)} = \frac{\sum_{i=1}^{n}\gamma_i^{(t)}}{\sum_{i=1}^{n}\gamma_i^{(t)}X_i}} \tag{5}$$

۵. (۱۵ نمره) برای هر یک از خوشه‌بندی‌های ارائه‌شده روی نقاط دوبعدی (هر کدام با $k = ۲$ خوشه) که در آن نقاط قرمز مربوط به خوشهٔ اول و نقاط آبی مربوط به خوشهٔ دوم هستند، مشخص کنید کدام‌یک از الگوریتم‌های زیر می‌توانستند منجر به این تخصیص خوشه‌ای شده باشند:

(آ) الگوریتم k-means

(ب) خوشه‌بندی single-link

(ج) مدل‌های مخلوط گاوسی Gaussian Mixture Models (GMM)

(د) هیچ‌یک از موارد فوق

ممکن است بیش از یک پاسخ صحیح باشد؛ تمام گزینه‌هایی را که ممکن است منجر به این خوشه‌بندی شده باشند با بیان استدلال ذکر کنید.

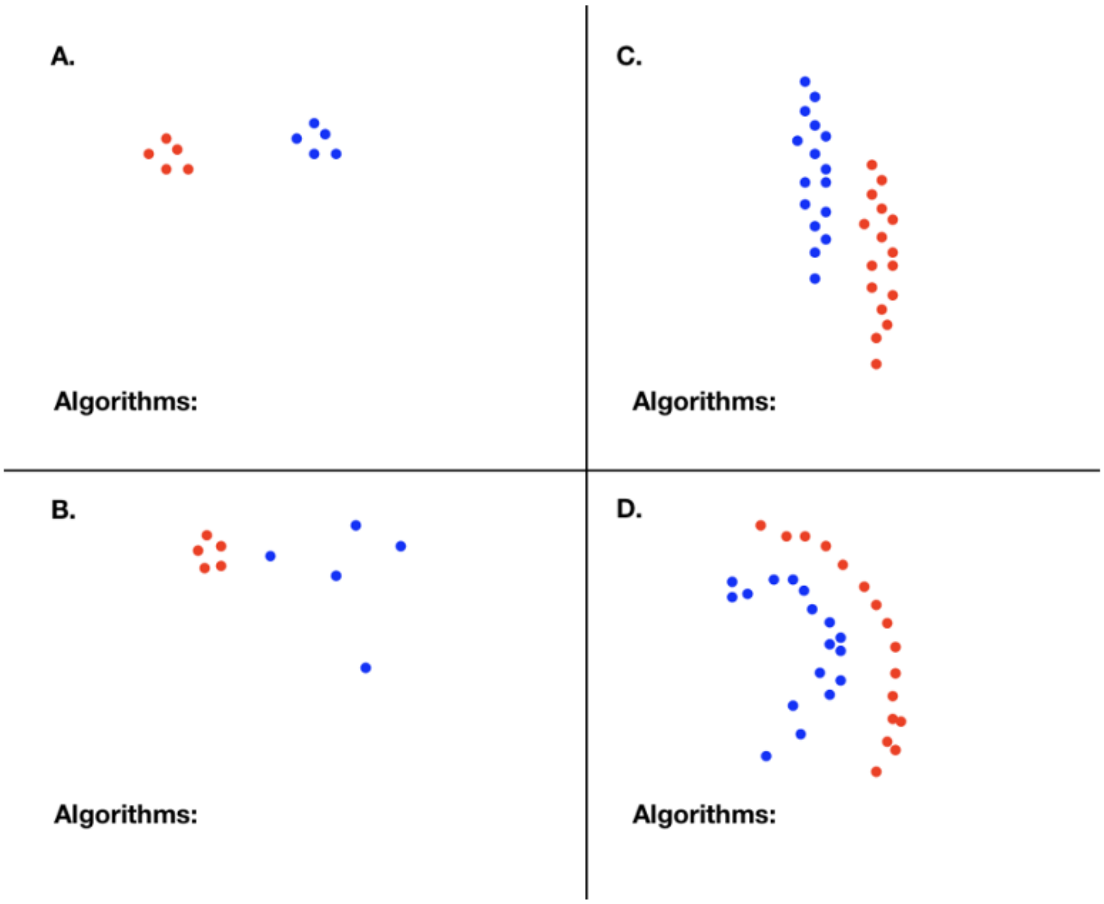

شکل A

در این شکل دو خوشه کاملاً کروی، فشرده و جدا از هم قرار دارند. این نوع ساختار برای هر سه الگوریتم مناسب است.

- **k-means**: خوشه‌ها محدب و جدا از هم هستند، بنابراین k-means به‌خوبی آن‌ها را تفکیک می‌کند.
- **single-link**: فاصلهٔ بین دو خوشه زیاد است، پس الگوریتم پیوندی نیز آن‌ها را جدا می‌کند.
- **GMM**: هر خوشه تقریباً شبیه یک توزیع نرمال دوبعدی است، بنابراین مدل مخلوط گاوسی کاملاً مناسب است.

شکل B

در این شکل نقاط پراکنده و بدون ساختار واضح و شکل‌نامنظم دارند اما نسبتاً جدا هستند.

- **k-means**: خوشه‌های کروی با اندازه تقریباً یکسان می‌سازد - این الگو را تولید نمی‌کند.
- **single-link**: چون کمترین فاصلهٔ بین اعضای دو خوشه زیاد نیست، این الگوریتم نمی‌تواند به خوبی جدا کند و معمولاً نقاط نزدیک به هم را در یک خوشه قرار می‌دهد.
- **GMM**: از آن‌جا که یک خوشه شبیه توزیع گاوسی نیست، عملکرد GMM ممکن است ایدئال نباشد، ولی همچنان با کواریانس آزاد قابل مدل‌سازی است.

شکل C

در این شکل دو خوشه در امتداد دو ستون باریک عمودی قرار دارند. هر خوشه کشیده و تقریباً خطی است.

- **k-means**: مرز سخت ایجاد می‌کند ــ با وجود همپوشانی، ممکن است خوشه‌بندی خوبی نباشد اما می‌تواند خوشه‌بندی مشابهی ایجاد کند
- **single-link**: می‌تواند شکل‌های دلخواه را تشخیص دهد اما با توجه به نزدیکی نقاط در مرز مشترک، ممکن است خوشه‌بندی اشتباه انجام دهد
- **GMM**: بسیار مناسب - می‌تواند با دو توزیع گوسی با همپوشانی این خوشه‌بندی را مدل کند.

شکل D

در این شکل خوشه‌ها به شکل دو نیم‌دایره یا دو «ماه‌نیمه» قرار دارند و به‌شدت **غیرمحدب** هستند. این حالت مشهورترین مثال شکست k-means و GMM است.

- **k-means**: مرزهای آن محدب هستند؛ نمی‌تواند خوشه‌های خمیدهٔ غیرخطی را تفکیک کند.
- **GMM**: هر مولفهٔ گاوسی محدب است و نمی‌تواند خوشه‌های هلالی را مدل کند.
- **single-link**: می‌تواند شکل‌های دلخواه را تشخیص دهد اما با توجه به نزدیکی نقاط در مرز مشترک، ممکن است خوشه‌بندی اشتباه انجام دهد

شکل	الگوریتم‌های ممکن
A	همهٔ الگوریتم‌ها
B	هیچ کدام
C	GMM
D	single-link

۶. (۱۵ نمره) می‌دانیم که نمایش‌های کم‌بعد برای مجموعه داده $D = \{\mathbf{x}_1, \mathbf{x}_2, \ldots \mathbf{x}_n\}$ در PCA به صورت زیر تعریف می‌شوند:

$$\mathbf{z}_i = \mathbf{U}^\top(\mathbf{x}_i - \boldsymbol{\mu})$$

که در آن $\mathbf{U}$ ماتریسی است که سطرهای آن شامل k بردار ویژهٔ بالایی ماتریس کوواریانس هستند و

$$\boldsymbol{\mu} = \frac{۱}{n}\sum_{i=۱}^{n}\mathbf{x}_i$$

می‌باشد. نشان دهید که میانگین نمایش‌های کم‌بعد برابر صفر است:

$$\bar{\mathbf{z}} = \frac{۱}{n}\sum_{i=۱}^{n}\mathbf{z}_i = ۰$$

برای محاسبهٔ میانگین نمایش‌های کم‌بعد داریم:

$$\bar{z} = \frac{۱}{n}\sum_{i=۱}^{n} z_i = \frac{۱}{n}\sum_{i=۱}^{n} U^\top(x_i - \mu).$$

چون $U^\top$ یک ماتریس ثابت است، می‌توان آن را از جمع بیرون کشید:

$$\bar{z} = U^\top\left(\frac{۱}{n}\sum_{i=۱}^{n}(x_i - \mu)\right).$$

اکنون داخل پرانتز را ساده می‌کنیم:

$$\frac{۱}{n}\sum_{i=۱}^{n}(x_i - \mu) = \left(\frac{۱}{n}\sum_{i=۱}^{n} x_i\right) - \mu.$$

ولی از تعریف میانگین داده‌ها می‌دانیم:

$$\mu = \frac{۱}{n}\sum_{i=۱}^{n} x_i.$$

پس عبارت داخل پرانتز برابر صفر می‌شود:

$$\frac{۱}{n}\sum_{i=۱}^{n}(x_i - \mu) = ۰.$$

در نتیجه:

$$\bar{z} = U^\top(۰) = ۰.$$

در PCA ابتدا داده‌ها را **حول میانگین مرکز** می‌کنیم. بنابراین بردارهای $(x_i - \mu)$ به صورت متقارن حول صفر پخش می‌شوند و میانگین آن‌ها صفر است. وقتی این بردارها را به فضای کم‌بعدی جدید ($z_i = U^\top(x_i - \mu)$) می‌فرستیم، این تبدیل خطی همچنان میانگین صفر را حفظ می‌کند. به همین دلیل میانگین ویژگی‌های کم‌بعدی (بردارهای z_i) همیشه صفر است.