پاسخنامه تمرین سوم | شبکه های عصبی | مهلت ارسال:

سوالات نظری (۱۰۰ نمره)

۱. (۸ نمره)

بخش اول: گزاره‌های زیر صحیح است یا خیر؟ مختصر توضیح دهید.

آ. اگر به تعداد کافی پرسپترون و لایه داشته باشیم، می‌توانیم هر تابع پیوسته‌ای را با دقت دلخواه تقریب بزنیم.

ب. تابع هزینه در یک شبکه عصبی عمیق، به دلیل وجود توابع فعال‌سازی غیرخطی و ساختار چند لایه، همواره یک تابع غیرمحدب است.

پ. یک شبکه عصبی که تنها یک لایه دارد و از تابع فعال‌سازی Sigmoid برای خروجی، به همراه تابع هزینه Cross-entropy برای دسته‌بندی دودویی استفاده می‌کند، کاملاً با مدل Logistic regression یکسان است.

ت. پارامترهای گاما (γ) و بتا (β) در لایه نرمال‌سازی دسته‌ای، هایپرپارامتر هستند که باید قبل از شروع آموزش به صورت دستی تنظیم شوند و در حین Backpropagation به‌روزرسانی نمی‌شوند.

بخش دوم: به سوالات زیر پاسخ کوتاه دهید.

آ. چرا مقداردهی اولیه صفر برای تمام وزن‌های یک شبکه عصبی ایده بدی است و باعث چه مشکلی در فرآیند یادگیری می‌شود؟

ب. چرا توابع فعال‌سازی در لایه‌های مخفی یک شبکه عصبی باید غیرخطی باشند؟ اگر همه آن‌ها خطی باشند چه اتفاقی می‌افتد؟

پ. مکانیزم بهینه‌ساز «مومنتوم» (Momentum) را با روش «کاهش شیب تصادفی» (SGD) استاندارد مقایسه کنید. مومنتوم برای حل چه مشکلی در فرآیند بهینه‌سازی معرفی شده است؟

ت. روش «حذف تصادفی»[۱] چگونه کار می‌کند و نقش اصلی آن به عنوان یک روش تنظیم‌گری[۲] چیست؟ چرا این روش فقط در مرحله آموزش فعال است و در مرحله آزمون باید غیرفعال شود؟

حل.

پاسخنامه بخش اول: بررسی صحت گزاره‌ها

آ. صحیح. این گزاره اشاره به «قضیه تقریب جهانی» (Universal Approximation Theorem) دارد. طبق این قضیه، یک شبکه عصبی Feedforward با تنها یک لایه مخفی (و تعداد کافی نورون) و یک تابع فعال‌سازی غیرخطی مناسب (مانند ReLU)، قادر است هر تابع پیوسته‌ای را با هر دقت دلخواهی تقریب بزند.

[۱] Dropout
[۲] Regularization

ب. صحیح. توابع هزینه در شبکه‌های عصبی عمیق (برخلاف مدل‌های خطی ساده)، سطوحی بسیار پیچیده با تعداد زیادی کمینه محلی (Local Minima) و نقاط زین‌اسبی (Saddle Points) دارند. ترکیب توابع فعال‌سازی غیرخطی در لایه‌های متوالی باعث می‌شود رابطه بین پارامترها و خطا غیرخطی شده و تابع هزینه خاصیت محدب بودن (Convexity) را از دست بدهد.

پ. صحیح. یک شبکه عصبی تک‌لایه که ورودی‌ها را مستقیماً وزن‌دهی کرده، از تابع فعال‌سازی Sigmoid عبور دهد و با تابع هزینه Cross-entropy بهینه‌سازی شود، دقیقاً فرمول‌بندی ریاضی و ساختار مدل رگرسیون لجستیک (Logistic Regression) را پیاده‌سازی می‌کند.

ت. غلط. پارامترهای γ (Scale) و β (Shift) در لایه Batch Normalization، «هایپرپارامتر» نیستند بلکه «پارامترهای قابل یادگیری» (Learnable Parameters) هستند. شبکه در طول فرآیند Back-propagation گرادیان این دو پارامتر را محاسبه کرده و آن‌ها را به‌روزرسانی می‌کند.

پاسخنامه بخش دوم: پاسخ کوتاه

آ. مشکل شکست تقارن: اگر تمام وزن‌ها با صفر (یا یک عدد ثابت یکسان) مقداردهی شوند، تمام نورون‌های لایه مخفی ورودی یکسانی دریافت کرده و خروجی یکسانی تولید می‌کنند. در نتیجه، گرادیان محاسبه شده برای همه آن‌ها یکسان خواهد بود و همگی به یک شکل به‌روزرسانی می‌شوند. این باعث می‌شود عملاً تمام نورون‌ها مثل «یک نورون» عمل کنند و شبکه قدرت یادگیری را از دست بدهد.

ب. ضرورت غیرخطی بودن: اگر توابع فعال‌سازی خطی باشند، ترکیب چندین لایه خطی همچنان معادل یک تابع خطی خواهد بود (چون ترکیب توابع خطی، خطی است: $W_2(W_1x) = W_{new}x$). در این حالت، شبکه عمیق به یک شبکه تک‌لایه (پرسپترون ساده) تقلیل می‌یابد و عمق شبکه بی‌اثر می‌شود.

پ. ممانعت از نوسان و سرعت بخشیدن: در SGD استاندارد، مسیر حرکت ممکن است دارای نوسانات شدید باشد. «مومنتوم» با اضافه کردن کسری از بردار به‌روزرسانی قبلی به گام فعلی، نوسانات را در جهاتی که تغییر جهت زیاد است خنثی کرده و در جهاتی که گرادیان هم‌سو است، سرعت همگرایی را افزایش می‌دهد.

ت. نقش تنظیم‌گری (Regularization) : روش Dropout با حذف تصادفی درصدی از نورون‌ها در حین آموزش، مانع از وابستگی شدید نورون‌ها به هم (Co-adaptation) می‌شود و مدل را مجبور به یادگیری ویژگی‌های مقاوم‌تر می‌کند. در مرحله آزمون غیرفعال می‌شود تا از تمام ظرفیت شبکه (مانند میانگین‌گیری از چندین مدل) استفاده شود.

نکات تکمیلی و رفع ابهام

در مورد دو سوال از بخش اول، ممکن است برداشت‌های متفاوتی وجود داشته باشد که لازم است مد نظر قرار گیرد:

- **در مورد سوال (آ) بخش اول:** پاسخ «صحیح» بر مبنای روح کلی قضیه تقریب جهانی است. اما دقیق‌ترین بیان ریاضی قضیه نیازمند شرط «فشرده بودن» (Compactness) دامنه ورودی است (یعنی بازه بسته و کران‌دار). اگر دامنه نامتناهی باشد، ممکن است تقریب با تعداد متناهی نورون امکان‌پذیر نباشد.

- **در مورد سوال (ب) بخش اول:** استفاده از کلمه «همواره» ممکن است چالش‌برانگیز باشد. هدف سوال تمایز قائل شدن بین مسائل بهینه‌سازی محدب کلاسیک و فضای غیرمحدب شبکه‌های عمیق است. اگرچه می‌توان موارد خاص و ساده‌ای ساخت که غیرمحدب نباشند، اما در عرف یادگیری عمیق، فرض بر غیرمحدب بودن تابع هزینه است.

۲. (۱۲ نمره) یک شبکه عصبی با ۲ ورودی، ۲ نورون در لایه مخفی[۳] با تابع فعال‌سازی ReLU و یک نورون خروجی با تابع فعال‌سازی Sigmoid داده شده است. پارامترها به صورت زیر هستند:

$$W^{(۱)} = \begin{bmatrix} ۱ & -۱ \\ ۰/۵ & ۰/۵ \end{bmatrix}, \quad b^{(۱)} = \begin{bmatrix} ۰ \\ ۰/۵ \end{bmatrix}, \quad W^{(۲)} = \begin{bmatrix} ۱ & -۱/۵ \end{bmatrix}, \quad b^{(۲)} = ۰/۲$$

برای ورودی $x = \begin{bmatrix} ۲ \\ -۱ \end{bmatrix}$ و برچسب $y = ۱$ ، موارد زیر را انجام دهید:

الف. یک مرحله پیش‌روی کامل[۴] را اجرا کرده و مقادیر $a^{(۱)}$، h، $z^{(۲)}$ و $\hat{y}$ را به دست آورید. (در اینجا h خروجی فعال‌شده لایه مخفی است).

ب. با استفاده از تابع هزینه[۵] Cross-Entropy که در زیر تعریف شده است، گرادیان‌های هزینه نسبت به تمام پارامترها را محاسبه کرده و مقادیر عددی آن‌ها را به دست آورید.

$$\mathcal{L}(\hat{y}, y) = -[y \ln \hat{y} + (۱ - y) \ln(۱ - \hat{y})]$$

گرادیان‌های مورد نیاز: $\frac{\partial \mathcal{L}}{\partial W^{(۱)}}$، $\frac{\partial \mathcal{L}}{\partial b^{(۱)}}$، $\frac{\partial \mathcal{L}}{\partial W^{(۲)}}$، $\frac{\partial \mathcal{L}}{\partial b^{(۲)}}$

پ. (۱) تعداد کل پارامترهای قابل آموزش برای یک شبکه عصبی تماماً متصل[۶] با n نورون در لایه ورودی، یک لایه مخفی با k نورون، و m نورون در لایه خروجی را به صورت یک فرمول کلی بنویسید.
(۲) با استفاده از فرمول به دست آمده، تعداد کل پارامترهای قابل آموزش برای شبکه تعریف شده در این سوال را محاسبه کنید.

ت. از لحاظ مفهومی توضیح دهید که افزودن یک لایه مخفی جدید به یک شبکه عصبی، چه تأثیری بر ظرفیت مدل می‌گذارد و چرا این کار احتمال بیش‌برازش[۷] را افزایش می‌دهد؟

حل.

الف. ابتدا مقادیر مرحله پیش‌روی (Forward Pass) را محاسبه می‌کنیم.

۱. **محاسبه خروجی لایه مخفی:** فرض می‌کنیم $a^{(۱)}$ مقدار ورودی خالص به لایه مخفی باشد (که معمولاً با $z^{(۱)}$ نیز نمایش داده می‌شود) و h خروجی فعال شده باشد.

$$a^{(۱)} = W^{(۱)}x + b^{(۱)} = \begin{bmatrix} ۱ & -۱ \\ ۰/۵ & ۰/۵ \end{bmatrix} \begin{bmatrix} ۲ \\ -۱ \end{bmatrix} + \begin{bmatrix} ۰ \\ ۰/۵ \end{bmatrix} = \begin{bmatrix} ۲ - (-۱) \\ ۱ - ۰/۵ \end{bmatrix} + \begin{bmatrix} ۰ \\ ۰/۵ \end{bmatrix} = \begin{bmatrix} ۳ \\ ۰/۵ \end{bmatrix} + \begin{bmatrix} ۰ \\ ۰/۵ \end{bmatrix} = \begin{bmatrix} ۳ \\ ۱ \end{bmatrix}$$

حال تابع فعال‌سازی ReLU را اعمال می‌کنیم تا h بدست آید:

$$h = \mathrm{ReLU}(a^{(۱)}) = \begin{bmatrix} \max(۰, ۳) \\ \max(۰, ۱) \end{bmatrix} = \begin{bmatrix} ۳ \\ ۱ \end{bmatrix}$$

۲. **محاسبه خروجی نهایی:** مقدار ورودی خالص لایه خروجی ($z^{(۲)}$):

$$z^{(۲)} = W^{(۲)}h + b^{(۲)} = \begin{bmatrix} ۱ & -۱/۵ \end{bmatrix} \begin{bmatrix} ۳ \\ ۱ \end{bmatrix} + ۰/۲ = (۳ - ۱/۵) + ۰/۲ = ۱/۵ + ۰/۲ = ۱/۷$$

---

[۳] Hidden Layer
[۴] Pass Forward
[۵] Loss Function
[۶] Fully Connected Neural Network
[۷] Overfit

محاسبه $\hat{y}$ با تابع Sigmoid :

$$\hat{y} = \sigma(z^{(۲)}) = \frac{۱}{۱ + e^{-۱/۷}} \approx \frac{۱}{۱ + ۰/۱۸۲۶۸} \approx ۰/۸۴۵۵$$

نتیجه نهایی بخش الف:

$$a^{(۱)} = \begin{bmatrix} ۳ \\ ۱ \end{bmatrix}, \quad h = \begin{bmatrix} ۳ \\ ۱ \end{bmatrix}, \quad z^{(۲)} = ۱/۷, \quad \hat{y} \approx ۰/۸۴۵۵$$

ب. برای محاسبه گرادیان‌ها از روش پس‌انتشار (Backpropagation) استفاده می‌کنیم. با توجه به $y = ۱$، مشتق تابع هزینه نسبت به ورودی خالص لایه آخر ($\delta^{(۲)}$) برابر است با:

$$\frac{\partial \mathcal{L}}{\partial z^{(۲)}} = \delta^{(۲)} = \hat{y} - y = ۰/۸۴۵۵ - ۱ = -۰/۱۵۴۵$$

۱. گرادیان‌های لایه دوم:

$$\frac{\partial \mathcal{L}}{\partial W^{(۲)}} = \delta^{(۲)} \cdot h^T = -۰/۱۵۴۵ \times \begin{bmatrix} ۳ & ۱ \end{bmatrix} = \begin{bmatrix} -۰/۴۶۳۵ & -۰/۱۵۴۵ \end{bmatrix}$$

$$\frac{\partial \mathcal{L}}{\partial b^{(۲)}} = \delta^{(۲)} = -۰/۱۵۴۵$$

۲. انتقال خطا به لایه مخفی: ابتدا خطای لایه مخفی ($\delta^{(۱)}$) را محاسبه می‌کنیم. مشتق ReLU برای مقادیر مثبت برابر ۱ است.

$$\delta^{(۱)} = (W^{(۲)})^T \delta^{(۲)} \odot \sigma'(a^{(۱)}) = \begin{bmatrix} ۱ \\ -۱/۵ \end{bmatrix} (-۰/۱۵۴۵) \odot \begin{bmatrix} ۱ \\ ۱ \end{bmatrix} = \begin{bmatrix} -۰/۱۵۴۵ \\ ۰/۲۳۱۷۵ \end{bmatrix}$$

۳. گرادیان‌های لایه اول:

$$\frac{\partial \mathcal{L}}{\partial W^{(۱)}} = \delta^{(۱)} x^T = \begin{bmatrix} -۰/۱۵۴۵ \\ ۰/۲۳۱۷۵ \end{bmatrix} \begin{bmatrix} ۲ & -۱ \end{bmatrix} = \begin{bmatrix} -۰/۳۰۹۰ & ۰/۱۵۴۵ \\ ۰/۴۶۳۵ & -۰/۲۳۱۷۵ \end{bmatrix}$$

$$\frac{\partial \mathcal{L}}{\partial b^{(۱)}} = \delta^{(۱)} = \begin{bmatrix} -۰/۱۵۴۵ \\ ۰/۲۳۱۷۵ \end{bmatrix}$$

پ. (۱) فرمول کلی تعداد پارامترها (مجموع وزن‌ها و بایاس‌ها): فرض کنیم n ورودی، k نورون مخفی و m خروجی داریم.

- لایه مخفی: $n \times k$ وزن + k بایاس.
- لایه خروجی: $k \times m$ وزن + m بایاس.

$$\text{Total Params} = (n \times k + k) + (k \times m + m) = (n + ۱)k + (k + ۱)m$$

(۲) محاسبه برای شبکه این سوال ($n = ۲, k = ۲, m = ۱$):

$$\text{Total} = (۲ \times ۲ + ۲) + (۲ \times ۱ + ۱) = ۶ + ۳ = ۹$$

تعداد کل پارامترهای قابل آموزش برابر ۹ است.

ت. افزودن یک لایه مخفی جدید باعث افزایش **ظرفیت (Capacity)** یا پیچیدگی مدل می‌شود. این کار به شبکه اجازه می‌دهد تا توابع پیچیده‌تر و غیرخطی‌تری را تقریب بزند (افزایش مرزهای تصمیم‌گیری غیرخطی).

چرا احتمال بیش‌برازش (Overfitting) زیاد می‌شود؟ با افزایش تعداد لایه‌ها و پارامترها، مدل انعطاف‌پذیری بیشتری پیدا می‌کند. اگر داده‌های آموزشی محدود باشند یا نویز داشته باشند، مدل به جای یادگیری الگوهای کلی حاکم بر داده‌ها، شروع به حفظ کردن جزئیات نویز و داده‌های خاص آموزشی می‌کند. این امر باعث می‌شود خطای آموزش بسیار کم شود اما خطای تست (روی داده‌های جدید) افزایش یابد.

۳. (۲۵ نمره) تابع سافت‌مکس (Softmax) این خاصیت مطلوب را دارد که یک توزیع احتمال خروجی می‌دهد و اغلب به عنوان تابع فعال‌سازی در بسیاری از شبکه‌های دسته‌بندی چندکلاسه استفاده می‌شود. یک شبکه عصبی ۲ـلایه برای دسته‌بندی Kـکلاسه، با استفاده از فعال‌سازی سافت‌مکس و تابع هزینه Cross-Entropy مطابق تعریف زیر در نظر بگیرید:

$$\begin{aligned} z^{[1]} &= W^{[1]}x + b^{[1]} \\ a^{[1]} &= \text{LeakyReLU}(z^{[1]}, \alpha = 0/01) \\ z^{[2]} &= W^{[2]}a^{[1]} + b^{[2]} \\ \bar{y} &= \text{softmax}(z^{[2]}) \\ L &= -\sum_{i=1}^{K} y_i \log(\bar{y}_i) \end{aligned}$$

که در آن مدل ورودی x به شکل $D_x \times 1$ و برچسب One-hot ($y \in \{0,1\}^K$) را می‌گیرد. فرض کنید لایه پنهان دارای D_a گره است، یعنی $z^{[1]}$ یک بردار با اندازه $D_a \times 1$ است. به یاد بیاورید که تابع سافت‌مکس به صورت زیر محاسبه می‌شود:

$$\hat{y} = \begin{bmatrix} \exp(z_1^{[2]})/Z \\ \vdots \\ \exp(z_K^{[2]})/Z \end{bmatrix}, \quad Z = \sum_{j=1}^{K} \exp(z_j^{[2]})$$

آ. شکل (ابعاد) $W^{[2]}$ و $b^{[2]}$ چیست؟ اگر بر روی m مثال برداری‌سازی می‌کردیم، یعنی از یک دسته[8] نمونه $X \in \mathbb{R}^{D_x \times m}$ به عنوان ورودی استفاده می‌کردیم، شکل خروجی لایه پنهان چه می‌بود؟

ب. مشتق $\frac{\partial \hat{y}_k}{\partial z_k^{[2]}}$ چیست؟ پاسخ خود را بر حسب مؤلفه(های) $\hat{y}$ ساده کنید.

پ. به ازای $i \neq k$، مشتق $\frac{\partial \hat{y}_k}{\partial z_i^{[2]}}$ چیست؟ پاسخ خود را بر حسب مؤلفه(های) $\hat{y}$ ساده کنید.

ت. فرض کنید برچسب y درایه kـام خود مقدار ۱ و در سایر درایه‌ها مقدار ۰ دارد. $\frac{\partial L}{\partial z_i^{[2]}}$ چیست؟ پاسخ خود را بر حسب $\hat{y}_i$ ساده کنید. نکته: هر دو حالت $i = k$ و $i \neq k$ را در نظر بگیرید.

ث. مشتق $\frac{\partial z^{[2]}}{\partial a^{[1]}}$ چیست؟ این نتیجه را با نماد δ_1 نشان دهید.

ج. مشتق $\frac{\partial a^{[1]}}{\partial z^{[1]}}$ چیست؟ این نتیجه را با نماد δ_2 نشان دهید. می‌توانید از نماد آکولاد (تابع چندضابطه‌ای) استفاده کنید.

چ. مشتق $\frac{\partial L}{\partial z^{[2]}}$ را با δ. نشان دهید. $\frac{\partial L}{\partial b^{[1]}}$ و $\frac{\partial L}{\partial W^{[1]}}$ چیست؟ می‌توانید از نمادهای بخش‌های قبلی استفاده مجدد کنید. نکته: به اشکال (ابعاد) دقت کنید.

ح. برای جلوگیری از مشکلات پایداری عددی، می‌توان از یک ترفند هنگام پیاده‌سازی تابع سافت‌مکس استفاده کرد. فرض کنید $m = \max_{j=1}^{K} z_j^{[2]}$ حداکثر مقادیر $z_i^{[2]}$ باشد، سپس $\hat{y}_i$ به صورت زیر محاسبه می‌شود:

$$\hat{y}_i = \frac{\exp(z_i^{[2]} - m)}{\sum_{j=1}^{K} \exp(z_j^{[2]} - m)}.$$

مشکل عددی در محاسبه اولیه سافت‌مکس چیست؟ چرا فرمول تغییر یافته به حل آن مشکل کمک می‌کند؟

خ. آیا اصلاح انتقال‌ـحداکثر (max-shift) در بخش آخر، مشتق نسبت به $z^{[2]}$ را تغییر می‌دهد؟

[8] Batch

حل.

آ. شکل پارامترها: $\mathbf{W}^{[۲]} \in \mathbb{R}^{K\times D_a}$، $\mathbf{b}^{[۲]} \in \mathbb{R}^{K\times ۱}$. **خروجی پنهان برداری‌شده:** برای یک دسته $\mathbf{X} \in \mathbb{R}^{D_x\times m}$، داریم:

$$\mathbf{z}^{[۱]} = \mathbf{W}^{[۱]}\mathbf{X} + \mathbf{b}^{[۱]}\mathbf{۱}^\top \in \mathbb{R}^{D_a\times m}, \quad \mathbf{a}^{[۱]} = \mathrm{LeakyReLU}(\mathbf{z}^{[۱]}) \in \mathbb{R}^{D_a\times m}.$$

بنابراین شکل خروجی لایه پنهان $D_a \times m$ است.

ب. با استفاده از $\hat{y}_k = \exp(z_k^{[۲]})/Z$ و $Z = \sum_j \exp(z_j^{[۲]})$،

$$\frac{\partial \hat{y}_k}{\partial z_k^{[۲]}} = \hat{y}_k(۱ - \hat{y}_k).$$

پ. به ازای $i \neq k$،

$$\frac{\partial \hat{y}_k}{\partial z_i^{[۲]}} = -\hat{y}_k\hat{y}_i.$$

ت. ژاکوبین سافت‌مکس $J_{ki} = \frac{\partial \hat{y}_k}{\partial z_i^{[۲]}} = \hat{y}_k(\delta_{ki} - \hat{y}_i)$ است. با $L = -\sum_k y_k \log \hat{y}_k$، داریم:

$$\frac{\partial L}{\partial \hat{y}_k} = -\frac{y_k}{\hat{y}_k}.$$

بر اساس قاعده زنجیره‌ای،

$$\frac{\partial L}{\partial z_i^{[۲]}} = \sum_{k=۱}^{K} \frac{\partial L}{\partial \hat{y}_k}\frac{\partial \hat{y}_k}{\partial z_i^{[۲]}} = \sum_{k=۱}^{K}\left(-\frac{y_k}{\hat{y}_k}\right)\hat{y}_k(\delta_{ki}-\hat{y}_i) = \sum_{k=۱}^{K} -y_k\delta_{ki} + \sum_{k=۱}^{K} y_k\hat{y}_i = -y_i + \hat{y}_i.$$

بنابراین،

$$\frac{\partial L}{\partial z_i^{[۲]}} = \hat{y}_i - y_i.$$

به طور مشخص: اگر $i = k$ باشد، $\frac{\partial L}{\partial z_k^{[۲]}} = \hat{y}_k - ۱$؛ اگر $i \neq k$ باشد، $\frac{\partial L}{\partial z_i^{[۲]}} = \hat{y}_i$. بردار $\delta_۰$ را به صورت $\delta_۰ \equiv \frac{\partial L}{\partial \mathbf{z}^{[۲]}} = \hat{\mathbf{y}} - \mathbf{y} \in \mathbb{R}^{K\times ۱}$ تعریف می‌کنیم.

ث. از آنجایی که $\mathbf{z}^{[۲]} = \mathbf{W}^{[۲]}\mathbf{a}^{[۱]} + \mathbf{b}^{[۲]}$ نسبت به $\mathbf{a}^{[۱]}$ آفین (affine) است،

$$\delta_۱ \equiv \frac{\partial \mathbf{z}^{[۲]}}{\partial \mathbf{a}^{[۱]}} = \mathbf{W}^{[۲]}.$$

ج. برای LeakyReLU با شیب $\alpha = ۰/۰۱$ برای مقادیر منفی،

$$\delta_۲ \equiv \frac{\partial \mathbf{a}^{[۱]}}{\partial \mathbf{z}^{[۱]}} = \begin{cases} ۱, & z_i^{[۱]} \geq ۰, \\ ۰/۰۱, & z_i^{[۱]} < ۰, \end{cases}$$

اعمال می‌شود (به صورت جزء به جزء بر روی $i = ۱, \ldots, D_a$).

در قالب برداری، $\frac{\partial L}{\partial \mathbf{z}^{[۱]}} = \left(\frac{\partial L}{\partial \mathbf{a}^{[۱]}}\right) \odot \delta_۲$، که در آن $\odot$ نشان‌دهنده ضرب جزء به جزء است.

چ. تک مثال (بردارهای ستونی): فرض کنید $\delta_۰ = \hat{\mathbf{y}} - \mathbf{y} \in \mathbb{R}^{K\times ۱}$. پس‌انتشار (Backpropagate):

$$\frac{\partial L}{\partial \mathbf{a}^{[۱]}} = (\mathbf{W}^{[۲]})^\top \delta_۰ \in \mathbb{R}^{D_a\times ۱}, \qquad \frac{\partial L}{\partial \mathbf{z}^{[۱]}} = \big((\mathbf{W}^{[۲]})^\top \delta_۰\big) \odot \delta_۲ \in \mathbb{R}^{D_a\times ۱}.$$

سپس

$$\frac{\partial L}{\partial \mathbf{W}^{[۱]}} = \left(\frac{\partial L}{\partial \mathbf{z}^{[۱]}}\right) \mathbf{x}^\top \in \mathbb{R}^{D_a\times D_x}, \qquad \frac{\partial L}{\partial \mathbf{b}^{[۱]}} = \frac{\partial L}{\partial \mathbf{z}^{[۱]}} \in \mathbb{R}^{D_a\times ۱}.$$

برداری‌شده بر روی یک دسته m مثال: ستون‌ها را بر اساس هر مثال روی هم قرار دهید:

$$\delta_۰ = \hat{\mathbf{y}} - \mathbf{y} \in \mathbb{R}^{K\times m}, \quad \frac{\partial L}{\partial \mathbf{a}^{[۱]}} = (\mathbf{W}^{[۲]})^\top \delta_۰ \in \mathbb{R}^{D_a\times m}, \quad \frac{\partial L}{\partial \mathbf{z}^{[۱]}} = \big((\mathbf{W}^{[۲]})^\top \delta_۰\big) \odot \delta_۲ \in \mathbb{R}^{D_a\times m}.$$

با $\mathbf{X} \in \mathbb{R}^{D_x\times m}$،

$$\frac{\partial L}{\partial \mathbf{W}^{[۱]}} = \left(\frac{\partial L}{\partial \mathbf{z}^{[۱]}}\right) \mathbf{X}^\top \in \mathbb{R}^{D_a\times D_x}, \qquad \frac{\partial L}{\partial \mathbf{b}^{[۱]}} = \left(\frac{\partial L}{\partial \mathbf{z}^{[۱]}}\right) \mathbf{۱} \in \mathbb{R}^{D_a\times ۱},$$

که در آن $\mathbf{۱} \in \mathbb{R}^{m\times ۱}$ است و گرادیان بایاس (bias) بر روی دسته جمع می‌شود زیرا بایاس‌ها در بین مثال‌ها پخش (broadcast) می‌شوند.

ح. مشکل: توان‌دهی (Exponentiating) به لاجیت‌های (logits) بزرگ $z_i^{[۲]}$ می‌تواند منجر به سرریز (overflow) (به $+\infty$) شود، در حالی که لاجیت‌های بسیار منفی می‌توانند منجر به زیرریز (under-flow) (به ۰) شوند. این می‌تواند مقادیر $\hat{y}_i$ را تولید کند که از نظر عددی ۰ یا NaN هستند و باعث می‌شود $\log(\hat{y}_i)$ تعریف‌نشده شود. **راه حل از طریق انتقال‌ـحداکثر (max-shift) :** کم کردن $m = \max_j z_j^{[۲]}$ سافت‌مکس را دقیقاً حفظ می‌کند (نسبت‌ها تغییر نمی‌کنند)، در حالی که تضمین می‌کند بزرگترین توان $\exp(۰) = ۱$ است (بدون سرریز) و همه توان‌ها در $(۰, ۱]$ قرار می‌گیرند (زیرریز را کاهش می‌دهد). بنابراین مخرج در مقیاس مناسب باقی می‌ماند و $\hat{y}$ بدون تغییر نتیجه ریاضی، از نظر عددی پایدار می‌ماند.

خ. پاسخ کوتاه: خیر. حتی با وجود اینکه $m = \max_j z_j^{[۲]}$ به $\mathbf{z}^{[۲]}$ بستگی دارد، گرادیان نسبت به لاجیت‌ها همان $\frac{\partial L}{\partial \mathbf{z}^{[۲]}} = \hat{\mathbf{y}} - \mathbf{y}$ باقی می‌ماند.

استخراج: $\mathbf{s} = \mathbf{z} - m\,\mathbf{۱}$ را با $m = \max_j z_j$ تعریف کنید. سپس $\mathrm{softmax}(\mathbf{s}) = \mathrm{softmax}(\mathbf{z})$، بنابراین

$$\frac{\partial L}{\partial \mathbf{s}} = \hat{\mathbf{y}} - \mathbf{y} \quad \text{و} \quad \frac{\partial \mathbf{s}}{\partial \mathbf{z}} = \mathbf{I} - \mathbf{۱}\, g^\top,$$

که در آن $g \in \partial m(\mathbf{z})$ یک زیرگرادیان (subgradient) ماکسیمم است: اگر ماکسیمم‌کننده در اندیس k منحصر به فرد باشد، $g = \mathbf{e}_k$؛ اگر تساوی وجود داشته باشد، g هر ترکیب محدب (convex combination) از بردارهای واحد متناظر است. بر اساس قاعده زنجیره‌ای،

$$\frac{\partial L}{\partial \mathbf{z}} = \big(\mathbf{I} - \mathbf{۱}\, g^\top\big)^\top \frac{\partial L}{\partial \mathbf{s}} = \frac{\partial L}{\partial \mathbf{s}} - g\,\big(\mathbf{۱}^\top \frac{\partial L}{\partial \mathbf{s}}\big).$$

برای کراس‌ـانتروپی با سافت‌مکس، $\mathbf{۱}^\top \frac{\partial L}{\partial \mathbf{s}} = \sum_i (\hat{y}_i - y_i) = ۱ - ۱ = ۰$، از این رو

$$\frac{\partial L}{\partial \mathbf{z}} = \frac{\partial L}{\partial \mathbf{s}} = \hat{\mathbf{y}} - \mathbf{y}.$$

بنابراین انتقال‌ـحداکثر گرادیان را تغییر نمی‌دهد، علی‌رغم اینکه m تابعی (غیر هموار) از $\mathbf{z}$ است.

۴. (۱۲ نمره) یک شبکه عصبی برای پیاده‌سازی تابع XOR برای چهار ورودی دودویی $x_۱, x_۲, x_۳, x_۴ \in \{۰, ۱\}$ طراحی شده است. این شبکه از توابع فعال‌سازی زیر استفاده می‌کند:

$$\mathrm{ReLU}(z) = \max(۰, z) \quad , \quad \sigma(z) = \frac{۱}{۱ + e^{-z}}$$

خروجی به عنوان ۱ در نظر گرفته می‌شود اگر $y > ۰/۵$ و در غیر این صورت ۰ است. تابع هزینه، خطای مربع است:

$$L(x) = (y_{\text{هدف}} - y)^۲.$$

ساختار شبکه

$$\begin{aligned}
h_۱ &= \mathrm{ReLU}(x_۱ + x_۲),\\
h_۲ &= \mathrm{ReLU}(x_۱ + x_۲ - ۱),\\
h_۳ &= \mathrm{ReLU}(x_۳ + x_۴),\\
h_۴ &= \mathrm{ReLU}(۰/۷x_۳ + x_۴ - ۱).\\
s_۱ &= h_۱ - ۲h_۲,\\
s_۲ &= h_۳ - ۲h_۴.\\
h_۵ &= \mathrm{ReLU}(s_۱ + s_۲),\\
h_۶ &= \mathrm{ReLU}(s_۱ + s_۲ - ۱).\\
y &= \sigma(۲h_۵ - ۴h_۶ - ۱).
\end{aligned}$$

نمودار شبکه

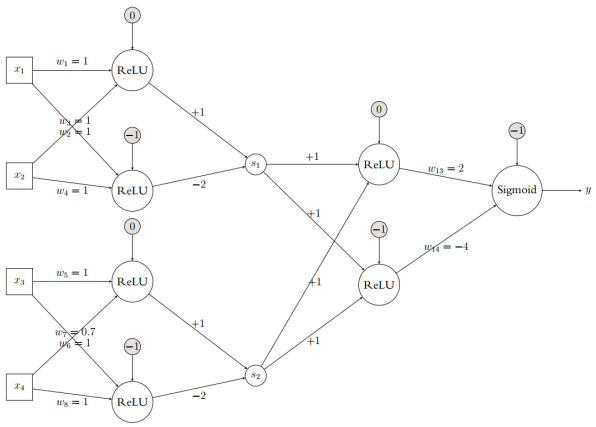

شکل ۱: نمودار شبکه عصبی مورد استفاده در سوال

آ. تمام بردارهای ورودی $x = (x_۱, x_۲, x_۳, x_۴)$ که در آن مدل پیش‌بینی نادرست انجام می‌دهد (یعنی $y_{\text{مدل}} \neq y_{\text{هدف}}$) را شناسایی کنید.

ب. یک گام SGD روی وزن $w_۷ = ۰/۷$ با استفاده از بردار ورودی $(x_۱, x_۲, x_۳, x_۴) = (۰, ۰, ۱, ۱)$ انجام دهید. نرخ یادگیری $\eta = ۰/۱$ را فرض کنید. مقدار جدید $w_۷$ را تعیین کنید.

حل.

الف. برای $(x_۱, x_۲)$ داریم:

$$h_۱ = \text{ReLU}(x_۱+x_۲), \quad h_۲ = \text{ReLU}(x_۱+x_۲-۱) \Rightarrow s_۱ = h_۱-۲h_۲ = \begin{cases} ۱, & x_۱ \oplus x_۲ = ۱, \\ ۰, & x_۱ \oplus x_۲ = ۰, \end{cases}$$

پس $s_۱$ عملگر XOR روی $(x_۱, x_۲)$ را پیاده‌سازی می‌کند. برای $(x_۳, x_۴)$:

$$h_۳ = \text{ReLU}(x_۳ + x_۴), \quad h_۴ = \text{ReLU}(۰/۷x_۳ + x_۴ - ۱),$$

که نتیجه می‌دهد:

$$s_۲ = h_۳ - ۲h_۴ = \begin{cases} ۰, & (x_۳, x_۴) = (۰, ۰), \\ ۱, & (x_۳, x_۴) \in \{(۱, ۰), (۰, ۱)\}, \\ ۰/۶, & (x_۳, x_۴) = (۱, ۱). \end{cases}$$

فرض کنید $t = s_۱ + s_۲$. آنگاه:

$$h_۵ = t, \quad h_۶ = \text{ReLU}(t - ۱), \quad z = ۲h_۵ - ۴h_۶ - ۱ = \begin{cases} ۲t - ۱, & t < ۱, \\ -۲t + ۳, & t \geq ۱, \end{cases}$$

و پیش‌بینی $y = ۱$ است اگر $z > ۰$. با بررسی مقادیر ممکن $t \in \{۰, ۰/۶, ۱, ۱/۶, ۲\}$:

$$\begin{aligned} t = ۰ &\Rightarrow z = -۱ \Rightarrow \hat{y} = ۰, \\ t = ۰/۶ &\Rightarrow z = ۰/۲ \Rightarrow \hat{y} = ۱, \\ t = ۱ &\Rightarrow z = ۱ \Rightarrow \hat{y} = ۱, \\ t = ۱/۶ &\Rightarrow z = -۰/۲ \Rightarrow \hat{y} = ۰, \\ t = ۲ &\Rightarrow z = -۱ \Rightarrow \hat{y} = ۰. \end{aligned}$$

XOR واقعی روی چهار بیت برابر با تابع زوج‌ـفرد (پاریته) تعداد کل یک‌ها است. وقتی $(x_۳, x_۴) = (۱, ۱)$ (پاریته زوج روی این جفت)، مدل $s_۲ = ۰/۶$ به جای ۰ تولید می‌کند که منجر به:

$$t = \begin{cases} ۰/۶ & \text{if} s_۱ = ۰, \\ ۱/۶ & \text{if} s_۱ = ۱, \end{cases}$$

و در نتیجه $\hat{y} = ۱$ (برای $t = ۰/۶$) یا $\hat{y} = ۰$ (برای $t = ۱/۶$) می‌شود که هر دو مخالف هدف واقعی هستند. بنابراین تمام ورودی‌های با $(x_۳, x_۴) = (۱, ۱)$ به اشتباه طبقه‌بندی می‌شوند:

$$(۰, ۰, ۱, ۱), \ (۱, ۱, ۱, ۱), \ (۱, ۰, ۱, ۱), \ (۰, ۱, ۱, ۱).$$

ب. ورودی نادرست $(x_۱, x_۲, x_۳, x_۴) = (۰, ۰, ۱, ۱)$ را انتخاب می‌کنیم. مقادیر forward :

$$\begin{aligned} &h_۱ = ۰, \ h_۲ = ۰ \Rightarrow s_۱ = ۰, \\ &h_۳ = ۲, \ h_۴ = \text{ReLU}(۰/۷ \cdot ۱ + ۱ - ۱) = ۰/۷ \Rightarrow s_۲ = ۲ - ۲(۰/۷) = ۰/۶, \\ &t = s_۱ + s_۲ = ۰/۶, \quad h_۵ = ۰/۶, \ h_۶ = ۰, \ z = ۲(۰/۶) - ۱ = ۰/۲, \\ &y = \sigma(۰/۲) = \frac{۱}{۱ + e^{-۰/۲}} \approx ۰/۵۴۹۸۳۴, \quad y_{\text{هدف}} = ۰. \end{aligned}$$

گرادیان (قاعده زنجیره‌ای):

$$\frac{dL}{dw} = \frac{dL}{dy}\,\frac{dy}{dz}\,\frac{dz}{dt}\,\frac{dt}{ds_۲}\,\frac{ds_۲}{dh_۴}\,\frac{dh_۴}{dw}.$$

برای $t = ۰/۶ < ۱$، $z = ۲t - ۱ \Rightarrow \frac{dz}{dt} = ۲$. همچنین $s_۲ = h_۳ - ۲h_۴ \Rightarrow \frac{ds_۲}{dh_۴} = -۲$.
از آنجا که $a_۴ = wx_۳ + x_۴ - ۱ = w$ و $a_۴ > ۰$، $\mathrm{ReLU}'(a_۴) = ۱ \Rightarrow \frac{dh_۴}{dw} = x_۳ = ۱$. با $L = (y_{\text{هدف}} - y)^۲$ و $y_{\text{هدف}} = ۰$:

$$\frac{dL}{dy} = -۲(y_{\text{هدف}} - y) = ۲y, \qquad \frac{dy}{dz} = y(۱ - y).$$

در نتیجه:

$$\frac{dL}{dw} = (۲y)\,(y(۱ - y))\,(۲)\,(۱)\,(-۲)\,(۱) = -۸\,y^۲(۱ - y).$$

به‌روزرسانی SGD با $\eta = ۰/۱$:

$$w_{\text{جدید}} = w - \eta\,\frac{dL}{dw} = ۰/۷ - ۰/۱\big(-۸\,y^۲(۱ - y)\big) = ۰/۷ + ۰/۸\,y^۲(۱ - y).$$

عددی، $y \approx ۰/۵۴۹۸۳۴ \Rightarrow y^۲(۱ - y) \approx ۰/۱۳۶۵۴۷$، بنابراین:

$$w_{\text{جدید}} \approx ۰/۷ + ۰/۸ \cdot ۰/۱۳۶۵۴۷ \approx ۰/۸۰۹۲۳۸.$$

۵. (۲۰ نمره) ماتریس طراحی $\mathbf{X}$ (که سطر iـام آن نقطه نمونه $\mathbf{x}_i^T$ است) و یک بردار nـتایی از برچسب‌ها $\mathbf{y} = [y_1, \ldots, y_n]^T$ به شما داده شده است. برای سادگی، فرض کنید $\mathbf{X}$ سفید (whitened) شده است، به طوری که $\mathbf{X}^T\mathbf{X} = n\mathbf{I}$. جمله بایاس یا بعد اضافی اضافه نکنید؛ برای ورودی صفر، خروجی همیشه صفر است. فرض کنید $\mathbf{x}_{*i}$ ستون iـام ماتریس $\mathbf{X}$ را نشان می‌دهد.

آ. نشان دهید که تابع هزینه برای کمترین مربعات با تنظیم‌گر ℓ_1، (Lasso) یعنی:

$$J_1(\mathbf{w}) \triangleq \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2 + \lambda\|\mathbf{w}\|_1 \quad (\text{که در آن } \lambda > 0)$$

می‌تواند به صورت زیر بازنویسی شود:

$$J_1(\mathbf{w}) = \|\mathbf{y}\|^2 + \sum_{i=1}^{d} f(\mathbf{x}_{*i}, w_i)$$

که در آن $f(\cdot,\cdot)$ یک تابع مناسب است که آرگومان اول آن یک بردار و آرگومان دوم آن یک اسکالر است.

ب. با استفاده از پاسخ خود به بخش (آ)، شرایط لازم و کافی برای مولفه iـام بهینه‌ساز $\mathbf{w}^*$ تابع $J_1(\cdot)$ را استخراج کنید به طوری که هر یک از سه خاصیت زیر را برآورده کند: $w_i^* > 0$، $w_i^* = 0$ و $w_i^* < 0$.

پ. برای بهینه‌ساز $\mathbf{w}^\#$ تابع هزینه کمترین مربعات با تنظیم‌گر ℓ_2، (Ridge) یعنی:

$$J_2(\mathbf{w}) \triangleq \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2 + \lambda\|\mathbf{w}\|_2^2 \quad (\text{که در آن } \lambda > 0)$$

یک شرط لازم و کافی برای $w_i^\# = 0$ استخراج کنید، که در آن $w_i^\#$ مولفه iـام بردار $\mathbf{w}^\#$ است.

ت. یک بردار را تُنُک[9] می‌نامیم اگر بیشتر مولفه‌های آن صفر باشند. بر اساس پاسخ‌های خود به بخش‌های (ب) و (پ)، کدام یک از بردارهای $\mathbf{w}^*$ و $\mathbf{w}^\#$ به احتمال زیاد تُنُک‌تر است؟ چرا؟

حل.

آ. بازنویسی تابع هزینه Lasso ابتدا عبارت مربع خطا را بسط می‌دهیم:

$$\|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2 = (\mathbf{X}\mathbf{w} - \mathbf{y})^T(\mathbf{X}\mathbf{w} - \mathbf{y}) = \mathbf{w}^T\mathbf{X}^T\mathbf{X}\mathbf{w} - 2\mathbf{y}^T\mathbf{X}\mathbf{w} + \mathbf{y}^T\mathbf{y}$$

با توجه به فرض سفید بودن داده‌ها ($\mathbf{X}^T\mathbf{X} = n\mathbf{I}$)، جمله اول به شکل زیر ساده می‌شود:

$$\mathbf{w}^T(n\mathbf{I})\mathbf{w} = n\mathbf{w}^T\mathbf{w} = n\sum_{i=1}^{d} w_i^2$$

جمله دوم ضرب داخلی است که می‌تواند به صورت مجموع مولفه‌ای نوشته شود (دقت کنید که $\mathbf{X}\mathbf{w} = \sum_{i=1}^{d} w_i\mathbf{x}_{*i}$):

$$2\mathbf{y}^T\mathbf{X}\mathbf{w} = 2\mathbf{y}^T(\sum_{i=1}^{d} w_i\mathbf{x}_{*i}) = 2\sum_{i=1}^{d} w_i(\mathbf{y}^T\mathbf{x}_{*i}) = 2\sum_{i=1}^{d} w_i(\mathbf{x}_{*i}^T\mathbf{y})$$

ترم تنظیم‌گر نیز برابر است با $\lambda\|\mathbf{w}\|_1 = \sum_{i=1}^{d} \lambda|w_i|$.

[9] sparse

با جایگذاری این موارد در تابع هزینه اصلی $J_1(\mathbf{w})$:

$$J_1(\mathbf{w}) = \|\mathbf{y}\|^2 + \sum_{i=1}^{d} \left(nw_i^2 - 2w_i(\mathbf{x}_{*i}^T\mathbf{y}) + \lambda|w_i|\right)$$

بنابراین تابع به فرم خواسته شده در می‌آید که در آن:

$$f(\mathbf{x}_{*i}, w_i) = nw_i^2 - 2(\mathbf{x}_{*i}^T\mathbf{y})w_i + \lambda|w_i|$$

(نکته مهم این است که به دلیل قطری بودن ماتریس کواریانس، متغیرهای w_i از هم جدا شده‌اند و می‌توانیم هر کدام را جداگانه بهینه کنیم).

ب. شرایط بهینگی برای Lasso ($\mathbf{w}^*$) برای به دست آوردن w_i^*، باید عبارت $f(\mathbf{x}_{*i}, w_i)$ را نسبت به w_i کمینه کنیم. فرض کنیم $c_i = \mathbf{x}_{*i}^T\mathbf{y}$ (میزان همبستگی ویژگی i با برچسب). گرادیان (یا زیرـ گرادیان) عبارت نسبت به w_i برابر است با:

$$\partial_{w_i} f = 2nw_i - 2c_i + \lambda \cdot \text{sign}(w_i)$$

حالات مختلف را بررسی می‌کنیم:

- **شرط $w_i^* > 0$:** در این حالت $\text{sign}(w_i) = 1$. مشتق باید صفر شود:

$$2nw_i^* - 2c_i + \lambda = 0 \implies w_i^* = \frac{2c_i - \lambda}{2n}$$

برای اینکه این مقدار مثبت باشد، باید صورت کسر مثبت باشد:

$$2c_i - \lambda > 0 \implies \mathbf{x}_{*i}^T\mathbf{y} > \frac{\lambda}{2}$$

- **شرط $w_i^* < 0$:** در این حالت $\text{sign}(w_i) = -1$. مشتق باید صفر شود:

$$2nw_i^* - 2c_i - \lambda = 0 \implies w_i^* = \frac{2c_i + \lambda}{2n}$$

برای اینکه این مقدار منفی باشد، باید:

$$2c_i + \lambda < 0 \implies \mathbf{x}_{*i}^T\mathbf{y} < -\frac{\lambda}{2}$$

- **شرط $w_i^* = 0$:** در این حالت صفر باید عضوی از زیرـ دیفرانسیل باشد. زیرـ دیفرانسیل $|w_i|$ در نقطه صفر بازه $[-1, 1]$ است، پس زیرـ دیفرانسیل تابع هزینه در صفر بازه $[-2c_i - \lambda, -2c_i + \lambda]$ است. شرط بهینگی ($0 \in \partial f$) ایجاب می‌کند:

$$-2c_i - \lambda \leq 0 \leq -2c_i + \lambda$$

$$-\lambda \leq 2c_i \leq \lambda \implies \left|\mathbf{x}_{*i}^T\mathbf{y}\right| \leq \frac{\lambda}{2}$$

پ. شرایط صفر شدن در Ridge ($\mathbf{w}^\#$) تابع هزینه Ridge به صورت زیر است (با همان بسط قسمت اول، اما با نرم L_2):

$$J_2(\mathbf{w}) = \|\mathbf{y}\|^2 + \sum_{i=1}^{d} \left(nw_i^2 - 2w_ic_i + \lambda w_i^2\right)$$

$$J_۲(\mathbf{w}) = \|\mathbf{y}\|^۲ + \sum_{i=۱}^{d} \left((n+\lambda)w_i^۲ - ۲c_i w_i\right)$$

مشتق را برابر صفر قرار می‌دهیم:

$$۲(n+\lambda)w_i^{\#} - ۲c_i = ۰ \implies w_i^{\#} = \frac{c_i}{n+\lambda} = \frac{\mathbf{x}_{*i}^T\mathbf{y}}{n+\lambda}$$

بنابراین شرط لازم و کافی برای اینکه $w_i^{\#} = ۰$ باشد، این است که صورت کسر صفر شود:

$$\mathbf{x}_{*i}^T\mathbf{y} = ۰$$

ت. مقایسه تُنُکی (Sparsity) بردار $\mathbf{w}^*$ (مربوط به Lasso) به احتمال بسیار زیاد تُنُک‌تر است.

دلیل: با توجه به نتایج بخش‌های (ب) و (پ):

- در مدل **Ridge**، وزن $w_i^{\#}$ فقط و فقط زمانی صفر می‌شود که $\mathbf{x}_{*i}^T\mathbf{y} = ۰$ باشد. در فضای پیوسته، احتمال اینکه همبستگی یک ویژگی با خروجی دقیقاً برابر با صفر باشد، بسیار ناچیز است (مجموعه‌ای با اندازه صفر).
- در مدل **Lasso**، وزن w_i^* زمانی صفر می‌شود که مقدار همبستگی $\mathbf{x}_{*i}^T\mathbf{y}$ در بازه $\left[-\frac{\lambda}{۲}, \frac{\lambda}{۲}\right]$ قرار گیرد. این یک بازه با طول غیرصفر است. اگر همبستگی ویژگی با خروجی کم باشد (اما لزوماً صفر نباشد)، Lasso آن را به صفر «Soft Threshold» می‌کند.

بنابراین Lasso بسیاری از ویژگی‌های کم‌اهمیت یا نویزی را حذف کرده و منجر به مدل تنک (Sparse) می‌شود.

۶. (۱۰ نمره) تابع هزینه یک مدل $J(\theta)$ دارای حداقل‌های محلی است و می‌خواهیم از الگوریتم کاهش شیب تصادفی (SGD) برای بهینه‌سازی پارامترهای آن (θ) استفاده کنیم. فرض کنید از یک نرخ یادگیری با کاهش نمایی[۱۰] به شکل زیر استفاده می‌کنیم:

$$\alpha_t = \alpha_۰ e^{-kt}$$

که در آن t شماره گام (epoch) است. نرخ یادگیری اولیه $\alpha_۰ = ۰/۱$ و ضریب کاهش $k = ۰/۰۵$ داده شده است.

آ. قاعده به‌روزرسانی پارامترها (θ) را با استفاده از SGD بنویسید.

ب. به صورت مفهومی توضیح دهید که چرا استفاده از نرخ یادگیری متغیر با کاهش[۱۱] می‌تواند هم به سرعت همگرایی و هم به پایداری فرآیند آموزش کمک کند.

پ. اگر الگوریتم در یک ناحیه با شیب تند از تابع هزینه قرار گیرد، رفتار آن را با نرخ یادگیری ثابت در مقایسه با نرخ یادگیری دارای کاهش تحلیل و مقایسه کنید. این دو رویکرد چه تفاوتی در مسیر رسیدن به نقطه بهینه دارند؟

ت. یکی از شرایط کلاسیک برای تضمین همگرایی SGD (تحت فروض مشخص)، شرایط رابینز-مونرو[۱۲] برای نرخ یادگیری α_t است:

$$\sum_{t=۱}^{\infty} \alpha_t = \infty \quad \text{و} \quad \sum_{t=۱}^{\infty} \alpha_t^۲ < \infty$$

بررسی کنید که آیا نرخ یادگیری با کاهش نمایی ($\alpha_t = \alpha_۰ e^{-kt}$) در این شرایط صدق می‌کند یا خیر. برای تحلیل می‌توانید از تقریب انتگرال برای سری‌ها استفاده کنید. نتیجه‌ای که به دست می‌آورید چه مفهومی در مورد تضمین همگرایی این نوع نرخ یادگیری دارد؟

حل.

آ. قاعده به‌روزرسانی پارامترها در الگوریتم کاهش شیب تصادفی (SGD)، در هر تکرار t، یک نمونه داده تصادفی $(x^{(i)}, y^{(i)})$ انتخاب می‌شود. گرادیان تابع هزینه بر اساس آن نمونه محاسبه شده و پارامترها به‌روز می‌شوند. با جایگذاری فرمول نرخ یادگیری داده شده:

$$\alpha_t = ۰/۱ \times e^{-۰/۰۵t}$$

قاعده به‌روزرسانی برای پارامتر θ در گام $t+۱$ برابر است با:

$$\theta_{t+۱} = \theta_t - \alpha_t \nabla J_i(\theta_t)$$

$$\theta_{t+۱} = \theta_t - (۰/۱ e^{-۰/۰۵t}) \nabla J_i(\theta_t)$$

که در آن $\nabla J_i(\theta_t)$ گرادیان تابع هزینه محاسبه شده روی نمونه i-ام است.

ب. تحلیل مفهومی نرخ یادگیری کاهنده استفاده از نرخ یادگیری متغیر (Decaying Learning Rate) تعادلی بین «سرعت» و «دقت» ایجاد می‌کند:

- **سرعت همگرایی (در ابتدای آموزش):** در شروع کار، پارامترها معمولاً از نقطه بهینه دور هستند. نرخ یادگیری بزرگ ($\alpha_۰$) اجازه می‌دهد که الگوریتم گام‌های بلندی بردارد و به سرعت به ناحیه کلی حول نقطه مینیمم نزدیک شود. اگر نرخ یادگیری از ابتدا کوچک باشد، رسیدن به این ناحیه بسیار زمان‌بر خواهد بود.

[۱۰] exponential decay
[۱۱] decaying learning rate
[۱۲] Robbins-Monro conditions

- **پایداری و دقت (در انتهای آموزش):** با نزدیک شدن به نقطه مینیمم، گرادیان‌ها همچنان دارای نویز هستند (به دلیل ماهیت تصادفی SGD). اگر نرخ یادگیری همچنان بزرگ بماند، پارامترها حول نقطه مینیمم نوسان کرده و هرگز در آن آرام نمی‌گیرند (Over-shooting) . کاهش نرخ یادگیری باعث می‌شود نویز گرادیان میرا شده و الگوریتم بتواند با دقت بیشتری به عمق دره (نقطه بهینه دقیق) نفوذ کند و نوسانات کاهش یابد.

پ. رفتار در ناحیه با شیب تند فرض کنید الگوریتم در ناحیه‌ای قرار گرفته که مقدار گرادیان $\|\nabla J\|$ بسیار بزرگ است (دیواره‌های تند تابع هزینه).

- **با نرخ یادگیری ثابت:** گام به‌روزرسانی برابر با $\Delta\theta = -\alpha\nabla J$ است. اگر α ثابت باشد و گرادیان بزرگ، حاصل‌ضرب آنها منجر به یک تغییر مکان بسیار بزرگ می‌شود. این می‌تواند باعث شود الگوریتم به سمت دیگر دره پرتاب شود (Overshooting) یا حتی واگرا شود (Exploding Gradient Problem). نوسانات شدید مانع از همگرایی می‌شود.
- **با نرخ یادگیری کاهنده:** حتی اگر گرادیان بزرگ باشد، با گذشت زمان (افزایش t)، ضریب α_t بسیار کوچک می‌شود. این ضریب کوچک مانند یک ترمز عمل کرده و اثر بزرگی گرادیان را خنثی می‌کند. در نتیجه، گام‌های برداشته شده کنترل‌شده‌تر خواهند بود و خطر پرش‌های ناگهانی یا واگرایی در مراحل پایانی آموزش به شدت کاهش می‌یابد.

ت. بررسی شرایط رابینز-مونرو (Robbins-Monro) شرایط رابینز-مونرو برای تضمین همگرایی SGD به مینیمم سراسری (برای توابع محدب) عبارتند از:

(آ) $\sum_{t=1}^{\infty} \alpha_t = \infty$ (الگوریتم باید بتواند مسافت نامحدودی را طی کند تا اگر نقطه شروع خیلی دور بود، به هدف برسد).

(ب) $\sum_{t=1}^{\infty} \alpha_t^2 < \infty$ (واریانس گام‌ها باید محدود باشد تا نوسانات میرا شوند).

حال نرخ یادگیری $\alpha_t = \alpha_0 e^{-kt}$ را با فرض $k > 0$ بررسی می‌کنیم:

بررسی شرط اول:

$$\sum_{t=1}^{\infty} \alpha_0 e^{-kt} = \alpha_0 \sum_{t=1}^{\infty} (e^{-k})^t$$

این یک سری هندسی با قدر نسبت $r = e^{-k}$ است. چون $k > 0$، پس $0 < r < 1$. سری‌های هندسی با $|r| < 1$ همگرا هستند (حاصل‌جمع آنها متناهی است). همچنین با استفاده از آزمون انتگرال:

$$\int_1^{\infty} \alpha_0 e^{-kx} dx = \alpha_0 \left[\frac{-1}{k} e^{-kx}\right]_1^{\infty} = \alpha_0 (0 - (\frac{-1}{k} e^{-k})) = \frac{\alpha_0}{k e^k} < \infty$$

بنابراین $\sum \alpha_t < \infty$. **شرط اول برقرار نیست.**

بررسی شرط دوم:

$$\sum_{t=1}^{\infty} (\alpha_0 e^{-kt})^2 = \alpha_0^2 \sum_{t=1}^{\infty} e^{-2kt}$$

این نیز یک سری هندسی با قدر نسبت $r' = e^{-2k} < 1$ است و همگرا می‌شود (حاصل‌جمع متناهی است). **شرط دوم برقرار است.**

نتیجه‌گیری و مفهوم: نرخ یادگیری با کاهش نمایی در شرط اول رابینز-مونرو صدق نمی‌کند. این بدین معناست که از نظر تئوری، تضمینی برای همگرایی به نقطه بهینه وجود ندارد. چون مجموع گام‌ها متناهی است، اگر فاصله اولیه تا نقطه بهینه ($\|\theta_0 - \theta^*\|$) بیشتر از مجموع کل گام‌هایی باشد که الگوریتم می‌تواند بردارد، پارامترها قبل از رسیدن به مقصد متوقف می‌شوند.

با این حال، در عمل اگر α_0 به اندازه کافی بزرگ و k به اندازه کافی کوچک تنظیم شود، این روش عملکرد بسیار خوبی دارد، اما از نظر ریاضی محض، خاصیت "Global Convergence" را مثل نرخ یادگیری $\alpha_t = \frac{c}{t}$ ندارد.

۷. (۱۳ نمره) فرض کنید یک لایه نرمال‌سازی دسته‌ای[۱۳] یک‌بعدی روی یک Mini-batch با اندازه m اعمال می‌شود. ورودی‌های اسکالر برای یک نورون خاص را با $x_1, \ldots, x_m$ نمایش می‌دهیم. لایه BN آماره‌ها و خروجی‌ها را به صورت زیر محاسبه می‌کند:

$$\mu_B = \frac{1}{m}\sum_{i=1}^{m} x_i$$
$$\sigma_B^2 = \frac{1}{m}\sum_{i=1}^{m}(x_i - \mu_B)^2$$
$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}$$
$$y_i = \gamma \hat{x}_i + \beta$$

که در آن γ و β پارامترهای قابل یادگیری هستند و ϵ یک عدد کوچک ثابت برای پایداری عددی است. تابع هزینه L تابعی از خروجی‌های $y_1, \ldots, y_m$ است و گرادیان نسبت به خروجی‌ها $g_i := \frac{\partial L}{\partial y_i}$ می‌باشد.

آ. با استفاده از قاعده زنجیره‌ای، فرمول بسته‌ای برای گرادیان‌های $\frac{\partial L}{\partial \gamma}$ و $\frac{\partial L}{\partial \beta}$ بر حسب g_i و $\hat{x}_i$ به دست آورید.

ب. گرادیان $\frac{\partial L}{\partial x_i}$ را برای هر i محاسبه کنید. توجه داشته باشید که μ_B و σ_B^2 توابعی از تمام x_jها هستند. پاسخ نهایی باید تنها بر حسب x_i، μ_B، σ_B^2، ϵ، γ و g_j باشد. هدف رسیدن به رابطه زیر است:

$$\frac{\partial L}{\partial x_i} = \frac{\gamma}{\sqrt{\sigma_B^2 + \epsilon}}\left(g_i - \frac{1}{m}\sum_{j=1}^{m} g_j - \frac{\hat{x}_i}{m}\sum_{j=1}^{m} g_j \hat{x}_j\right)$$

راهنمایی: ابتدا $\frac{\partial L}{\partial \hat{x}_i}$ را بر حسب g_i و γ بنویسید، سپس گرادیان‌ها را از طریق $\hat{x}_i$، μ_B و σ_B^2 به عقب منتقل کنید.

پ. با استفاده از رابطه‌ای که در قسمت (ب) به دست آوردید، به صورت تحلیلی ثابت کنید که:

$$\sum_{i=1}^{m} \frac{\partial L}{\partial x_i} = 0$$

در یک یا دو جمله توضیح دهید که این ویژگی چه مفهوم شهودی‌ای در مورد رفتار لایه BN نسبت به شیفت دادن تمام ورودی‌های دسته با یک مقدار ثابت (مثلاً $x_i \leftarrow x_i + c$) دارد.

حل.

پاسخ آ. برای محاسبه گرادیان پارامترهای قابل یادگیری γ و β، از قاعده زنجیره‌ای استفاده می‌کنیم. از آنجا که این پارامترها برای تمام نمونه‌های موجود در Mini-batch مشترک هستند، باید گرادیان‌ها را روی تمام $i = 1 \ldots m$ جمع بزنیم.

رابطه خروجی عبارت است از: $y_i = \gamma \hat{x}_i + \beta$.

۱. گرادیان نسبت به β:

$$\frac{\partial L}{\partial \beta} = \sum_{i=1}^{m} \frac{\partial L}{\partial y_i}\frac{\partial y_i}{\partial \beta}$$

[۱۳] Batch Normalization (BN)

چون $\frac{\partial y_i}{\partial \beta} = ۱$، داریم:

$$\frac{\partial L}{\partial \beta} = \sum_{i=۱}^{m} g_i$$

۲. گرادیان نسبت به γ:

$$\frac{\partial L}{\partial \gamma} = \sum_{i=۱}^{m} \frac{\partial L}{\partial y_i}\frac{\partial y_i}{\partial \gamma}$$

چون $\frac{\partial y_i}{\partial \gamma} = \hat{x}_i$، داریم:

$$\frac{\partial L}{\partial \gamma} = \sum_{i=۱}^{m} g_i \hat{x}_i$$

پاسخ ب. برای محاسبه $\frac{\partial L}{\partial x_i}$، مسیر گرادیان از سه طریق به x_i می‌رسد: مستقیم از طریق $\hat{x}_i$، و غیرمستقیم از طریق μ_B و $\sigma_B^۲$.

گام ۱: محاسبه گرادیان نسبت به ورودی نرمال‌شده ($\hat{x}_i$)

$$\frac{\partial L}{\partial \hat{x}_i} = \frac{\partial L}{\partial y_i}\frac{\partial y_i}{\partial \hat{x}_i} = g_i \gamma$$

گام ۲: محاسبه گرادیان نسبت به واریانس ($\sigma_B^۲$)

$$\frac{\partial L}{\partial \sigma_B^۲} = \sum_{j=۱}^{m} \frac{\partial L}{\partial \hat{x}_j}\frac{\partial \hat{x}_j}{\partial \sigma_B^۲}$$

با توجه به اینکه $\hat{x}_j = (x_j - \mu_B)(\sigma_B^۲ + \epsilon)^{-۱/۲}$:

$$\frac{\partial \hat{x}_j}{\partial \sigma_B^۲} = -\frac{۱}{۲}(x_j - \mu_B)(\sigma_B^۲ + \epsilon)^{-۳/۲} = -\frac{۱}{۲}\frac{\hat{x}_j}{\sigma_B^۲ + \epsilon}$$

بنابراین:

$$\frac{\partial L}{\partial \sigma_B^۲} = -\frac{۱}{۲(\sigma_B^۲ + \epsilon)} \sum_{j=۱}^{m} g_j \gamma \hat{x}_j$$

گام ۳: محاسبه گرادیان نسبت به میانگین (μ_B) توجه کنید که مجموع انحرافات از میانگین صفر است ($\sum(x_j - \mu_B) = ۰$)، بنابراین ترم وابسته به $\sigma_B^۲$ در مشتق‌گیری نسبت به μ_B صفر می‌شود. تنها وابستگی مستقیم $\hat{x}$ باقی می‌ماند:

$$\frac{\partial L}{\partial \mu_B} = \sum_{j=۱}^{m} \frac{\partial L}{\partial \hat{x}_j}\frac{\partial \hat{x}_j}{\partial \mu_B}$$

$$\frac{\partial \hat{x}_j}{\partial \mu_B} = \frac{-۱}{\sqrt{\sigma_B^۲ + \epsilon}}$$

بنابراین:

$$\frac{\partial L}{\partial \mu_B} = \sum_{j=۱}^{m} (g_j \gamma)\frac{-۱}{\sqrt{\sigma_B^۲ + \epsilon}} = \frac{-\gamma}{\sqrt{\sigma_B^۲ + \epsilon}} \sum_{j=۱}^{m} g_j$$

گام ۴: محاسبه گرادیان نهایی نسبت به x_i

$$\frac{\partial L}{\partial x_i} = \underbrace{\frac{\partial L}{\partial \hat{x}_i}\frac{\partial \hat{x}_i}{\partial x_i}}_{\text{۱ Term}} + \underbrace{\frac{\partial L}{\partial \sigma_B^۲}\frac{\partial \sigma_B^۲}{\partial x_i}}_{\text{۲ Term}} + \underbrace{\frac{\partial L}{\partial \mu_B}\frac{\partial \mu_B}{\partial x_i}}_{\text{۳ Term}}$$

محاسبه اجزا:

- $\frac{\partial \hat{x}_i}{\partial x_i} = \frac{۱}{\sqrt{\sigma_B^۲+\epsilon}}$
- $\frac{\partial \sigma_B^۲}{\partial x_i} = \frac{۲(x_i-\mu_B)}{m}$
- $\frac{\partial \mu_B}{\partial x_i} = \frac{۱}{m}$

جایگذاری در رابطه کلی:

$$\text{Term ۱} = \frac{g_i\gamma}{\sqrt{\sigma_B^۲+\epsilon}}$$

$$\text{Term ۲} = \left(\frac{-\gamma\sum_j g_j\hat{x}_j}{۲(\sigma_B^۲+\epsilon)}\right)\left(\frac{۲(x_i-\mu_B)}{m}\right) = \frac{-\gamma}{\sqrt{\sigma_B^۲+\epsilon}}\cdot\frac{\hat{x}_i}{m}\sum_{j=۱}^{m} g_j\hat{x}_j$$

$$\text{Term ۳} = \left(\frac{-\gamma\sum_j g_j}{\sqrt{\sigma_B^۲+\epsilon}}\right)\left(\frac{۱}{m}\right) = \frac{-\gamma}{\sqrt{\sigma_B^۲+\epsilon}}\cdot\frac{۱}{m}\sum_{j=۱}^{m} g_j$$

با فاکتورگیری از $\frac{\gamma}{\sqrt{\sigma_B^۲+\epsilon}}$ به رابطه خواسته شده می‌رسیم:

$$\frac{\partial L}{\partial x_i} = \frac{\gamma}{\sqrt{\sigma_B^۲+\epsilon}}\left(g_i - \frac{۱}{m}\sum_{j=۱}^{m} g_j - \frac{\hat{x}_i}{m}\sum_{j=۱}^{m} g_j\hat{x}_j\right)$$

پاسخ پ. اثبات: برای اثبات $\sum_{i=۱}^{m}\frac{\partial L}{\partial x_i} = ۰$، از رابطه به دست آمده در قسمت (ب) استفاده کرده و روی i جمع می‌بندیم. ضریب ثابت $C = \frac{\gamma}{\sqrt{\sigma_B^۲+\epsilon}}$ را بیرون نگه می‌داریم:

$$\sum_{i=۱}^{m}\frac{\partial L}{\partial x_i} = C\left[\sum_{i=۱}^{m} g_i - \sum_{i=۱}^{m}\left(\frac{۱}{m}\sum_{j=۱}^{m} g_j\right) - \sum_{i=۱}^{m}\left(\frac{\hat{x}_i}{m}\sum_{j=۱}^{m} g_j\hat{x}_j\right)\right]$$

ترم دوم: $\sum_{i=۱}^{m}\frac{۱}{m}(\sum g_j) = m\cdot\frac{۱}{m}\sum g_j = \sum g_j$. (این با ترم اول خنثی می‌شود).
ترم سوم: $\frac{۱}{m}(\sum_j g_j\hat{x}_j)\sum_{i=۱}^{m}\hat{x}_i$. از آنجا که داده‌ها نرمال شده‌اند، مجموع آن‌ها صفر است ($\sum_{i=۱}^{m}\hat{x}_i = ۰$). بنابراین ترم سوم نیز صفر می‌شود.

$$\sum_{i=۱}^{m}\frac{\partial L}{\partial x_i} = C\left[\sum g_i - \sum g_j - ۰\right] = ۰$$

مفهوم شهودی: این ویژگی نشان می‌دهد که لایه Normalization Batch نسبت به **تغییر مکان (Shift)** ورودی‌ها ناوردا است. اگر عدد ثابتی به تمام ورودی‌های یک دسته اضافه شود، چون میانگین (μ_B) نیز به همان اندازه زیاد می‌شود، خروجی نهایی ($x_i - \mu_B$) تغییری نمی‌کند؛ بنابراین گرادیان کل نسبت به این تغییر مکان سراسری برابر صفر است.

یک اشتباه رایج برای قسمت ب: در محاسبه گرادیان ورودی، ممکن است به اشتباه تصور شود که x_i تنها روی $\hat{x}_i$ تاثیر می‌گذارد و بنویسیم:

$$\frac{\partial L}{\partial x_i} \stackrel{?}{=} \frac{\partial L}{\partial \hat{x}_i}\frac{\partial \hat{x}_i}{\partial x_i}$$

این رابطه **نادرست** است. دلیل آن مکانیزم نرمال‌سازی است: تغییر در مقدار یک ورودی خاص (x_i) باعث تغییر میانگین (μ_B) و واریانس (σ_B^2) کل دسته (Batch) می‌شود. چون تمام خروجی‌های نرمال‌سازی شده ($\hat{x}_1, \ldots, \hat{x}_m$) در فرمول خود به μ_B و σ_B^2 وابسته هستند، تغییر x_i در واقع روی **تمامی** خروجی‌ها تاثیر می‌گذارد. بنابراین، طبق قاعده زنجیره‌ای چندمتغیره، باید گرادیان را روی تمام jها جمع بست:

$$\frac{\partial L}{\partial x_i} = \sum_{j=1}^{m} \frac{\partial L}{\partial \hat{x}_j} \frac{\partial \hat{x}_j}{\partial x_i}$$