دانشگاه صنعتی شریف
دانشکده‌ی مهندسی کامپیوتر

یادگیری ماشین
پاییز و زمستان ۱۴۰۴
استاد: علی شریفی زارچی
گردآورندگان:

تمرین سوم	موضوع	مهلت ارسال: ۲۸ آذر

سوالات نظری (۱۰۰ نمره)

۱. (۸ نمره)

بخش اول: گزاره‌های زیر صحیح است یا خیر؟ مختصر توضیح دهید.

آ. اگر به تعداد کافی پرسپترون و لایه داشته باشیم، می‌توانیم هر تابع پیوسته‌ای را با دقت دلخواه تقریب بزنیم.

صحیح است. این گزاره بیان‌کننده قضیه Universal Approximation است. طبق این قضیه، یک شبکه‌ی عصبی پیش‌خور با حداقل یک لایه‌ی مخفی و تعداد کافی نورون می‌تواند هر تابع **پیوسته** را روی یک بازه‌ی فشرده، با دقت دلخواه تقریب بزند.

ب. تابع هزینه در یک شبکه عصبی عمیق، به دلیل وجود توابع فعال‌سازی غیرخطی و ساختار چند لایه، همواره یک تابع غیرمحدب است.

نادرست است. تابع هزینه‌ی یک شبکه‌ی عصبی عمیق **الزاماً غیرمحدب نیست**. در بسیاری از حالت‌ها، مانند رگرسیون خطی یا شبکه‌هایی با ساختار خاص، تابع هزینه می‌تواند محدب باشد. اگرچه در عمل، به دلیل وجود لایه‌های متعدد و توابع فعال‌سازی غیرخطی، معمولاً تابع هزینه **غیرمحدب** است، اما این یک حکم همیشگی نیست.

پ. یک شبکه عصبی که تنها یک لایه دارد و از تابع فعال‌سازی Sigmoid برای خروجی، به همراه تابع هزینه Cross-entropy برای دسته‌بندی دودویی استفاده می‌کند، کاملاً با مدل Logistic regression یکسان است.

صحیح است. یک شبکه‌ی عصبی با یک لایه (بدون لایه‌ی مخفی)، تابع فعال‌سازی Sigmoid در خروجی، و تابع هزینه‌ی Cross-Entropy برای دسته‌بندی دودویی، از نظر ریاضی کاملاً معادل مدل Logistic Regression است.

ت. پارامترهای گاما (γ) و بتا (β) در لایه نرمال‌سازی دسته‌ای، هایپرپارامتر هستند که باید قبل از شروع آموزش به صورت دستی تنظیم شوند و در حین Backpropagation به‌روزرسانی نمی‌شوند.

نادرست است. پارامترهای γ (گاما) و β (بتا) در لایه‌ی نرمال‌سازی دسته‌ای یا Batch Normalization **پارامترهای قابل یادگیری** هستند و در طول آموزش، از طریق الگوریتم به‌روزرسانی می‌شوند. این پارامترها هایپرپارامتر نیستند و به‌صورت دستی تنظیم نمی‌شوند.

بخش دوم: به سوالات زیر پاسخ کوتاه دهید.

آ. چرا مقداردهی اولیه صفر برای تمام وزن‌های یک شبکه عصبی ایده بدی است و باعث چه مشکلی در فرآیند یادگیری می‌شود؟

مقداردهی همه‌ی وزن‌ها با صفر باعث **شکست تقارن** می‌شود. اگر وزن‌های تمام نورون‌های یک لایه یکسان باشند، در مرحله‌ی Backpropagation گرادیان‌های یکسانی دریافت می‌کنند و بنابراین همیشه یکسان به‌روز می‌شوند و یکسان رفتار می‌کنند. در نتیجه، شبکه هرگز یاد نمی‌گیرد ویژگی‌های متفاوتی را استخراج کند.

ب. چرا توابع فعال‌سازی در لایه‌های مخفی یک شبکه عصبی باید غیرخطی باشند؟ اگر همه آن‌ها خطی باشند چه اتفاقی می‌افتد؟

اگر تمام توابع فعال‌سازی خطی باشند، کل شبکه معادل یک تبدیل خطی می‌شود:

$$W_3(W_2(W_1x)) = Wx$$

یعنی چندین لایه‌ی خطی پشت سر هم **باز هم یک تابع خطی** ایجاد می‌کنند. در این حالت، شبکه نمی‌تواند هیچ رابطه‌ی غیرخطی را مدل کند و الگوهای پیچیده غیر خطی را از دست می‌دهد.

$\Rightarrow$ شبکه‌ی عمیق به یک رگرسیون خطی ساده تبدیل می‌شود.

پ. مکانیزم بهینه‌ساز «مومنتوم» (Momentum) را با روش «کاهش شیب تصادفی» (SGD) استاندارد مقایسه کنید. مومنتوم برای حل چه مشکلی در فرآیند بهینه‌سازی معرفی شده است؟

SGD استاندارد تنها از گرادیان لحظه‌ای استفاده می‌کند:

$$\theta_{t+1} = \theta_t - \eta \nabla L(\theta_t)$$

اما در **Gradient Descent با مومنتوم** از میانگین‌گیری نمایی گرادیان‌ها استفاده می‌شود:

$$v_{t+1} = \beta v_t + (1-\beta)\nabla L(\theta_t), \qquad \theta_{t+1} = \theta_t - \eta v_{t+1}$$

مزایا و دلیل معرفی:

- کاهش نوسان‌ها در جهت‌های ناهموار
- حرکت سریع‌تر در جهت درست و جلوگیری از گیرکردن در مینیمم‌های محلی کم‌عمق
- افزایش سرعت همگرایی

ت. روش «حذف تصادفی»[1] چگونه کار می‌کند و نقش اصلی آن به عنوان یک روش تنظیم‌گری[2] چیست؟ چرا این روش فقط در مرحله آموزش فعال است و در مرحله آزمون باید غیرفعال شود؟

در روش **Dropout**، در هر مرحله‌ی آموزش، هر نورون با احتمال p غیرفعال می‌شود:

$$h_i^{(dropped)} = \begin{cases} 0 & \text{با احتمال } p \\ h_i & \text{با احتمال } 1-p \end{cases}$$

نقش اصلی:

- جلوگیری از **overfitting** با کاهش وابستگی بیش از حد نورون‌ها به یکدیگر
- شبیه‌سازی رفتار **ensemble** از چندین شبکه‌ی کوچکتر

چرا در مرحله‌ی آزمون غیرفعال است؟

- در زمان آزمون نیاز به خروجی پایدار و قطعی داریم.
- غیرفعال کردن نورون‌ها باعث نوسان و کاهش دقت می‌شود.
- به‌جای این کار، در زمان آزمون خروجی‌ها **اسکیل می‌شوند** تا اثر dropout جبران شود.

۲. (۱۲ نمره) یک شبکه عصبی با ۲ ورودی، ۲ نورون در لایه مخفی[3] با تابع فعال‌سازی ReLU و یک نورون خروجی با تابع فعال‌سازی Sigmoid داده شده است. پارامترها به صورت زیر هستند:

$$W^{(1)} = \begin{bmatrix} 1 & -1 \\ 0.5 & 0.5 \end{bmatrix}, \quad b^{(1)} = \begin{bmatrix} 0 \\ 0.5 \end{bmatrix}, \quad W^{(2)} = \begin{bmatrix} 1 & -1.5 \end{bmatrix}, \quad b^{(2)} = 0.2$$

برای ورودی $x = \begin{bmatrix} 2 \\ -1 \end{bmatrix}$ و برچسب $y = 1$ ، موارد زیر را انجام دهید:

الف. یک مرحله پیش‌روی کامل[4] را اجرا کرده و مقادیر $a^{(1)}$، h، $z^{(2)}$ و $\hat{y}$ را به دست آورید. (در اینجا h خروجی فعال‌شده لایه مخفی است).

مرحله ۱: محاسبه $\mathbf{z}^{(۱)}$

$$
\begin{aligned}
z^{(۱)} &= W^{(۱)}x + b^{(۱)} \\
z^{(۱)} &= \begin{bmatrix} ۱ & -۱ \\ ۰/۵ & ۰/۵ \end{bmatrix} \begin{bmatrix} ۲ \\ -۱ \end{bmatrix} + \begin{bmatrix} ۰ \\ ۰/۵ \end{bmatrix} \\
&= \begin{bmatrix} ۱ \cdot ۲ + (-۱) \cdot (-۱) \\ ۰/۵ \cdot ۲ + ۰/۵ \cdot (-۱) \end{bmatrix} + \begin{bmatrix} ۰ \\ ۰/۵ \end{bmatrix} \\
&= \begin{bmatrix} ۳ \\ ۰/۵ \end{bmatrix} + \begin{bmatrix} ۰ \\ ۰/۵ \end{bmatrix} = \begin{bmatrix} ۳ \\ ۱ \end{bmatrix}.
\end{aligned}
$$

مرحله ۲: محاسبه $\mathbf{a}^{(۱)} ReLU$

$$
\begin{aligned}
a^{(۱)} &= \mathrm{ReLU}(z^{(۱)}) = \max(۰, z^{(۱)}) \\
a^{(۱)} &= \begin{bmatrix} \max(۰, ۳) \\ \max(۰, ۱) \end{bmatrix} = \begin{bmatrix} ۳ \\ ۱ \end{bmatrix} \\
h &= a^{(۱)} = \begin{bmatrix} ۳ \\ ۱ \end{bmatrix}
\end{aligned}
$$

مرحله ۳: محاسبه $\mathbf{z}^{(۲)}$

$$
\begin{aligned}
z^{(۲)} &= W^{(۲)}a^{(۱)} + b^{(۲)} \\
z^{(۲)} &= \begin{bmatrix} ۱ & -\frac{۱}{۵} \end{bmatrix} \begin{bmatrix} ۳ \\ ۱ \end{bmatrix} + ۰/۲ \\
&= ۱ \cdot ۳ - ۱/۵ + ۰/۲ \\
&= ۳ - ۱/۵ + ۰/۲ = ۱/۷
\end{aligned}
$$

مرحله ۴: محاسبه خروجی نهایی

$$
\begin{aligned}
\hat{y} &= \sigma(z^{(۲)}) = \frac{۱}{۱ + e^{-z^{(۲)}}} \\
\hat{y} &= \frac{۱}{۱ + e^{-۱/۷}} \approx ۰/۸۴۵
\end{aligned}
$$

$$
h = \begin{bmatrix} ۳ \\ ۱ \end{bmatrix}, \qquad z^{(۲)} = ۳, \qquad \hat{y} \approx ۰/۸۴۵
$$

ب. با استفاده از تابع هزینه[۵] Cross-Entropy که در زیر تعریف شده است، گرادیان‌های هزینه نسبت به تمام پارامترها را محاسبه کرده و مقادیر عددی آن‌ها را به دست آورید.

$$
\mathcal{L}(\hat{y}, y) = -[y \ln \hat{y} + (۱ - y) \ln(۱ - \hat{y})]
$$

گرادیان‌های مورد نیاز: $\frac{\partial \mathcal{L}}{\partial W^{(۱)}}$، $\frac{\partial \mathcal{L}}{\partial b^{(۱)}}$، $\frac{\partial \mathcal{L}}{\partial W^{(۲)}}$، $\frac{\partial \mathcal{L}}{\partial b^{(۲)}}$

$$\frac{\partial L}{\partial z^{(۲)}} = \frac{\partial L}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial z^{(۲)}}$$

$$\frac{\partial L}{\partial \hat{y}} = -\left(\frac{y}{\hat{y}} - \frac{۱-y}{۱-\hat{y}}\right)$$

$$\frac{\partial \hat{y}}{\partial z^{(۲)}} = \hat{y}(۱-\hat{y})$$

$$\frac{\partial L}{\partial z^{(۲)}} = -\left(\frac{y}{\hat{y}} - \frac{۱-y}{۱-\hat{y}}\right)\hat{y}(۱-\hat{y})$$

از جمله اول داریم:

$$-\frac{y}{\hat{y}} \cdot \hat{y}(۱-\hat{y}) = -y(۱-\hat{y})$$

از جمله دوم داریم:

$$\frac{۱-y}{۱-\hat{y}} \cdot \hat{y}(۱-\hat{y}) = \hat{y}(۱-y)$$

حاصل جمع این دو جمله برابر است با:

$$\frac{\partial L}{\partial z^{(۲)}} = -y + y\hat{y} + \hat{y} - y\hat{y} = \hat{y} - y$$

در نتیجه داریم:

$$\frac{\partial L}{\partial z^{(۲)}} = \hat{y} - y = ۰/۸۴۵ - ۱ = -۰/۱۵۵$$

$$\frac{\partial L}{\partial W^{(۲)}} = \frac{\partial L}{\partial z^{(۲)}}(a^{(۱)})^T = -۰/۱۵۵\begin{bmatrix} ۳ & ۱ \end{bmatrix} = \begin{bmatrix} -۰/۴۶۵ & -۰/۱۵۵ \end{bmatrix}$$

$$\frac{\partial L}{\partial b^{(۲)}} = \frac{\partial L}{\partial z^{(۲)}} \cdot \frac{\partial z^{(۲)}}{\partial b^{(۲)}} = \frac{\partial L}{\partial z^{(۲)}} \cdot ۱ = -۰/۱۵۵$$

$$\frac{\partial L}{\partial a^{(۱)}} = \frac{\partial L}{\partial z^{(۲)}} \cdot \frac{\partial z^{(۲)}}{\partial a^{(۱)}} = \left(W^{(۲)}\right)^{\top}(\hat{y} - y)$$

$$= \begin{bmatrix} ۱ \\ -۱/۵ \end{bmatrix}(-۰/۱۵۵) = \begin{bmatrix} -۰/۱۵۵ \\ ۰/۲۳۳ \end{bmatrix}$$

$$\frac{\partial L}{\partial z^{(۱)}} = \frac{\partial L}{\partial a^{(۱)}}\frac{\partial a^{(۱)}}{\partial z^{(۱)}} = \frac{\partial L}{\partial a^{(۱)}} \odot \begin{bmatrix} ۱ \\ ۱ \end{bmatrix} = \begin{bmatrix} -۰/۱۵۵ \\ ۰/۲۳۳ \end{bmatrix}$$

$$\frac{\partial L}{\partial W^{(۱)}} = \frac{\partial L}{\partial z^{(۱)}} x^T = \begin{bmatrix} -۰/۱۵۵ \\ ۰/۲۳۳ \end{bmatrix}\begin{bmatrix} ۲ & -۱ \end{bmatrix} = \begin{bmatrix} -۰/۳۱۰ & ۰/۱۵۵ \\ ۰/۴۶۶ & -۰/۲۳۳ \end{bmatrix}$$

$$\frac{\partial L}{\partial b^{(۱)}} = \frac{\partial L}{\partial z^{(۱)}} \cdot \frac{\partial z^{(۱)}}{\partial b^{(۱)}} = \frac{\partial L}{\partial z^{(۱)}} \cdot ۱ = \begin{bmatrix} -۰/۱۵۵ \\ ۰/۲۳۳ \end{bmatrix}$$

پ. (۱) تعداد کل پارامترهای قابل آموزش برای یک شبکه عصبی تماماً متصل[۶] با n نورون در لایه ورودی، یک لایه مخفی با k نورون، و m نورون در لایه خروجی را به صورت یک فرمول کلی بنویسید.
(۲) با استفاده از فرمول به دست آمده، تعداد کل پارامترهای قابل آموزش برای شبکه تعریف شده در این سوال را محاسبه کنید.

- تعداد وزن‌های بین لایهٔ ورودی و لایهٔ مخفی:

$$nk$$

- تعداد بایاس‌های لایهٔ مخفی:

$$k$$

- تعداد وزن‌های بین لایهٔ مخفی و لایهٔ خروجی:

$$mk$$

- تعداد بایاس‌های لایهٔ خروجی:

$$m$$

بنابراین تعداد کل پارامترهای قابل آموزش برابر است با:

$$P = nk + k + mk + m$$

یا به صورت فاکتورگیری شده:

$$P = k(n + ۱) + m(k + ۱)$$

طبق فرمول بدست آمده تعداد پارامترهای سوال فوق برابر است با:

$$P = ۲(۲ + ۱) + ۱(۲ + ۱) = ۹$$

ت. از لحاظ مفهومی توضیح دهید که افزودن یک لایه مخفی جدید به یک شبکه عصبی، چه تأثیری بر ظرفیت مدل می‌گذارد و چرا این کار احتمال بیش‌برازش[۷] را افزایش می‌دهد؟

افزودن یک لایهٔ مخفی جدید به یک شبکهٔ عصبی ظرفیت مدل را افزایش می‌دهد، زیرا هر لایهٔ اضافی یک تبدیل غیرخطی جدید ایجاد کرده و فضای توابع قابل نمایش توسط شبکه را بزرگ‌تر می‌کند؛ در نتیجه مدل می‌تواند روابط پیچیده‌تر و الگوهای سطح‌بالاتری را از داده استخراج کند. از سوی دیگر، این لایهٔ جدید معمولاً تعداد قابل توجهی وزن و بایاس به شبکه اضافه می‌کند و همین افزایش پارامترها آزادی بیشتری برای یادگیری جزئیات داده به مدل می‌دهد. هنگامی که ظرفیت مدل نسبت به میزان دادهٔ در دسترس بزرگ‌تر شود، شبکه به‌جای یادگیری الگوهای کلی، تمایل به حفظ و دنبال‌کردن نویز و نوسانات تصادفی داده پیدا می‌کند؛ بنابراین احتمال بیش‌برازش افزایش می‌یابد، زیرا مدل روی دادهٔ آموزش عملکرد بسیار خوبی پیدا کرده اما روی داده‌های جدید تعمیم ضعیف‌تری خواهد داشت.

۳. (۲۵ نمره) تابع سافت‌مکس (Softmax) این خاصیت مطلوب را دارد که یک توزیع احتمال خروجی می‌دهد و اغلب به عنوان تابع فعال‌سازی در بسیاری از شبکه‌های دسته‌بندی چندکلاسه استفاده می‌شود. یک شبکه عصبی ۲ـ لایه برای دسته‌بندی Kـ کلاسه، با استفاده از فعال‌سازی سافت‌مکس و تابع هزینه Cross-Entropy مطابق تعریف زیر در نظر بگیرید:

$$\begin{aligned} z^{[1]} &= W^{[1]}x + b^{[1]} \\ a^{[1]} &= \text{LeakyReLU}(z^{[1]}, \alpha = 0/01) \\ z^{[2]} &= W^{[2]}a^{[1]} + b^{[2]} \\ \bar{y} &= \text{softmax}(z^{[2]}) \\ L &= -\sum_{i=1}^{K} y_i \log(\bar{y}_i) \end{aligned}$$

که در آن مدل ورودی x به شکل $D_x \times 1$ و برچسب One-hot ($y \in \{0,1\}^K$) را می‌گیرد. فرض کنید لایه پنهان دارای D_a گره است، یعنی $z^{[1]}$ یک بردار با اندازه $D_a \times 1$ است. به یاد بیاورید که تابع سافت‌مکس به صورت زیر محاسبه می‌شود:

$$\hat{y} = \begin{bmatrix} \exp(z_1^{[2]})/Z \\ \vdots \\ \exp(z_K^{[2]})/Z \end{bmatrix}, \quad Z = \sum_{j=1}^{K} \exp(z_j^{[2]})$$

آ. شکل (ابعاد) $W^{[2]}$ و $b^{[2]}$ چیست؟ اگر بر روی m مثال برداری‌سازی می‌کردیم، یعنی از یک دسته[8] نمونه $X \in \mathbb{R}^{D_x \times m}$ به عنوان ورودی استفاده می‌کردیم، شکل خروجی لایه پنهان چه می‌بود؟

ابعاد ماتریس وزن‌های لایه پنهان و بایاس متناظر با آن در حالتی که ورودی تک نمونه است برابر است با:

$$\begin{aligned} W^{[1]} \in \mathbb{R}^{D_a \times D_x}, \qquad & b^{[1]} \in \mathbb{R}^{D_a \times 1} \\ z^{[1]} = W^{[1]}x + b^{[1]} \quad \Rightarrow \quad & z^{[1]} \in \mathbb{R}^{D_a \times 1} \\ a^{[1]} = \text{LeakyReLU}(z^{[1]}) \quad \Rightarrow \quad & a^{[1]} \in \mathbb{R}^{D_a \times 1} \\ W^{[2]} \in \mathbb{R}^{K \times D_a}, \qquad & b^{[2]} \in \mathbb{R}^{K \times 1} \\ z^{[2]} = W^{[2]}a^{[1]} + b^{[2]} \quad \Rightarrow \quad & z^{[2]} \in \mathbb{R}^{K \times 1} \end{aligned}$$

با توجه به روابط مسئله، اگر ورودی یک بردار باشد آنگاه $z^{[1]} \in \mathbb{R}^{D_a \times 1}$ خواهد بود. حال اگر به‌جای یک نمونه، ماتریس ورودی $X \in \mathbb{R}^{D_x \times m}$ شامل m نمونه (هر ستون یک نمونه) به شبکه داده شود، خروجی لایهٔ پنهان از رابطهٔ

$$Z^{[1]} = W^{[1]}X + b^{[1]}$$

به‌دست می‌آید. از آن‌جا که $W^{[1]} \in \mathbb{R}^{D_a \times D_x}$ و $X \in \mathbb{R}^{D_x \times m}$ داریم:

$$W^{[1]}X \in \mathbb{R}^{D_a \times m}$$

بردار بایاس نیز $b^{[1]} \in \mathbb{R}^{D_a \times 1}$ است و برای تمام ستون‌ها broadcast شده و با حاصل، جمع می‌شود. بنابراین خروجی لایهٔ پنهان برابر است با:

$$\boxed{Z^{[1]} \in \mathbb{R}^{D_a \times m}}$$

ب. مشتق $\frac{\partial \hat{y}_k}{\partial z_k^{[2]}}$ چیست؟ پاسخ خود را بر حسب مؤلفه(های) $\hat{y}$ ساده کنید.

می‌دانیم:

$$\hat{y}^{(k)} = \frac{\exp\left(z_k^{[2]}\right)}{Z}, Z = \sum_{j=1}^{K} \exp\left(z_j^{[2]}\right)$$

$$\frac{\partial \hat{y}^{(k)}}{\partial z_k^{[۲]}} = \frac{\partial}{\partial z_k^{[۲]}}\left(\frac{\exp(z_k^{[۲]})}{Z}\right) = \frac{\exp(z_k^{[۲]})'\, Z - \exp(z_k^{[۲]})\, Z'}{Z^۲},$$

$$\frac{\partial}{\partial z_k^{[۲]}} \exp(z_k^{[۲]}) = \exp(z_k^{[۲]})$$

$$Z' = \frac{\partial}{\partial z_k^{[۲]}} \sum_j \exp(z_j^{[۲]}) = \exp(z_k^{[۲]}),$$

$$\frac{\partial \hat{y}^{(k)}}{\partial z_k^{[۲]}} = \frac{\exp(z_k^{[۲]})\, Z - \exp(z_k^{[۲]})\, \exp(z_k^{[۲]})}{Z^۲} = \frac{\exp(z_k^{[۲]})}{Z} \cdot \frac{Z - \exp(z_k^{[۲]})}{Z}$$

$$\hat{y}^{(k)} = \frac{\exp(z_k^{[۲]})}{Z} \quad \Rightarrow \quad \frac{\partial \hat{y}^{(k)}}{\partial z_k^{[۲]}} = \hat{y}^{(k)}\left(۱ - \hat{y}^{(k)}\right).$$

پ. به ازای $i \neq k$، مشتق $\frac{\partial \hat{y}_k}{\partial z_i^{[۲]}}$ چیست؟ پاسخ خود را بر حسب مؤلفه(های) $\hat{y}$ ساده کنید.

چون صورت کسر نسبت به $z_i^{[۲]}$ مشتق ندارد (برای $i \neq k$)، تنها به Z وابسته است:

$$\frac{\partial \hat{y}^{(k)}}{\partial z_i^{[۲]}} = \frac{\partial}{\partial z_i^{[۲]}}\left(\frac{\exp(z_k^{[۲]})}{Z}\right) = \exp(z_k^{[۲]}) \cdot \frac{\partial}{\partial z_i^{[۲]}}\left(\frac{۱}{Z}\right)$$

$$\frac{\partial}{\partial z_i^{[۲]}}\left(\frac{۱}{Z}\right) = -\frac{Z'}{Z^۲}, \qquad Z' = \frac{\partial}{\partial z_i^{[۲]}} \sum_j \exp(z_j^{[۲]}) = \exp(z_i^{[۲]})$$

$$\frac{\partial \hat{y}^{(k)}}{\partial z_i^{[۲]}} = \exp(z_k^{[۲]})\left(-\frac{\exp(z_i^{[۲]})}{Z^۲}\right)$$

حال از تعریف خروجی سافت‌مکس استفاده می‌کنیم:

$$\hat{y}^{(k)} = \frac{\exp(z_k^{[۲]})}{Z}, \qquad \hat{y}^{(i)} = \frac{\exp(z_i^{[۲]})}{Z}$$

پس:

$$\frac{\partial \hat{y}^{(k)}}{\partial z_i^{[۲]}} = -\frac{\exp(z_k^{[۲]})}{Z} \cdot \frac{\exp(z_i^{[۲]})}{Z}$$

در نهایت:

$$\boxed{\frac{\partial \hat{y}^{(k)}}{\partial z_i^{[۲]}} = -\,\hat{y}^{(k)}\,\hat{y}^{(i)}}$$

ت. فرض کنید برچسب y درایه kـام خود مقدار ۱ و در سایر درایه‌ها مقدار ۰ دارد. $\frac{\partial L}{\partial z_i^{[۲]}}$ چیست؟ پاسخ خود را بر حسب $\hat{y}_i$ ساده کنید. نکته: هر دو حالت $i = k$ و $i \neq k$ را در نظر بگیرید.

ابتدا مشتق‌های سافت‌مکس را بازنویسی می‌کنیم:

$$\frac{\partial \hat{y}^{(k)}}{\partial z_i^{[۲]}} = \begin{cases} \hat{y}^{(k)}\left(۱ - \hat{y}^{(k)}\right), & i = k, \\ -\,\hat{y}^{(k)}\,\hat{y}^{(i)}, & i \neq k. \end{cases}$$

حالا مشتق تابع هزینه نسبت به $z_i^{[۲]}$ را محاسبه می‌کنیم. از آن‌جا که $L = -\log \hat{y}^{(k)}$ داریم:

$$\frac{\partial L}{\partial z_i^{[۲]}} = -\frac{۱}{\hat{y}^{(k)}} \cdot \frac{\partial \hat{y}^{(k)}}{\partial z_i^{[۲]}}$$

بنابراین دو حالت به‌دست می‌آید:

حالت $i = k$**:**

$$\frac{\partial L}{\partial z_k^{[۲]}} = -\frac{۱}{\hat{y}^{(k)}} \cdot \hat{y}^{(k)}\left(۱ - \hat{y}^{(k)}\right) = -\left(۱ - \hat{y}^{(k)}\right) = \hat{y}^{(k)} - ۱$$

حالت $i \neq k$**:**

$$\frac{\partial L}{\partial z_i^{[۲]}} = -\frac{۱}{\hat{y}^{(k)}} \cdot \left(-\hat{y}^{(k)}\hat{y}^{(i)}\right) = \hat{y}^{(i)}$$

می‌توان این نتایج را به صورت یک رابطهٔ کلی جمع‌بندی کرد:

$$\boxed{\frac{\partial L}{\partial z_i^{[۲]}} = \hat{y}^{(i)} - y_i}$$

زیرا وقتی y بردار one-hot با $y_k = ۱$ باشد، برای $i = k$ مقدار $\hat{y}^{(i)} - y_i = \hat{y}^{(k)} - ۱$ و برای $i \neq k$ مقدار $\hat{y}^{(i)} - y_i = \hat{y}^{(i)}$ می‌دهد.

ث. مشتق $\frac{\partial z^{[۲]}}{\partial a^{[۱]}}$ چیست؟ این نتیجه را با نماد $\delta_۱$ نشان دهید.

طبق رابطه $z^{[۲]} = W^{[۲]}a^{[۱]} + b^{[۲]}$ داریم:

$$\delta_۱ = \frac{\partial z^{[۲]}}{\partial a^{[۱]}} = W^{[۲]}$$

ج. مشتق $\frac{\partial a^{[۱]}}{\partial z^{[۱]}}$ چیست؟ این نتیجه را با نماد $\delta_۲$ نشان دهید. می‌توانید از نماد آکولاد (تابع چندضابطه‌ای) استفاده کنید.

$$a^{[۱]} = \begin{cases} z^{[۱]}, & z^{[۱]} \geq ۰, \\ ۰/۰۱\, z^{[۱]}, & z^{[۱]} < ۰, \end{cases}$$

حال مشتق هر مؤلفه نسبت به ورودی آن برابر است با:

$$\frac{\partial a^{[۱]}}{\partial z^{[۱]}} = \begin{cases} ۱, & z^{[۱]} \geq ۰, \\ ۰/۰۱, & z^{[۱]} < ۰, \end{cases}$$

بنابراین مشتق نهایی چنین خواهد بود:

$$\delta_۲ = \boxed{\frac{\partial a^{[۱]}}{\partial z^{[۱]}} = \begin{cases} ۱, & z^{[۱]} \geq ۰, \\ ۰/۰۱, & z^{[۱]} < ۰ \end{cases}}$$

چ. مشتق $\frac{\partial L}{\partial z^{[۲]}}$ را با $\delta_۰$ نشان دهید. $\frac{\partial L}{\partial b^{[۱]}}$ و $\frac{\partial L}{\partial W^{[۱]}}$ چیست؟ می‌توانید از نمادهای بخش‌های قبلی استفاده مجدد کنید. نکته: به اشکال (ابعاد) دقت کنید.

برای لایهٔ اول داشتیم:

$$z^{[۱]} = W^{[۱]}x + b^{[۱]}, \qquad a^{[۱]} = g(z^{[۱]})$$

که g همان تابع LeakyReLU است. از بخش‌های قبلی نیز داریم:

$$\delta_۰ = \frac{\partial L}{\partial z^{[۲]}} \in \mathbb{R}^{K\times ۱} \qquad \delta_۲ = \frac{\partial a^{[۱]}}{\partial z^{[۱]}} \in \mathbb{R}^{D_a\times D_a}$$

سوال مشتق تابع هزینه نسبت به وزن‌ها لایه اول را خواسته است:

$$\frac{\partial L}{\partial W^{[۱]}} \in \mathbb{R}^{D_a\times D_x}$$

پس حاصل باید به ابعاد ماتریس وزن لایه اول باشد. با در نظر گرفتن این موضوع و داشتن ابعاد ورودی و ماتریس وزن‌های لایه دوم داریم:

$$\frac{\partial L}{\partial W^{[۱]}} = \frac{\partial a^{[۱]}}{\partial z^{[۱]}} \cdot W^{[۲]^T} \cdot \frac{\partial L}{\partial z^{[۲]}} \cdot x^T \quad \Rightarrow \quad \frac{\partial L}{\partial W^{[۱]}} = \delta_۲ \cdot W^{[۲]^T} \cdot \delta_۰ \cdot x^T \in \mathbb{R}^{D_a\times D_x}$$

برای محاسبه مشتق تابع هزینه نسبت به بایاس نیز به صورت مشابه داریم:

$$\frac{\partial L}{\partial b^{[۱]}} = \frac{\partial a^{[۱]}}{\partial z^{[۱]}} \cdot W^{[۲]^T} \cdot \frac{\partial L}{\partial z^{[۲]}}$$

و با استفاده از نمادگذاری قبلی:

$$\frac{\partial L}{\partial b^{[۱]}} = \delta_۲ \cdot W^{[۲]^T} \cdot \delta_۰ \in \mathbb{R}^{D_a\times ۱}$$

برای حل این سوال از اسلاید ۹۸ مبحث MLP-Backprop درس یادگیری عمیق دکتر سلیمانی کمک گرفته شده است.

ح. برای جلوگیری از مشکلات پایداری عددی، می‌توان از یک ترفند هنگام پیاده‌سازی تابع سافت‌مکس استفاده کرد. فرض کنید $m = \max_{j=۱}^{K} z_j^{[۲]}$ حداکثر مقادیر $z_i^{[۲]}$ باشد، سپس $\hat{y}_i$ به صورت زیر محاسبه می‌شود:

$$\hat{y}_i = \frac{\exp(z_i^{[۲]} - m)}{\sum_{j=۱}^{K} \exp(z_j^{[۲]} - m)}.$$

مشکل عددی در محاسبه اولیه سافت‌مکس چیست؟ چرا فرمول تغییر یافته به حل آن مشکل کمک می‌کند؟

در فرمول اصلی سافت‌مکس داریم:

$$\hat{y}_i = \frac{\exp(z_i^{[۲]})}{\sum_{j=۱}^{K} \exp(z_j^{[۲]})}$$

اگر مقادیر $z_j^{[۲]}$ بزرگ باشند، آنگاه $\exp(z_j^{[۲]})$ اعدادی بسیار بزرگ تولید می‌کند که می‌تواند باعث سرریز عددی (overflow) شود و نتیجهٔ سافت‌مکس بی‌معنی یا ∞ گردد. به همین ترتیب، اگر $z_j^{[۲]}$ بسیار منفی باشند، خروجی $\exp(z_j^{[۲]})$ ممکن است صفر شود (underflow).
چرا فرمول تغییر یافته این مشکل را حل می‌کند؟ با کم کردن عدد m که بزرگ‌ترین مؤلفهٔ بردار است، داریم:

$$z_i^{[۲]} - m \leq ۰$$

بنابراین:

- بزرگ‌ترین مقدار نمایی برابر $\exp(۰) = ۱$ می‌شود (هیچ سرریزی رخ نمی‌دهد)،
- سایر مقادیر نیز نمایی از عدد منفی هستند و مقدارشان در بازهٔ قابل‌نمایش قرار دارد.

از آنجا که:

$$\frac{\exp(z_i - m)}{\sum_j \exp(z_j - m)} = \frac{\exp(z_i)}{\sum_j \exp(z_j)},$$

فرمول تغییر یافته از نظر ریاضی معادل سافت‌مکس اصلی است اما از نظر عددی بسیار پایدارتر است.

خ. آیا اصلاح انتقال‌ـحداکثر (max-shift) در بخش آخر، مشتق نسبت به $z^{[۲]}$ را تغییر می‌دهد؟

از آن‌جایی که:

$$\exp(z_i - m) = \frac{\exp(z_i)}{\exp(m)},$$

می‌توان نوشت:

$$\hat{y}_i = \frac{\exp(z_i)/\exp(m)}{\sum_j \exp(z_j)/\exp(m)} = \frac{\exp(z_i)}{\sum_j \exp(z_j)}$$

بنابراین خروجی سافت‌مکسِ پایدارشده **دقیقاً برابر** خروجی سافت‌مکسِ اصلی است. چون دو تابع کاملاً یکسان‌اند، مشتق آنها نیز یکسان خواهد بود:

$$\frac{\partial \hat{y}_i}{\partial z_k} \quad \text{در هر دو حالت یکسان است.}$$

به طور خلاصه، انتقالِ حداکثر، تنها یک ثابت را از تمام ورودی‌ها کم می‌کند. این ثابت در نسبت‌ها حذف می‌شود و لذا حاصل مشتق را تغییر نمی‌دهد. بنابراین $\hat{y}_i$ تغییر نمی‌کند، پس مشتق نیز تغییر نمی‌کند.

۴. (۱۲ نمره) یک شبکه عصبی برای پیاده‌سازی تابع XOR برای چهار ورودی دودویی $x_۱, x_۲, x_۳, x_۴ \in \{۰, ۱\}$ طراحی شده است. این شبکه از توابع فعال‌سازی زیر استفاده می‌کند:

$$\mathrm{ReLU}(z) = \max(۰, z) \quad , \quad \sigma(z) = \frac{۱}{۱ + e^{-z}}$$

خروجی به عنوان ۱ در نظر گرفته می‌شود اگر $y > ۰/۵$ و در غیر این صورت ۰ است. تابع هزینه، خطای مربع است:

$$L(x) = (y_{\text{هدف}} - y)^۲.$$

ساختار شبکه

$$\begin{aligned}
h_۱ &= \mathrm{ReLU}(x_۱ + x_۲),\\
h_۲ &= \mathrm{ReLU}(x_۱ + x_۲ - ۱),\\
h_۳ &= \mathrm{ReLU}(x_۳ + x_۴),\\
h_۴ &= \mathrm{ReLU}(۰/۷x_۳ + x_۴ - ۱).\\
s_۱ &= h_۱ - ۲h_۲,\\
s_۲ &= h_۳ - ۲h_۴.\\
h_۵ &= \mathrm{ReLU}(s_۱ + s_۲),\\
h_۶ &= \mathrm{ReLU}(s_۱ + s_۲ - ۱).\\
y &= \sigma(۲h_۵ - ۴h_۶ - ۱).
\end{aligned}$$

نمودار شبکه

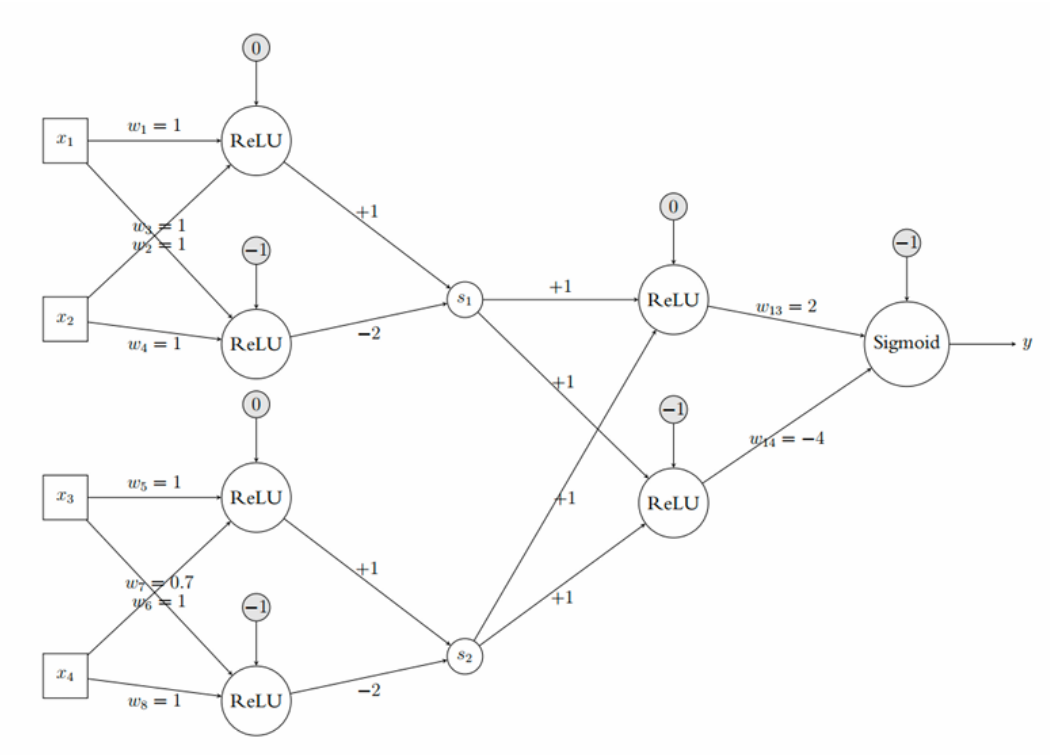

شکل ۱ : نمودار شبکه عصبی مورد استفاده در سوال

آ. تمام بردارهای ورودی $x = (x_۱, x_۲, x_۳, x_۴)$ که در آن مدل پیش‌بینی نادرست انجام می‌دهد (یعنی $y_{\text{مدل}} \neq y_{\text{هدف}}$) را شناسایی کنید.

$$x = (۰, ۰, ۱, ۱), \quad \hat{y} = ۱, \ \Pr(y = ۱) = ۰/۵۴۹۸, \quad y_{\text{هدف}} = ۰,$$
$$x = (۰, ۱, ۱, ۱), \quad \hat{y} = ۰, \ \Pr(y = ۱) = ۰/۴۵۰۱, \quad y_{\text{هدف}} = ۱,$$
$$x = (۱, ۰, ۱, ۱), \quad \hat{y} = ۰, \ \Pr(y = ۱) = ۰/۴۵۰۱, \quad y_{\text{هدف}} = ۱,$$
$$x = (۱, ۱, ۱, ۱), \quad \hat{y} = ۱, \ \Pr(y = ۱) = ۰/۸۵۸۱, \quad y_{\text{هدف}} = ۰.$$

در مجموع شبکه روی این ۴ ورودی اشتباه می‌کند. همهٔ حالاتِ اشتباه دارای $x_۳ = x_۴ = ۱$ هستند.

ب. یک گام SGD روی وزن $w_۷ = ۰/۷$ با استفاده از بردار ورودی $(x_۱, x_۲, x_۳, x_۴) = (۰, ۰, ۱, ۱)$ انجام دهید. نرخ یادگیری $\eta = ۰/۱$ را فرض کنید. مقدار جدید $w_۷$ را تعیین کنید.

طبق اطلاعات صورت سوال راجع به شبکه، یک دور مسیر forward را برای ورودی گفته شده می‌نویسیم:

$$
\begin{aligned}
h_۱ &= \mathrm{ReLU}(x_۱ + x_۲) = \mathrm{ReLU}(۰ + ۰) = ۰,\\
h_۲ &= \mathrm{ReLU}(x_۱ + x_۲ - ۱) = \mathrm{ReLU}(-۱) = ۰,\\
h_۳ &= \mathrm{ReLU}(x_۳ + x_۴) = \mathrm{ReLU}(۱ + ۱) = ۲,\\
\mathrm{pre}_{h_۴} &= w \cdot x_۳ + x_۴ - ۱ = ۰/۷ \cdot ۱ + ۱ - ۱ = ۰/۷,\\
h_۴ &= \mathrm{ReLU}(\mathrm{pre}_{h_۴}) = ۰/۷,\\
s_۱ &= h_۱ - ۲h_۲ = ۰ - ۲ \cdot ۰ = ۰,\\
s_۲ &= h_۳ - ۲h_۴ = ۲ - ۲ \cdot ۰/۷ = ۰/۶,\\
\mathrm{pre}_{h_۵} &= s_۱ + s_۲ = ۰ + ۰/۶ = ۰/۶,\\
h_۵ &= \mathrm{ReLU}(\mathrm{pre}_{h_۵}) = ۰/۶,\\
\mathrm{pre}_{h_۶} &= \mathrm{pre}_{h_۵} - ۱ = ۰/۶ - ۱ = -۰/۴,\\
h_۶ &= \mathrm{ReLU}(\mathrm{pre}_{h_۶}) = ۰
\end{aligned}
$$

خروجی لایه آخر و پیش‌فعال‌سازی سیگموئید:

$$
\begin{aligned}
z &= ۲h_۵ - ۲h_۶ - ۱ = ۲ \cdot ۰/۶ - ۲ \cdot ۰ - ۱ = ۰/۲,\\
y &= \sigma(z) = \frac{۱}{۱ + e^{-۰/۲}} \approx ۰/۵۵
\end{aligned}
$$

مسیر Backward

$$
\begin{aligned}
\frac{\partial L}{\partial y} &= ۲(y - y_{\text{target}}) = ۲y \approx ۲ \cdot ۰/۵۵ \approx ۱/۱\\
\frac{\partial y}{\partial z} &= y(۱ - y) \approx ۰/۵۵(۱ - ۰/۵۵) \approx ۰/۲۴۸
\end{aligned}
$$

مشتق نسبت به $h_۵$ و $h_۶$:

$$
\frac{\partial z}{\partial h_۵} = ۲, \qquad \frac{\partial z}{\partial h_۶} = -۲.
$$

در ورودی حاضر $h_۵$ فعال است ($\mathrm{pre}_{h_۵} = ۰/۶ > ۰$) و $h_۶$ غیرفعال است ($\mathrm{pre}_{h_۶} = -۰/۴ < ۰$). بنابراین

$$
\frac{\partial h_۵}{\partial s_۲} = ۱, \qquad \frac{\partial h_۶}{\partial s_۲} = ۰.
$$

و

$$
\frac{\partial s_۲}{\partial h_۴} = -۲, \qquad \frac{\partial h_۴}{\partial w} = \begin{cases} x_۳ & \text{if} \mathrm{pre}_{h_۴} > ۰,\\ ۰ & \text{o.w.} \end{cases}
$$

در این مورد $\mathrm{pre}_{h_۴} = ۰/۷ > ۰$ بنابراین $\frac{\partial h_۴}{\partial w} = x_۳ = ۱$

$$
\frac{\partial L}{\partial w} = \frac{\partial L}{\partial y} \cdot \frac{\partial y}{\partial z} \cdot \left(\frac{\partial z}{\partial h_۵} \frac{\partial h_۵}{\partial s_۲} + \frac{\partial z}{\partial h_۶} \frac{\partial h_۶}{\partial s_۲} \right) \cdot \frac{\partial s_۲}{\partial h_۴} \cdot \frac{\partial h_۴}{\partial w}
$$

با جایگذاری مقادیر عددی خواهیم داشت:

$$\begin{aligned}\frac{\partial L}{\partial w} &= (۲y)\cdot\big(y(۱-y)\big)\cdot\big(۲\cdot ۱+(-۲)\cdot ۰\big)\cdot(-۲)\cdot ۱\\ &= ۲y\cdot y(۱-y)\cdot ۲\cdot(-۲)\\ &= -۸\,y^{۲}(۱-y)\end{aligned}$$

$$y \approx ۰/۵۵ \quad\Rightarrow\quad \frac{\partial L}{\partial w} \approx -۱/۰۸۹$$

نحوه بروزرسانی وزن خواسته شده:

$$w_{۷}^{\text{new}} = w_{۷} - \eta\frac{\partial L}{\partial w_{۷}}$$

$$= ۰/۷ - ۰/۱\cdot(-۱/۰۸۹) = ۰/۷ + ۰/۱۰۸۹ \approx ۰/۸۰۸۹$$

۵. (۲۰ نمره) ماتریس طراحی $\mathbf{X}$ (که سطر iـام آن نقطه نمونه $\mathbf{x}_i^T$ است) و یک بردار nـتایی از برچسب‌ها $\mathbf{y} = [y_۱, \ldots, y_n]^T$ به شما داده شده است. برای سادگی، فرض کنید $\mathbf{X}$ سفید (whitened) شده است، به طوری که $\mathbf{X}^T\mathbf{X} = n\mathbf{I}$. جمله بایاس یا بعد اضافی اضافه نکنید؛ برای ورودی صفر، خروجی همیشه صفر است. فرض کنید $\mathbf{x}_{*i}$ ستون iـام ماتریس $\mathbf{X}$ را نشان می‌دهد.

آ. نشان دهید که تابع هزینه برای کمترین مربعات با تنظیم‌گر $\ell_۱$، (Lasso) یعنی:

$$J_۱(\mathbf{w}) \triangleq \|\mathbf{X}\mathbf{w}-\mathbf{y}\|^{۲} + \lambda\|\mathbf{w}\|_۱ \quad (\text{که در آن } \lambda > ۰)$$

می‌تواند به صورت زیر بازنویسی شود:

$$J_۱(\mathbf{w}) = \|\mathbf{y}\|^{۲} + \sum_{i=۱}^{d} f(\mathbf{x}_{*i}, w_i)$$

که در آن $f(\cdot,\cdot)$ یک تابع مناسب است که آرگومان اول آن یک بردار و آرگومان دوم آن یک اسکالر است.

از آنجا که ماتریس طراحی X سفید است، داریم:

$$X^\top X = nI$$

عبارت اول تابع هزینه لاسو را گسترش می‌دهیم:

$$\|X\mathbf{w}-\mathbf{y}\|^{۲} = (X\mathbf{w}-\mathbf{y})^\top(X\mathbf{w}-\mathbf{y}) = \mathbf{w}^\top X^\top X\mathbf{w} - ۲\mathbf{y}^\top X\mathbf{w} + \|\mathbf{y}\|^{۲}.$$

با جایگذاری $X^\top X = nI$:

$$\|X\mathbf{w}-\mathbf{y}\|^{۲} = n\|\mathbf{w}\|^{۲} - ۲\sum_{i=۱}^{d} w_i\,\mathbf{y}^\top x_{*i} + \|\mathbf{y}\|^{۲}.$$

پس:

$$J_\lambda(\mathbf{w}) = \|\mathbf{y}\|^{۲} + \sum_{i=۱}^{d}\left(nw_i^{۲} - ۲w_i\,\mathbf{y}^\top x_{*i} + \lambda|w_i|\right).$$

با تعریف

$$f(x_{*i}, w_i) = nw_i^{۲} - ۲w_i\,\mathbf{y}^\top x_{*i} + \lambda|w_i|,$$

فرم خواسته‌شده به دست می‌آید:

$$J_\lambda(\mathbf{w}) = \|\mathbf{y}\|^{۲} + \sum_{i=۱}^{d} f(x_{*i}, w_i).$$

ب. با استفاده از پاسخ خود به بخش (آ)، شرایط لازم و کافی برای مولفه iـام بهینه‌ساز $\mathbf{w}^*$ تابع $J_۱(\cdot)$ را استخراج کنید به طوری که هر یک از سه خاصیت زیر را برآورده کند: $w_i^* > ۰$، $w_i^* = ۰$ و $w_i^* < ۰$.

تابع جزء برای متغیر w_i برابر است با:

$$f(w_i) = nw_i^{۲} - ۲w_i\,\mathbf{y}^\top x_{*i} + \lambda|w_i|$$

که مشتق آن برای

حالت $w_i > ۰$:

$$۲nw_i - ۲\mathbf{y}^\top x_{*i} + \lambda = ۰$$

$$w_i{}^* = \frac{\mathbf{y}^\top x_{*i} - \lambda/۲}{n}, \quad \mathbf{y}^\top x_{*i} > \frac{\lambda}{۲}.$$

حالت $w_i < ۰$:

$$۲nw_i - ۲\mathbf{y}^\top x_{*i} - \lambda = ۰$$

$$w_i{}^* = \frac{\mathbf{y}^\top x_{*i} + \lambda/۲}{n}, \quad \mathbf{y}^\top x_{*i} < -\frac{\lambda}{۲}.$$

حالت $w_i = ۰$:

$$-\frac{\lambda}{۲} \le \mathbf{y}^\top x_{*i} \le \frac{\lambda}{۲}.$$

نتیجه نهایی:

$$w_i{}^* = \begin{cases} \frac{۱}{n}\left(\mathbf{y}^\top x_{*i} - \frac{\lambda}{۲}\right), & \mathbf{y}^\top x_{*i} > \frac{\lambda}{۲}, \\ ۰, & \left|\mathbf{y}^\top x_{*i}\right| \le \frac{\lambda}{۲}, \\ \frac{۱}{n}\left(\mathbf{y}^\top x_{*i} + \frac{\lambda}{۲}\right), & \mathbf{y}^\top x_{*i} < -\frac{\lambda}{۲} \end{cases}$$

پ. برای بهینه‌ساز $\mathbf{w}^{\#}$ تابع هزینه کمترین مربعات با تنظیم‌گر $\ell_۲$، (Ridge) یعنی:

$$J_۲(\mathbf{w}) \triangleq \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^{۲} + \lambda\|\mathbf{w}\|_۲^۲ \quad (\text{که در آن } \lambda > ۰)$$

یک شرط لازم و کافی برای $w_i^{\#} = ۰$ استخراج کنید، که در آن $w_i^{\#}$ مولفه iـام بردار $\mathbf{w}^{\#}$ است.

برای تابع هزینه ریج داریم:

$$J_۲(\mathbf{w}) \triangleq \|X\mathbf{w} - \mathbf{y}\|^{۲} + \lambda\|\mathbf{w}\|_۲^۲, \qquad (\lambda > ۰)$$

و می‌خواهیم شرط لازم و کافی برای صفر بودن مؤلفه‌ی $w_i^{\#}$ را استخراج کنیم. مجددا عبارت اول را بسط می‌دهیم:

$$\|X\mathbf{w} - \mathbf{y}\|^{۲} = (X\mathbf{w} - \mathbf{y})^\top (X\mathbf{w} - \mathbf{y})$$

$$= \mathbf{w}^\top X^\top X\mathbf{w} - ۲\mathbf{y}^\top X\mathbf{w} + \mathbf{y}^\top\mathbf{y}$$

بنابراین:

$$J_۲(\mathbf{w}) = \mathbf{w}^\top X^\top X\mathbf{w} - ۲\mathbf{y}^\top X\mathbf{w} + \|\mathbf{y}\|^۲ + \lambda\mathbf{w}^\top\mathbf{w}.$$

ترم‌های درجه دوم را ترکیب می‌کنیم:

$$J_۲(\mathbf{w}) = \mathbf{w}^\top(X^\top X + \lambda I)\mathbf{w} - ۲\mathbf{y}^\top X\mathbf{w} + \|\mathbf{y}\|^۲$$

چون ماتریس $X^\top X + \lambda I$ متقارن است:

$$\nabla_{\mathbf{w}}\left(\mathbf{w}^\top(X^\top X + \lambda I)\mathbf{w}\right) = ۲(X^\top X + \lambda I)\mathbf{w}$$

همچنین:

$$\nabla_{\mathbf{w}}(-۲\mathbf{y}^\top X\mathbf{w}) = -۲X^\top\mathbf{y}$$

پس:

$$\nabla_{\mathbf{w}} J_۲(\mathbf{w}) = ۲(X^\top X + \lambda I)\mathbf{w} - ۲X^\top\mathbf{y} = ۰$$
$$(X^\top X + \lambda I)\mathbf{w} = X^\top\mathbf{y}$$

چون $\lambda > ۰$، ماتریس $(X^\top X + \lambda I)$ مثبت‌ـمعین و وارون‌پذیر است. بنابراین:

$$\mathbf{w}^\# = (X^\top X + \lambda I)^{-۱}X^\top\mathbf{y} = \frac{۱}{n+\lambda}X^\top\mathbf{y}$$

پس داریم:

$$w_i^\# = \frac{۱}{n+\lambda}\mathbf{y}^\top x_{*i}$$

اکنون شرط لازم و کافی برای صفر شدن این مولفه:

$$w_i^\# = ۰ \quad\Longleftrightarrow\quad \frac{۱}{n+\lambda}\mathbf{y}^\top x_{*i} = ۰ \quad\Longleftrightarrow\quad \mathbf{y}^\top x_{*i} = ۰$$

ت. یک بردار را تُنُک[۹] می‌نامیم اگر بیشتر مولفه‌های آن صفر باشند. بر اساس پاسخ‌های خود به بخش‌های (ب) و (پ)، کدام یک از بردارهای $\mathbf{w}^*$ و $\mathbf{w}^\#$ به احتمال زیاد تُنُک‌تر است؟ چرا؟

با توجه به نتایج بخش‌های (ب) و (پ)، می‌توانیم تعیین کنیم کدام یک از دو بردار $\mathbf{w}^*$ (لاسو) و $\mathbf{w}^\#$ (ریج) با احتمال بیشتری تنک است. در بخش (ب) نشان دادیم که در لاسو داریم:

$$w_i{}^* = ۰ \quad\Longleftrightarrow\quad |\mathbf{y}^\top x_{*i}| \le \frac{\lambda}{۲}$$

این شرط یک ناحیه‌ی بازه‌ای است؛ یعنی مجموعه‌ی بزرگی از مقادیر $\mathbf{y}^\top x_{*i}$ منجر به صفر شدن w_i می‌شود. بنابراین لاسو ذاتاً وزن‌ها را به صفر **فشرده** می‌کند و بردارهای تنک تولید می‌کند. اما در بخش (پ) برای ریج به دست آوردیم:

$$w_i^\# = \frac{۱}{n+\lambda}\mathbf{y}^\top x_{*i},$$

و لذا:

$$w_i^\# = ۰ \quad\Longleftrightarrow\quad \mathbf{y}^\top x_{*i} = ۰$$

این یک نقطه است نه یک بازه؛ بنابراین تنها در شرایط بسیار خاص (و با احتمال بسیار کم) یک وزن دقیقاً صفر می‌شود. در نتیجه ریج **تنک‌کننده نیست**. پس بردار $\mathbf{w}$ حاصل از لاسو بسیار محتمل‌تر از $\mathbf{w}^\#$ (ریج) تنک است،

چون لاسو باعث اعمال آستانه‌گذاری و صفر کردن وزن‌ها می‌شود.

۶. (۱۰ نمره) تابع هزینه یک مدل $J(\theta)$ دارای حداقل‌های محلی است و می‌خواهیم از الگوریتم کاهش شیب تصادفی (SGD) برای بهینه‌سازی پارامترهای آن (θ) استفاده کنیم. فرض کنید از یک نرخ یادگیری با کاهش نمایی[۱۰] به شکل زیر استفاده می‌کنیم:

$$\alpha_t = \alpha_۰ e^{-kt}$$

که در آن t شماره گام (epoch) است. نرخ یادگیری اولیه $\alpha_۰ = ۰/۱$ و ضریب کاهش $k = ۰/۰۵$ داده شده است.

آ. قاعده به‌روزرسانی پارامترها (θ) را با استفاده از SGD بنویسید.

در الگوریتم **کاهش شیب تصادفی (SGD)**، پارامترهای مدل θ در هر گام به‌روزرسانی بر اساس گرادیان تابع هزینه نسبت به یک نمونه تصادفی (یا یک زیرمجموعه از داده‌ها) انجام می‌شود. قاعده کلی به‌روزرسانی در گام t به صورت زیر است:

$$\theta_{t+۱} = \theta_t - \alpha_t \nabla_\theta J_i(\theta_t)$$

که در آن:

- θ_t: پارامترها در گام tام،
- α_t: نرخ یادگیری در گام tام،
- $\nabla_\theta J_i(\theta_t)$: گرادیان تابع هزینه برای نمونه iام.

نرخ یادگیری به صورت کاهش نمایی داده شده است:

$$\alpha_t = \alpha_۰ e^{-kt}$$

با توجه به اطلاعات داده‌شده:

$$\alpha_۰ = ۰/۱, \quad k = ۰/۰۵$$

پس:

$$\alpha_t = ۰/۱ \cdot e^{-۰/۰۵t}$$

با جایگذاری α_t در فرمول اصلی، قاعده به‌روزرسانی پارامترها به صورت زیر خواهد بود:

$$\boxed{\theta_{t+۱} = \theta_t - ۰/۱ \cdot e^{-۰/۰۵t} \cdot \nabla_\theta J_i(\theta_t)}$$

ب. به صورت مفهومی توضیح دهید که چرا استفاده از نرخ یادگیری متغیر با کاهش[۱۱] می‌تواند هم به سرعت همگرایی و هم به پایداری فرآیند آموزش کمک کند.

استفاده از نرخ یادگیری متغیر با کاهش تدریجی (مانند کاهش نمایی) در الگوریتم SGD دو مزیت اصلی را همزمان فراهم می‌کند: در مراحل **اولیه آموزش**، نرخ یادگیری نسبتاً بزرگ، امکان حرکت سریع به سمت ناحیه بهینه را فراهم کرده و سرعت همگرایی را افزایش می‌دهد؛ در مراحل **پایانی**، با کاهش نرخ یادگیری، گام‌های به‌روزرسانی کوچک‌تر می‌شوند و این امر موجب پایداری فرآیند و جلوگیری از نوسان یا پرت شدن از نقطه بهینه می‌گردد.

پ. اگر الگوریتم در یک ناحیه با شیب تند از تابع هزینه قرار گیرد، رفتار آن را با نرخ یادگیری ثابت در مقایسه با نرخ یادگیری دارای کاهش تحلیل و مقایسه کنید. این دو رویکرد چه تفاوتی در مسیر رسیدن به نقطه بهینه دارند؟

در مواجهه با **نواحی با شیب تند**، نرخ یادگیری ثابت ممکن است به دلیل بزرگ بودن همزمان گرادیان و نرخ یادگیری، گام‌های بزرگی ایجاد کند که سبب پرش از دره بهینه یا نوسان شدید حول آن شود؛ درحالی‌که در نرخ یادگیری کاهشی، با

رسیدن به این نواحی (که معمولاً در مراحل بعدی آموزش رخ می‌دهد)، مقدار نرخ یادگیری به‌طور خودکار کاهش یافته و گام‌ها کنترل‌شده‌تر می‌شوند. در نتیجه، نرخ یادگیری کاهشی، **مسیر همگرایی نرم‌تر و مستقیم‌تری** به سمت بهینه سراسری ایجاد می‌کند، در حالی که نرخ یادگیری ثابت ممکن است به مسیری نوسانی یا ناپایدار منجر شود که نیازمند تنظیم دقیق دستی بوده و ریسک گیرکردن در بهینه‌های محلی یا گذر از نقطه بهینه را افزایش می‌دهد.

ت. یکی از شرایط کلاسیک برای تضمین همگرایی SGD (تحت فروض مشخص)، شرایط رابینز-مونرو[۱۲] برای نرخ یادگیری α_t است:

$$\sum_{t=1}^{\infty} \alpha_t = \infty \quad \text{و} \quad \sum_{t=1}^{\infty} \alpha_t^2 < \infty$$

بررسی کنید که آیا نرخ یادگیری با کاهش نمایی ($\alpha_t = \alpha_0 e^{-kt}$) در این شرایط صدق می‌کند یا خیر. برای تحلیل می‌توانید از تقریب انتگرال برای سری‌ها استفاده کنید. نتیجه‌ای که به دست می‌آورید چه مفهومی در مورد تضمین همگرایی این نوع نرخ یادگیری دارد؟

$$\sum_{t=1}^{\infty} \alpha_t = \alpha_0 \sum_{t=1}^{\infty} e^{-kt}$$

این یک سری هندسی با قدر نسبت $r = e^{-k}$ است ($0 < r < 1$):

$$\sum_{t=1}^{\infty} e^{-kt} = \frac{e^{-k}}{1 - e^{-k}}$$

که مقدار آن متناهی است. بنابراین:

$$\sum_{t=1}^{\infty} \alpha_t = \alpha_0 \cdot \frac{e^{-k}}{1 - e^{-k}} < \infty$$

شرط اول **برقرار نیست**، زیرا مجموع متناهی است. برای شرط دوم داریم:

$$\alpha_t^2 = \alpha_0^2 e^{-2kt}$$

$$\sum_{t=1}^{\infty} \alpha_t^2 = \alpha_0^2 \sum_{t=1}^{\infty} e^{-2kt}$$

این هم یک سری هندسی با $r' = e^{-2k}$ است:

$$\sum_{t=1}^{\infty} e^{-2kt} = \frac{e^{-2k}}{1 - e^{-2k}} < \infty$$

شرط دوم **برقرار است**.

با تقریب انتگرال:

$$\sum_{t=1}^{\infty} e^{-kt} \approx \int_1^{\infty} e^{-kx} dx = \frac{1}{k} e^{-k}$$

$$\sum_{t=1}^{\infty} e^{-2kt} \approx \int_1^{\infty} e^{-2kx} dx = \frac{1}{2k} e^{-2k}$$

که هر دو انتگرال‌ها همگرا (متناهی) هستند. این تأیید می‌کند که شرط اول برقرار نیست. از آنجا که شرط اول رابینز-مونرو (مجموع نامتناهی نرخ یادگیری) برقرار نیست، همگرایی قطعی SGD با نرخ یادگیری نمایی خالص $\alpha_t = \alpha . e^{-kt}$ تضمین‌شده نیست. این نوع نرخ یادگیری ممکن است **قبل از رسیدن به بهینه دقیق**، آنقدر کوچک شود که به‌روزرسانی‌ها تقریباً متوقف گردند و الگوریتم در نقطه‌ای غیر از بهینه متوقف شود.

۷. (۱۳ نمره) فرض کنید یک لایه نرمال‌سازی دسته‌ای[۱۳] یک‌بعدی روی یک Mini-batch با اندازه m اعمال می‌شود. ورودی‌های اسکالر برای یک نورون خاص را با $x_1, \ldots, x_m$ نمایش می‌دهیم. لایه BN آماره‌ها و خروجی‌ها را به صورت زیر محاسبه می‌کند:

$$\mu_B = \frac{1}{m}\sum_{i=1}^{m} x_i$$
$$\sigma_B^2 = \frac{1}{m}\sum_{i=1}^{m}(x_i - \mu_B)^2$$
$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}$$
$$y_i = \gamma \hat{x}_i + \beta$$

که در آن γ و β پارامترهای قابل یادگیری هستند و ϵ یک عدد کوچک ثابت برای پایداری عددی است. تابع هزینه L تابعی از خروجی‌های $y_1, \ldots, y_m$ است و گرادیان نسبت به خروجی‌ها $g_i := \frac{\partial L}{\partial y_i}$ می‌باشد.

آ. با استفاده از قاعده زنجیره‌ای، فرمول بسته‌ای برای گرادیان‌های $\frac{\partial L}{\partial \gamma}$ و $\frac{\partial L}{\partial \beta}$ بر حسب g_i و $\hat{x}_i$ به دست آورید.

$$\frac{\partial L}{\partial \beta} = \sum_{i=1}^{m} \frac{\partial L}{\partial y_i}\frac{\partial y_i}{\partial \beta}$$

از آنجا که:

$$y_i = \gamma \hat{x}_i + \beta \quad \Rightarrow \quad \frac{\partial y_i}{\partial \beta} = 1$$

پس:

$$\frac{\partial L}{\partial \beta} = \sum_{i=1}^{m} \frac{\partial L}{\partial y_i} \cdot 1$$

$$\boxed{\frac{\partial L}{\partial \beta} = \sum_{i=1}^{m} g_i}$$

گرادیان نسبت به γ

$$\frac{\partial L}{\partial \gamma} = \sum_{i=1}^{m} \frac{\partial L}{\partial y_i}\frac{\partial y_i}{\partial \gamma}$$

از آنجا که:

$$\frac{\partial y_i}{\partial \gamma} = \hat{x}_i$$

پس:

$$\frac{\partial L}{\partial \gamma} = \sum_{i=1}^{m} \frac{\partial L}{\partial y_i} \cdot \hat{x}_i$$

$$\boxed{\frac{\partial L}{\partial \gamma} = \sum_{i=1}^{m} g_i \hat{x}_i}$$

ب. گرادیان $\frac{\partial L}{\partial x_i}$ را برای هر i محاسبه کنید. توجه داشته باشید که μ_B و σ_B^2 توابعی از تمام x_jها هستند. پاسخ نهایی باید تنها بر حسب x_i، μ_B، σ_B^2، ϵ، γ و g_j باشد. هدف رسیدن به رابطه زیر است:

$$\frac{\partial L}{\partial x_i} = \frac{\gamma}{\sqrt{\sigma_B^2 + \epsilon}} \left(g_i - \frac{1}{m} \sum_{j=1}^{m} g_j - \frac{\hat{x}_i}{m} \sum_{j=1}^{m} g_j \hat{x}_j \right)$$

راهنمایی: ابتدا $\frac{\partial L}{\partial \hat{x}_i}$ را بر حسب g_i و γ بنویسید، سپس گرادیان‌ها را از طریق $\hat{x}_i$، μ_B و σ_B^2 به عقب منتقل کنید.

از رابطه‌ی خروجی داریم:

$$\frac{\partial L}{\partial \hat{x}_i} = \frac{\partial L}{\partial y_i} \frac{\partial y_i}{\partial \hat{x}_i} = \gamma g_i$$

برای سادگی، تعریف می‌کنیم:

$$\delta_i := \frac{\partial L}{\partial \hat{x}_i} = \gamma g_i$$

از آن‌جا که $\hat{x}_k$ به تمام x_iها وابسته است، داریم:

$$\frac{\partial L}{\partial x_i} = \sum_{k=1}^{m} \frac{\partial L}{\partial \hat{x}_k} \frac{\partial \hat{x}_k}{\partial x_i} = \sum_{k=1}^{m} \delta_k \frac{\partial \hat{x}_k}{\partial x_i}$$

$$\mu_B = \frac{1}{m} \sum_{j=1}^{m} x_j \quad \Rightarrow \quad \frac{\partial \mu_B}{\partial x_i} = \frac{1}{m}$$

$$\sigma_B^2 = \frac{1}{m} \sum_{j=1}^{m} (x_j - \mu_B)^2$$

با استفاده از خاصیت:

$$\sum_{j=1}^{m} (x_j - \mu_B) = 0$$

داریم:

$$\frac{\partial \sigma_B^2}{\partial x_i} = \frac{2}{m}(x_i - \mu_B)$$

تعریف می‌کنیم:

$$s := \sqrt{\sigma_B^2 + \epsilon}$$

آنگاه:

$$\frac{\partial s}{\partial x_i} = \frac{1}{2} s^{-1} \frac{\partial \sigma_B^2}{\partial x_i} = \frac{x_i - \mu_B}{ms}$$

برای محاسبه مشتق $\hat{x}_k$ نسبت به x_i داریم: بنابراین:

$$\frac{\partial \hat{x}_k}{\partial x_i} = \frac{1}{s} \left(\delta_{ik} - \frac{1}{m} \right) - \frac{(x_k - \mu_B)(x_i - \mu_B)}{ms^3}$$

که با استفاده از:

$$\hat{x}_k = \frac{x_k - \mu_B}{s}$$

به‌صورت زیر بازنویسی می‌شود:

$$\frac{\partial \hat{x}_k}{\partial x_i} = \frac{۱}{s}\left(\delta_{ik} - \frac{۱}{m}\right) - \frac{\hat{x}_k \hat{x}_i}{ms}$$

$$\frac{\partial L}{\partial x_i} = \sum_{k=۱}^{m} \delta_k \left[\frac{۱}{s}\left(\delta_{ik} - \frac{۱}{m}\right) - \frac{\hat{x}_k \hat{x}_i}{ms}\right]$$

فاکتورگیری از $\frac{۱}{s}$:

$$\frac{\partial L}{\partial x_i} = \frac{۱}{s}\left[\delta_i - \frac{۱}{m}\sum_{k=۱}^{m}\delta_k - \frac{\hat{x}_i}{m}\sum_{k=۱}^{m}\delta_k \hat{x}_k\right]$$

جایگذاری $\delta_k = \gamma g_k$:

$$\boxed{\frac{\partial L}{\partial x_i} = \frac{\gamma}{\sqrt{\sigma_B^۲ + \epsilon}}\left(g_i - \frac{۱}{m}\sum_{k=۱}^{m} g_k - \frac{\hat{x}_i}{m}\sum_{k=۱}^{m} g_k \hat{x}_k\right)}$$

پ. با استفاده از رابطه‌ای که در قسمت (ب) به دست آوردید، به صورت تحلیلی ثابت کنید که:

$$\sum_{i=۱}^{m} \frac{\partial L}{\partial x_i} = ۰$$

در یک یا دو جمله توضیح دهید که این ویژگی چه مفهوم شهودی‌ای در مورد رفتار لایه BN نسبت به شیفت دادن تمام ورودی‌های دسته با یک مقدار ثابت (مثلاً $x_i \leftarrow x_i + c$) دارد.

$$\sum_{i=۱}^{m} \frac{\partial L}{\partial x_i} = \frac{\gamma}{\sqrt{\sigma_B^۲ + \epsilon}} \sum_{i=۱}^{m}\left(g_i - \frac{۱}{m}\sum_{j=۱}^{m} g_j - \frac{\hat{x}_i}{m}\sum_{j=۱}^{m} g_j \hat{x}_j\right)$$

$$= \frac{\gamma}{\sqrt{\sigma_B^۲ + \epsilon}}\left[\sum_{i=۱}^{m} g_i - \sum_{i=۱}^{m}\frac{۱}{m}\sum_{j=۱}^{m} g_j - \sum_{i=۱}^{m}\frac{\hat{x}_i}{m}\sum_{j=۱}^{m} g_j \hat{x}_j\right]$$

جمله دوم را بازنویسی می‌کنیم:

$$\sum_{i=۱}^{m}\frac{۱}{m}\sum_{j=۱}^{m} g_j = \frac{۱}{m}\sum_{j=۱}^{m} g_j \sum_{i=۱}^{m} ۱ = \sum_{j=۱}^{m} g_j$$

همچنین برای جمله سوم داریم:

$$\sum_{i=۱}^{m}\frac{\hat{x}_i}{m}\sum_{j=۱}^{m} g_j \hat{x}_j = \frac{۱}{m}\sum_{j=۱}^{m} g_j \hat{x}_j \sum_{i=۱}^{m} \hat{x}_i$$

اما از تعریف Normalization Batch می‌دانیم:

$$\sum_{i=۱}^{m} \hat{x}_i = ۰$$

پس کل جمله سوم برابر صفر می‌شود. با جایگذاری نتایج:

$$\sum_{i=1}^{m} \frac{\partial L}{\partial x_i} = \frac{\gamma}{\sqrt{\sigma_B^2 + \epsilon}} \left(\sum_{i=1}^{m} g_i - \sum_{j=1}^{m} g_j - 0 \right) = 0$$

بنابراین:

$$\boxed{\sum_{i=1}^{m} \frac{\partial L}{\partial x_i} = 0}$$

Normalization Batch نسبت به شیفت یکسان همهٔ ورودی‌ها ناوردا است؛ یعنی اگر به تمام x_iها یک مقدار ثابت اضافه شود، خروجی نرمال‌شده تغییر نمی‌کند. در نتیجه، تابع هزینه در جهت بردار $(1, 1, \ldots, 1)$ حساسیتی ندارد و به‌طور طبیعی مجموع گرادیان‌ها نسبت به ورودی‌ها صفر می‌شود.