دانشگاه صنعتی شریف
دانشکده‌ی مهندسی کامپیوتر

یادگیری ماشین

پاییز و زمستان ۱۴۰۴

استاد: علی شریفی زارچی

گردآورندگان:

تمرین چهارم | موضوع | مهلت ارسال: ۱۹ دی

سوالات نظری (۱۰۰ نمره)

۱. (۲۲ نمره) وقتی شبکه‌های عصبی بسیار عمیق می‌شوند، آموزش ممکن است به دلیل مشکل محو شدن گرادیان غیرممکن شود. ResNet این مسئله را با استفاده از skip connections حل می‌کند که به جریان بهتر گرادیان کمک می‌کنند.

محاسبات زیر را برای یک بلوک residual واحد در نظر بگیرید:

$$\begin{aligned}
\mathbf{z}_1 &= \mathbf{W}_1\mathbf{x} + \mathbf{b}_1 \\
\mathbf{h}_1 &= \mathrm{ReLU}(\mathbf{z}_1) \\
\mathbf{d} &= \mathbf{h}_1 + \mathbf{x} \\
\mathbf{z}_2 &= \mathbf{W}_2\mathbf{d} + \mathbf{b}_2 \\
\mathbf{h}_2 &= \mathrm{ReLU}(\mathbf{z}_2) \\
\boldsymbol{\theta} &= \mathbf{h}_2 + \mathbf{d} \\
\hat{\mathbf{y}} &= \mathrm{softmax}(\boldsymbol{\theta}) \\
J &= \mathrm{CE}(\mathbf{y}, \hat{\mathbf{y}})
\end{aligned}$$

فرض کنید $\mathbf{x}, \mathbf{d}, \boldsymbol{\theta} \in \mathbb{R}^{H\times 1}$ و $\mathbf{W}_1, \mathbf{W}_2 \in \mathbb{R}^{H\times H}$ باشند.

آ. $\boldsymbol{\delta}_\theta = \dfrac{\partial J}{\partial \boldsymbol{\theta}}$ و $\boldsymbol{\delta}_1 = \dfrac{\partial J}{\partial \mathbf{z}_1}$ را بیابید.

هدف ما محاسبه مشتق جزئی تابع هزینه J نسبت به مولفه kـام از بردار ورودی $\boldsymbol{\theta}$ است. طبق قاعده زنجیره‌ای داریم:

$$\frac{\partial J}{\partial \theta_k} = \sum_i \frac{\partial J}{\partial \hat{y}_i}\frac{\partial \hat{y}_i}{\partial \theta_k}$$

برای محاسبه مشتق تابع هزینه نسبت به خروجی ($\frac{\partial J}{\partial \hat{y}_i}$) با فرض استفاده از تابع هزینه Cross-Entropy داریم:

$$J = -\sum_i y_i \log(\hat{y}_i) \implies \frac{\partial J}{\partial \hat{y}_i} = -\frac{y_i}{\hat{y}_i}$$

برای محاسبه مشتق سافت‌مکس نسبت به لاجیت ($\frac{\partial \hat{y}_i}{\partial \theta_k}$) با توجه به فرمول سافت‌مکس $\hat{y}_i = \frac{e^{\theta_i}}{\sum_j e^{\theta_j}}$، دو حالت رخ می‌دهد:

- **حالت اول ($i = k$):**

$$\frac{\partial \hat{y}_k}{\partial \theta_k} = \frac{e^{\theta_k}(\sum e^{\theta_j}) - e^{\theta_k}(e^{\theta_k})}{(\sum e^{\theta_j})^2} = \hat{y}_k(1 - \hat{y}_k)$$

- **حالت دوم ($i \neq k$):**

$$\frac{\partial \hat{y}_i}{\partial \theta_k} = \frac{۰ - e^{\theta_i}(e^{\theta_k})}{(\sum e^{\theta_j})^۲} = -\hat{y}_i \hat{y}_k$$

با استفاده از دلتای کرونکر (δ_{ik})، این دو حالت ادغام می‌شوند:

$$\frac{\partial \hat{y}_i}{\partial \theta_k} = \hat{y}_i(\delta_{ik} - \hat{y}_k)$$

با جایگذاری نتایج گام‌های قبلی در رابطه اول خواهیم داشت:

$$\begin{aligned}
\frac{\partial J}{\partial \theta_k} &= \sum_i \left(-\frac{y_i}{\hat{y}_i}\right)(\hat{y}_i(\delta_{ik} - \hat{y}_k)) \\
&= -\sum_i y_i(\delta_{ik} - \hat{y}_k) \\
&= \sum_i y_i \hat{y}_k - \sum_i y_i \delta_{ik}
\end{aligned}$$

با توجه به اینکه $\sum_i y_i = ۱$ و $\sum_i y_i \delta_{ik} = y_k$، نتیجه نهایی برای یک مولفه و سپس فرم برداری به دست می‌آید:

$$\frac{\partial J}{\partial \theta_k} = \hat{y}_k - y_k \implies \boxed{\frac{\partial J}{\partial \boldsymbol{\theta}} = \hat{\mathbf{y}} - \mathbf{y}}$$

برای محاسبه $\delta_{z_۱} = \frac{\partial J}{\partial z_۱}$ ابتدا گرادیان را به عقب منتشر می‌کنیم.

$$\theta = h_۲ + d \quad \implies \quad \frac{\partial J}{\partial h_۲} = \delta_\theta, \qquad \left.\frac{\partial J}{\partial d}\right|_{\text{skip}} = \delta_\theta$$

عبور از ReLU دوم

$$\begin{aligned}
h_۲ &= \mathrm{ReLU}(z_۲) \\
\delta_{z_۲} &= \delta_\theta \odot ۱_{z_۲ > ۰}
\end{aligned}$$

عبور از لایه خطی دوم

$$\begin{aligned}
z_۲ &= W_۲ d + b_۲ \\
\left.\frac{\partial J}{\partial d}\right|_{\text{main}} &= W_۲^\top \delta_{z_۲}
\end{aligned}$$

جمع گرادیان‌های مسیر residual

$$\delta_d = \frac{\partial J}{\partial d} = \delta_\theta + W_۲^\top \delta_{z_۲}$$

عبور از ReLU اول

$$\begin{aligned}
h_۱ &= \mathrm{ReLU}(z_۱) \\
\delta_{z_۱} &= \delta_d \odot ۱_{z_۱ > ۰}
\end{aligned}$$

$$\boxed{\delta_{z_۱} = \left(\delta_\theta + W_۲^\top (\delta_\theta \odot ۱_{z_۲ > ۰})\right) \odot ۱_{z_۱ > ۰}}$$

ب. $\boldsymbol{\delta}_۲ = \dfrac{\partial J}{\partial \mathbf{z}_۲}$ را بیابید.

این رابطه ضمن حل قسمت قبل هم محاسبه شده است. برای محاسبه مجدد آن در این بخش، از خروجی به سمت عقب حرکت می‌کنیم. از آنجا که $\boldsymbol{\theta} = \mathbf{h}_۲ + \mathbf{d}$، مشتق J نسبت به $\mathbf{h}_۲$ همان δ_θ است. حال با عبور از تابع ReLU:

$$\delta_۲ = \frac{\partial J}{\partial \mathbf{z}_۲} = \frac{\partial J}{\partial \mathbf{h}_۲} \odot \mathrm{ReLU}'(\mathbf{z}_۲) = \delta_\theta \odot \mathbb{I}(\mathbf{z}_۲ > ۰)$$

پ. $\boldsymbol{\delta}_d = \dfrac{\partial J}{\partial \mathbf{d}}$ را محاسبه کنید.

این رابطه ضمن حل قسمت الف هم محاسبه شده است. متغیر $\mathbf{d}$ در دو مسیر حضور دارد: یکی به عنوان بخشی از جمع در $\boldsymbol{\theta}$ و دیگری به عنوان ورودی برای $\mathbf{z}_۲$. طبق قاعده زنجیره‌ای برای توابع چندمتغیره:

$$\delta_d = \frac{\partial J}{\partial \boldsymbol{\theta}} \frac{\partial \boldsymbol{\theta}}{\partial \mathbf{d}} + \frac{\partial J}{\partial \mathbf{z}_۲} \frac{\partial \mathbf{z}_۲}{\partial \mathbf{d}}$$

با جایگذاری مقادیر ($\frac{\partial \boldsymbol{\theta}}{\partial \mathbf{d}} = \mathbf{I}$ و $\frac{\partial \mathbf{z}_۲}{\partial \mathbf{d}} = \mathbf{W}_۲$):

$$\delta_d = \delta_\theta + \mathbf{W}_۲^T \delta_۲$$

ت. با استفاده از نتایج قبلی، $\dfrac{\partial J}{\partial \mathbf{x}}$ را محاسبه کنید.

مشابه مرحله قبل، ورودی $\mathbf{x}$ هم در دو مسیر نقش دارد: یکی در محاسبه $\mathbf{z}_۱$ و دیگری در اتصال کوتاه برای تشکیل $\mathbf{d}$.

$$\frac{\partial J}{\partial \mathbf{x}} = \frac{\partial J}{\partial \mathbf{d}} \frac{\partial \mathbf{d}}{\partial \mathbf{x}} + \frac{\partial J}{\partial \mathbf{z}_۱} \frac{\partial \mathbf{z}_۱}{\partial \mathbf{x}}$$

با توجه به اینکه $\frac{\partial \mathbf{d}}{\partial \mathbf{x}} = \mathbf{I}$ و $\frac{\partial \mathbf{z}_۱}{\partial \mathbf{x}} = \mathbf{W}_۱$:

$$\frac{\partial J}{\partial \mathbf{x}} = \delta_d + \mathbf{W}_۱^T \delta_۱$$

۲. (۱۶ نمره)

یکی دیگر از مشکلاتی که در ارتباط با شبکه‌های ژرف وجود دارد، تعداد بالای پارامترها و پیچیدگی بالای محاسباتی است. این مشکل استفاده از شبکه‌های CNN روی دستگاه‌های کوچک با پردازنده‌های محدود (مانند تلفن همراه) را با دشواری‌هایی همراه می‌سازد. برای حل این مشکل، شبکه‌ی MobileNet ارائه شده است. شبکه‌ی MobileNet-V1 از کانولوشن عمقی (Depthwise) استفاده می‌کند که تعداد پارامترها و پیچیدگی زمانی را کاهش دهد.

آ. در شکل ۱ یک پیمانه از شبکه‌ی MobileNet-V1 (بالا) و یک لایه‌ی کانولوشن معمولی از شبکه‌ی CNN (پایین) نمایش داده شده است. در هر روش، تعداد پارامترها قابل آموزش را محاسبه کنید.

ب. در شبکه‌ی MobileNet-V2 از دو فیلتر کانولوشن ۱ × ۱ استفاده شده است. شمای کلی معماری استفاده‌شده از این شبکه در شکل ۲ نشان داده شده است. با محاسبه‌ی تعداد پارامترها برای این شبکه، آن را با MobileNet-V1 مقایسه نمایید.

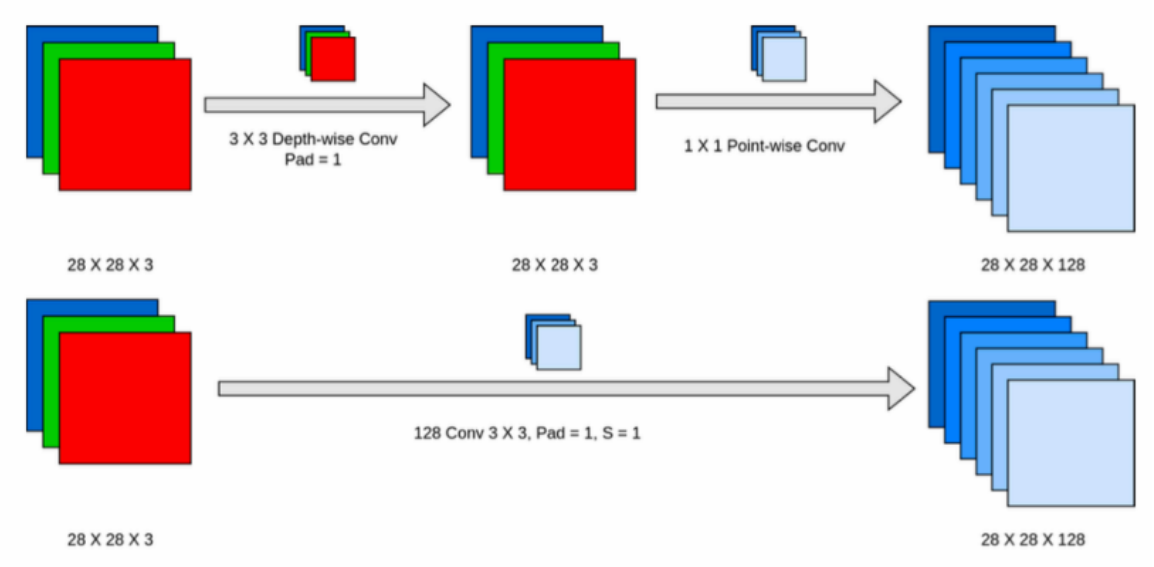

شکل ۱: یک پیمانه از شبکه‌ی MobileNet-V1 (بالا) و یک لایه‌ی کانولوشن معمولی (پایین).

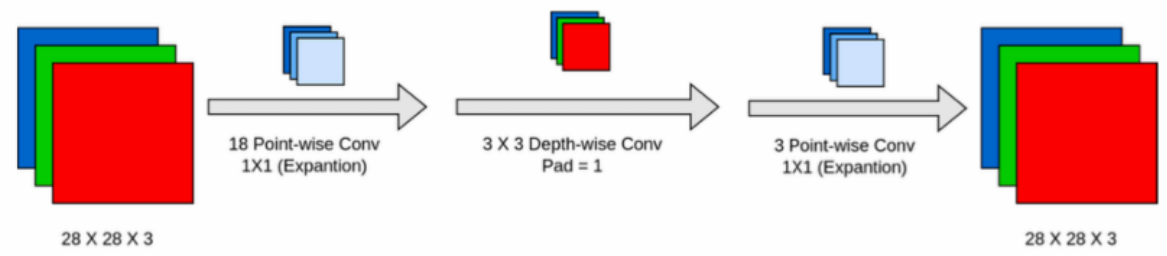

شکل ۲: شمای کلی بلوک MobileNet-V2 با استفاده از کانولوشن‌های ۱ × ۱ و کانولوشن عمقی ۳ × ۳.

کانولوشن معمولی - در این لایه، ۱۲۸ فیلتر با ابعاد ۳ × ۳ روی ورودی با ۳ کانال اعمال می‌شود.

تعداد وزن‌ها: $۱۲۸ \times (۳ \times ۳ \times ۳) = ۳,۴۵۶$

تعداد بایاس‌ها: چون ۱۲۸ فیلتر داریم، ۱۲۸ بایاس خواهیم داشت.

مجموع پارامترها:

$$۱۲۸ \times (۳ \times ۳ \times ۳ + ۱) = ۱۲۸ \times ۲۸ = ۳,۵۸۴$$

کانولوشن عمقی تفکیک‌پذیر - از دو مرحله تشکیل شده است که هر کدام بایاس جداگانه دارند:

مرحله اول: در این لایه، هر کانال ورودی به طور جداگانه با یک فیلتر ۳ × ۳ پردازش می‌شود. (۳ کانال ورودی ← ۳ فیلتر)

تعداد وزن‌ها: ۲۷ = (۳ × ۳) × ۳

تعداد بایاس‌ها: ۳ (به ازای هر فیلترِ مخصوص هر کانال)

مجموع پارامترهای این مرحله: ۳۰ = ۳ + ۲۷

مرحله دوم: کانولوشن نقطه‌ای تفکیک‌پذیر

تعداد وزن‌ها: ۳۸۴ = (۳ × ۱ × ۱) × ۱۲۸

تعداد بایاس‌ها: ۱۲۸ (به ازای هر فیلتر ۱ در ۱ خروجی)

مجموع پارامترهای این مرحله: ۵۱۲ = ۱۲۸ + ۳۸۴

مجموع کل پارامترهای MobileNet:

$$۳۰ + ۵۱۲ = ۵۴۲$$

در شکل ۲، یک بلوک MobileNet-V۲ با ورودی و خروجی ۳ کانال و لایه میانی ۱۸ کانال نمایش داده شده است. محاسبات به شرح زیر است:

۱. لایه اول: Point-wise Expansion (۱ × ۱)

این لایه تعداد کانال‌ها را از ۳ به ۱۸ افزایش می‌دهد:

$$\text{Params}_۱ = ۱۸ \times (۱ \times ۱ \times ۳ + ۱) = ۱۸ \times ۴ = ۷۲$$

۲. لایه دوم: Depth-wise Convolution (۳ × ۳)

این لایه روی ۱۸ کانال ورودی اعمال می‌شود:

$$\text{Params}_۲ = ۱۸ \times (۳ \times ۳ + ۱) = ۱۸ \times ۱۰ = ۱۸۰$$

۳. لایه سوم: Point-wise Projection (۱ × ۱)

این لایه تعداد کانال‌ها را از ۱۸ به ۳ کاهش می‌دهد:

$$\text{Params}_۳ = ۳ \times (۱ \times ۱ \times ۱۸ + ۱) = ۳ \times ۱۹ = ۵۷$$

مجموع کل پارامترهای این بلوک برابر است با:

$$\text{Total Params} = ۷۲ + ۱۸۰ + ۵۷ = ۳۰۹$$

در مقایسه با MobileNet-V۱، استفاده از استراتژی Residual Inverted (گسترش و سپس فشرده‌سازی) باعث افزایش قدرت بازنمایی شبکه با وجود تعداد کم پارامترها در مقایسه با کانولوشن‌های استاندارد می‌شود.

۳. (۲۲ نمره) در بعضی از معماری‌های نوین کانولوشنی، به جای استفاده از لایه‌های تمام‌متصل[۱] در انتهای شبکه، از لایه ادغام میانگین سراسری[۲] استفاده می‌شود. فرض کنید خروجی آخرین لایه کانولوشن، یک تنسور $X \in \mathbb{R}^{C \times H \times W}$ باشد (که C تعداد کانال‌ها، و H, W ابعاد مکانی هستند).

آ. رابطه ریاضی برای محاسبه بردار خروجی y حاصل از ادغام میانگین سراسری را بنویسید. ابعاد بردار خروجی y چقدر است؟

برای هر کانال c (از ۱ تا C)، مقدار خروجی y_c به صورت زیر محاسبه می‌شود:

$$y_c = \frac{۱}{H \times W} \sum_{i=۱}^{H} \sum_{j=۱}^{W} X_{i,j,c}$$

خروجی این لایه یک بردار است که به ازای هر کانال ورودی، یک مقدار میانگین دارد. بنابراین ابعاد بردار y برابر است با:

$$\mathbf{y} \in \mathbb{R}^{C \times ۱ \times ۱} \quad \text{or} \quad \mathbf{y} \in \mathbb{R}^{C}$$

ب. فرض کنید تنسور ویژگی ورودی دارای ابعاد ۷ × ۷ و تعداد کانال ۵۱۲ باشد ($H = W = ۷, C = ۵۱۲$). می‌خواهیم این ویژگی‌ها را به یک لایه دسته‌بندی با ۱۰۰۰ کلاس متصل کنیم. تعداد پارامترهای قابل یادگیری (وزن‌ها) را در دو حالت زیر محاسبه و مقایسه کنید:

(آ) روش اول: صاف کردن[۳] تنسور و اتصال به یک لایه تمام‌متصل.

(ب) روش دوم: اعمال ادغام میانگین سراسری و سپس اتصال به یک لایه تمام‌متصل.

فرض بر این است که تنسور ویژگی ورودی دارای ابعاد $H = ۷, W = ۷, C = ۵۱۲$ بوده و تعداد کلاس‌های خروجی $K = ۱۰۰۰$ است. در این حالت، ابتدا تنسور به یک بردار تبدیل می‌شود. تعداد پارامترهای لایه تمام‌متصل عبارت است از:

$$\begin{aligned} N_{\text{flatten}} &= (H \times W \times C) \times K \\ &= (۷ \times ۷ \times ۵۱۲) \times ۱۰۰۰ \\ &= ۲۵,۰۸۸ \times ۱۰۰۰ = ۲۵,۰۸۸,۰۰۰ \end{aligned}$$

در حالت دوم، لایه GAP ابعاد مکانی را حذف کرده و برداری به طول C تولید می‌کند. تعداد پارامترها عبارت است از:

$$\begin{aligned} N_{\text{GAP}} &= C \times K \\ &= ۵۱۲ \times ۱۰۰۰ = ۵۱۲,۰۰۰ \end{aligned}$$

تعداد پارامترها در روش دوم به میزان قابل توجهی کمتر است:

$$\frac{N_{\text{flatten}}}{N_{\text{GAP}}} = \frac{۲۵,۰۸۸,۰۰۰}{۵۱۲,۰۰۰} = ۴۹$$

استفاده از GAP منجر به کاهش ۴۹ برابری پارامترها در این لایه می‌شود که علاوه بر کاهش محاسبات، مقاومت شبکه در برابر بیش‌برازش را افزایش می‌دهد.

پ. توضیح دهید چرا استفاده از ادغام سراسری[۴] به شبکه اجازه می‌دهد تا تصاویر با ابعاد ورودی متغیر (مثلاً هم ۲۲۴ × ۲۲۴ و هم ۴۰۰ × ۴۰۰) را بپذیرد؟ چرا این امکان در روش صاف کردن ورودی وجود ندارد؟

لایه GAP به دلیل میانگین‌گیری روی ابعاد مکانی، خروجی با طول ثابت (برابر با تعداد کانال‌ها) تولید می‌کند که مستقل از H و W است. اما در روش Flatten طول بردار خروجی تابع مستقیم ابعاد تصویر ($H \times W \times C$) است، لذا با تغییر ابعاد ورودی، تعداد اتصالات مورد نیاز لایه تمام‌متصل تغییر کرده و مدل با خطا مواجه می‌شود.

ت. فرض کنید به جای میانگین، از ادغام بیشینه سراسری استفاده کنیم. اگر گرادیان لاس نسبت به خروجی این لایه برای کانال kـام برابر با δ_k باشد، گرادیان نسبت به پیکسل‌های ورودی $X_{k,i,j}$ در آن کانال چگونه توزیع می‌شود؟ (فرض کنید مقدار بیشینه یکتاست)

در لایه ادغام بیشینه سراسری، خروجی برای کانال k به صورت $y_k = \max_{i,j}(X_{k,i,j})$ تعریف می‌شود. با فرض اینکه مقدار بیشینه در هر کانال منحصربه‌فرد باشد، گرادیان لاس نسبت به پیکسل‌های ورودی طبق قاعده زنجیره‌ای به شرح زیر توزیع می‌شود:

$$\frac{\partial J}{\partial X_{k,i,j}} = \frac{\partial J}{\partial y_k} \cdot \frac{\partial y_k}{\partial X_{k,i,j}}$$

با توجه به ماهیت تابع max:

$$\frac{\partial y_k}{\partial X_{k,i,j}} = \begin{cases} ۱ & \text{if} X_{k,i,j} = \text{argmax}(X_k) \\ ۰ & \text{otherwise} \end{cases}$$

بنابراین، اگر گرادیان نسبت به خروجی برابر با δ_k باشد، گرادیان نسبت به ورودی‌ها به صورت زیر خواهد بود:

$$\boxed{\frac{\partial J}{\partial X_{k,i,j}} = \begin{cases} \delta_k & \text{if} X_{k,i,j} \text{pixel maximum the is} \\ ۰ & \text{otherwise} \end{cases}}$$

در این لایه، تمام مقدار گرادیان δ_k تنها به پیکسلی که دارای مقدار بیشینه بوده منتقل می‌شود و سایر پیکسل‌های کانال k گرادیان صفر دریافت می‌کنند.

ث. فرض کنید ماتریس ورودی X با ابعاد ۳ × ۳ به صورت زیر داده شده است:

$$X = \begin{bmatrix} ۱ & ۳ & ۲ \\ ۴ & ۶ & ۵ \\ ۷ & ۸ & ۹ \end{bmatrix}$$

یک لایه ادغام بیشینه[۵] با ابعاد پنجره ۲ × ۲ و گام حرکت (Stride) برابر با ۱ روی این ورودی اعمال می‌شود.

ج. ماتریس خروجی Y را محاسبه کنید. (توجه کنید که به دلیل Stride=1، پنجره‌ها همپوشانی دارند).

چ. فرض کنید گرادیان تابع هزینه نسبت به خروجی این لایه ($\frac{\partial \mathcal{L}}{\partial Y}$) به صورت زیر به دست آمده باشد:

$$\frac{\partial \mathcal{L}}{\partial Y} = \begin{bmatrix} ۲ & -۳ \\ ۱ & ۴ \end{bmatrix}$$

ماتریس گرادیان نسبت به ورودی ($\frac{\partial \mathcal{L}}{\partial X}$) را محاسبه کنید.

راهنمایی: دقت کنید که برخی از پیکسل‌های ورودی ممکن است در محاسبه چندین خروجی مشارکت داشته باشند.

با اعمال فیلتر ۲ × ۲ و $Stride = ۱$ بر ماتریس X داریم:

- $Y_{۱,۱} = \max\{۱, ۳, ۴, ۶\} = ۶$
- $Y_{۱,۲} = \max\{۳, ۲, ۶, ۵\} = ۶$
- $Y_{۲,۱} = \max\{۴, ۶, ۷, ۸\} = ۸$
- $Y_{۲,۲} = \max\{۶, ۵, ۸, ۹\} = ۹$

بنابراین:

$$Y = \begin{bmatrix} ۶ & ۶ \\ ۸ & ۹ \end{bmatrix}$$

حال به محاسبه ماتریس گرادیان نسبت به ورودی می‌پردازیم: $\frac{\partial \mathcal{L}}{\partial X}$
با توجه به اینکه مقدار بیشینه در پنجره‌های اول و دوم درایه‌ی $X_{۲,۲}$ است، گرادیان‌های مربوطه با هم جمع می‌شوند:

$$\frac{\partial \mathcal{L}}{\partial X_{۲,۲}} = \frac{\partial \mathcal{L}}{\partial Y_{۱,۱}} + \frac{\partial \mathcal{L}}{\partial Y_{۱,۲}} = ۲ + (-۳) = -۱$$
$$\frac{\partial \mathcal{L}}{\partial X_{۳,۲}} = \frac{\partial \mathcal{L}}{\partial Y_{۲,۱}} = ۱$$
$$\frac{\partial \mathcal{L}}{\partial X_{۳,۳}} = \frac{\partial \mathcal{L}}{\partial Y_{۲,۲}} = ۴$$

سایر درایه‌ها به دلیل اینکه در هیچ پنجره‌ای مقدار بیشینه نبودند، گرادیان صفر دریافت می‌کنند. ماتریس نهایی:

$$\boxed{\frac{\partial \mathcal{L}}{\partial X} = \begin{bmatrix} ۰ & ۰ & ۰ \\ ۰ & -۱ & ۰ \\ ۰ & ۱ & ۴ \end{bmatrix}}$$

۴. (۲۲ نمره)

آ. فرض کنید یک تصویر ۳ × ۳۲ × ۳۲ دارید.

- اگر این تصویر را با یک فیلتر ۳ × ۵ × ۵، با استفاده از گام (stride) برابر ۱ و لایه‌گذاری (padding) برابر ۰ کانولوشن کنید، ابعاد مکانی حاصل چه خواهد بود؟
- اگر ورودی را به اندازه ۲ با صفر لایه‌گذاری (zero-pad) کنیم، ابعاد مکانی حاصل چه خواهد بود؟
- فرض کنید اکنون ۱۰ عدد از این فیلترهای ۳ × ۵ × ۵ را روی هم قرار دهیم (با حفظ لایه‌گذاری ۲).
  - شکل جدید کامل خروجی چیست؟
  - چه تعداد پارامتر قابل یادگیری در این لایه وجود دارد (بدون در نظر گرفتن پارامترهای بایاس)؟
  - اگر بایاس را هم در نظر بگیریم، تعداد پارامترها چقدر خواهد بود؟
- ابعاد مکانی پس از اعمال یک کانولوشن ۱ × ۱ چه خواهد بود؟ توضیح دهید که این عملیات از نظر مفهومی چه کاری انجام می‌دهد.

برای ورودی ۳ × ۳۲ × ۳۲ و فیلتر ۵ × ۵ داریم:

- **با لایه‌گذاری (Padding) صفر:**

$$O = \frac{۳۲ - ۵ + ۲(۰)}{۱} + ۱ = ۲۸ \implies ۲۸ \times ۲۸$$

- **با لایه‌گذاری (Padding) دو:**

$$O = \frac{۳۲ - ۵ + ۲(۲)}{۱} + ۱ = ۳۲ \implies ۳۲ \times ۳۲$$

با استفاده از ۱۰ تا از این فیلترها خواهیم داشت:

- **شکل خروجی نهایی:** $۳۲ \times ۳۲ \times ۱۰$
- **تعداد پارامترها (بدون بایاس):**

$$۵ \times ۵ \times ۳ \times ۱۰ = ۷۵۰$$

- **تعداد پارامترها (با بایاس):**

$$۷۵۰ + ۱۰ = ۷۶۰$$

در اثر استفاده از کانولوشن ۱×۱ ابعاد مکانی تغییر نمی‌کند (۳۲×۳۲ می‌ماند). از نظر مفهومی، این لایه برای **کاهش تعداد کانال‌ها** (در راستای عمق پولینگ) و ترکیب ویژگی‌های کانال‌های مختلف در هر پیکسل با هزینه محاسباتی کم استفاده می‌شود.

ب. می‌دانیم کانولوشن‌ها عملیات خطی هستند و هر نگاشت خطی بین فضاهای با ابعاد محدود می‌تواند به صورت یک ماتریس بیان شود.
یک کانولوشن یک‌بعدی با ورودی $\mathbf{x} \in \mathbb{R}^۴$ و فیلتر $\mathbf{w} \in \mathbb{R}^۳$ را در نظر بگیرید. فرض کنید $\bar{\mathbf{x}}$ نشان‌دهنده نتیجه لایه‌گذاری صفر ورودی به اندازه ۱ در هر طرف باشد. ماتریس $\mathbf{W}$ را به گونه‌ای بسازید که:

$$\bar{\mathbf{x}} \star \mathbf{w} = \mathbf{W}\bar{\mathbf{x}}$$

راهنمایی: ابتدا عناصر بردار حاصل از کانولوشن را بنویسید.

فرض کنید ورودی گسترش‌یافته با لایه‌گذاری صفر به صورت $\bar{\mathbf{x}} = [۰, x_۱, x_۲, x_۳, x_۴, ۰]^T$ باشد. برای فیلتر $\mathbf{w} = [w_۱, w_۲, w_۳]$، خروجی کانولوشن یک‌بعدی از ترکیب‌های خطی زیر تشکیل می‌شود:

$$\begin{aligned}
y_۱ &= w_۱(۰) + w_۲(x_۱) + w_۳(x_۲) \\
y_۲ &= w_۱(x_۱) + w_۲(x_۲) + w_۳(x_۳) \\
y_۳ &= w_۱(x_۲) + w_۲(x_۳) + w_۳(x_۴) \\
y_۴ &= w_۱(x_۳) + w_۲(x_۴) + w_۳(۰)
\end{aligned}$$

برای نمایش این عملیات به صورت $\mathbf{W}\bar{\mathbf{x}}$، ماتریس $\mathbf{W}$ (معروف به ماتریس کانولوشن) باید به صورت زیر تشکیل گردد:

$$\mathbf{W} = \begin{bmatrix} w_۱ & w_۲ & w_۳ & ۰ & ۰ & ۰ \\ ۰ & w_۱ & w_۲ & w_۳ & ۰ & ۰ \\ ۰ & ۰ & w_۱ & w_۲ & w_۳ & ۰ \\ ۰ & ۰ & ۰ & w_۱ & w_۲ & w_۳ \end{bmatrix}$$

این ماتریس دارای ابعاد ۶×۴ است و هر سطر آن نشان‌دهنده یک گام حرکت فیلتر روی ورودی است.

پ. بیایید گرادیان‌ها را برای یک کانولوشن مشتق بگیریم. فرض کنید $\mathbf{y} = \mathbf{x} \star \mathbf{w} \in \mathbb{R}^۲$، که در آن $\mathbf{w} \in \mathbb{R}^۳$ و $\mathbf{x} \in \mathbb{R}^۴$ (بدون لایه‌گذاری صفر) است. فرض کنید L تابع زیان (loss function) باشد و $\nabla_{\mathbf{y}} L$ گرادیان زیان نسبت به خروجی کانولوشن را نشان دهد.

- گرادیان L نسبت به ورودی $\mathbf{x}$ را محاسبه کنید (یعنی $\frac{\partial L}{\partial \mathbf{x}}$). آیا می‌توانید این گرادیان را به صورت یک کانولوشن بیان کنید؟
- گرادیان L نسبت به وزن‌های $\mathbf{w}$ را محاسبه کنید (یعنی $\frac{\partial L}{\partial \mathbf{w}}$). آیا می‌توانید این گرادیان را به صورت یک کانولوشن بیان کنید؟

تابع زیان $L(y)$ بوده و گرادیان نسبت به خروجی داده شده است:

$$\nabla_y L = \frac{\partial L}{\partial y}$$

کانولوشن را می‌توان به‌صورت ضرب ماتریسی نوشت:

$$y = W_x x$$

که:

$$W_x = \begin{bmatrix} w_۱ & w_۲ & w_۳ & ۰ \\ ۰ & w_۱ & w_۲ & w_۳ \end{bmatrix}$$

پس با استفاده از قاعده زنجیره‌ای داریم:

$$\frac{\partial L}{\partial x} = W_x^\top \frac{\partial L}{\partial y}$$

این ضرب دقیقاً معادل **کانولوشن گرادیان خروجی با فیلترِ معکوس‌شده** است:

$$\boxed{\frac{\partial L}{\partial x} = \nabla_y L \star \tilde{w}}$$

که در آن:

$$\tilde{w} = [w_۳,\ w_۲,\ w_۱]$$

به‌طور مشابه، برای وزن‌ها می‌توان نوشت:

$$y = W_w w$$

که در آن:

$$W_w = \begin{bmatrix} x_۱ & x_۲ & x_۳ \\ x_۲ & x_۳ & x_۴ \end{bmatrix}$$

پس:

$$\frac{\partial L}{\partial w} = W_w^\top \frac{\partial L}{\partial y}$$

که معادل است با:

$$\boxed{\frac{\partial L}{\partial w} = x \star \nabla_y L}$$

پس می‌توان گفت:

- کانولوشن یک عمل خطی است و می‌توان آن را به‌صورت ضرب ماتریسی نوشت.
- گرادیان نسبت به ورودی برابر است با کانولوشن گرادیان خروجی با فیلتر برعکس‌شده.
- گرادیان نسبت به وزن‌ها برابر است با کانولوشن ورودی با گرادیان خروجی.

۵. (۱۸ نمره) یکی از تصمیمات مهم در طراحی معماری‌های کانولوشنی، انتخاب اندازه هسته [۶] و عمق شبکه است که مستقیماً بر میدان دید[۷] و تعداد پارامترها تاثیر می‌گذارد.

آ. فرض کنید ورودی یک تنسور با تعداد کانال C باشد. دو معماری زیر را در نظر بگیرید:
«الف»: استفاده از یک لایه کانولوشن با سایز هسته ۵ × ۵.
«ب»: استفاده از دو لایه متوالی کانولوشن با سایز هسته ۳ × ۳.
(فرض کنید در هر دو حالت Stride=1 است و تعداد کانال‌های ورودی و خروجی در تمام لایه‌ها برابر C می‌باشد).

(آ) نشان دهید که میدان دید نهایی در هر دو معماری یکسان است.

(ب) تعداد پارامترهای این دو معماری را محاسبه کرده (از تعداد پارامترهای بایاس صرف نظر کنید). کدام معماری پارامتر کمتری دارد؟

(ج) جدا از بحث تعداد پارامتر، مزیت اصلی «معماری ب» (لایه‌های متوالی کوچک) نسبت به «معماری الف» از نظر سوگیری القایی [۸] و یادگیری ویژگی‌های غیرخطی چیست؟

میدان دید در معماری «الف» مستقیماً برابر ۵ × ۵ است. در معماری «ب»، میدان دید دو لایه متوالی ۳ × ۳ طبق فرمول $R = k_۱ + k_۲ - ۱$ محاسبه می‌شود:

$$R = ۳ + ۳ - ۱ = ۵ \implies ۵ \times ۵$$

بنابراین هر دو معماری میدان دید یکسانی دارند. با فرض تعداد کانال ثابت C در ورودی و خروجی:

- **معماری «الف»:** $۵ \times ۵ \times C \times C = ۲۵C^۲$
- **معماری «ب»:** $(۳ \times ۳ \times C \times C) \times ۲ = ۱۸C^۲$

معماری «ب» با تعداد پارامتر کمتر ($۱۸C^۲$) بهینه‌تر است. مزیت اصلی معماری «ب»، افزایش **تعداد توابع فعال‌ساز غیرخطی** در مسیر پردازش است. این امر قدرت بازنمایی (Representational) شبکه را افزایش می‌دهد تا توابع پیچیده‌تری را یاد بگیرد. همچنین، این رویکرد باعث کاهش محاسبات و افزایش سرعت آموزش در شبکه‌های بسیار عمیق می‌شود.

ب. سوگیری القایی در شبکه‌های کانولوشنی معمولاً با دو ویژگی محلی بودن و هم‌ارزی انتقالی [۹] شناخته می‌شود. رابطه ریاضی عملگر کانولوشن برای ورودی x و فیلتر w به صورت $y(t) = (x * w)(t)$ تعریف می‌شود. اگر عملگر شیفت (انتقال) ورودی به اندازه h واحد را با T_h نشان دهیم (یعنی $(T_h x)(t) = x(t-h)$): ثابت کنید که عملگر کانولوشن نسبت به انتقال هم‌ارز است. یعنی نشان دهید:

$$(T_h x) * w = T_h(x * w)$$

محاسبه سمت چپ: $(T_h x) * w$
طبق تعریف کانولوشن و عملگر شیفت $(T_h x)(t) = x(t-h)$:

$$((T_h x) * w)(t) = \int_{-\infty}^{\infty} x(\tau - h) w(t - \tau) d\tau$$

با تغییر متغیر $u = \tau - h \implies \tau = u + h$ و $d\tau = du$:

$$((T_h x) * w)(t) = \int_{-\infty}^{\infty} x(u) w(t - (u + h)) du = \int_{-\infty}^{\infty} x(u) w((t - h) - u) du$$

محاسبه سمت راست: $T_h(x * w)$
فرض می‌کنیم $y(t) = (x * w)(t)$. طبق تعریف عملگر شیفت:

$$(T_h y)(t) = y(t-h) = \int_{-\infty}^{\infty} x(\tau) w((t-h)-\tau) d\tau$$

از آنجا که هر دو عبارت بالا با هم برابر هستند، ثابت می‌شود که:

$$\boxed{(T_h x) * w = T_h(x * w)}$$

این بدین معناست که اگر تصویر ورودی جابه‌جا شود، نقشه ویژگی‌های استخراج شده نیز به همان میزان جابه‌جا می‌گردد.

پ. در بسیاری از شبکه‌های مدرن، با جلو رفتن در لایه‌ها، رزلوشن مکانی ($H \times W$) کاهش و تعداد کانال‌ها (C) افزایش می‌یابد. توضیح دهید این طراحی چگونه باعث تغییر نوع ویژگی‌های یاد گرفته شده می‌شود و چه ارتباطی با افزایش میدان دید دارد؟

تحلیل و بررسی طراحی معماری این استراتژی طراحی، که در اکثر شبکه‌های عصبی کانولوشنال (CNN) مانند ResNet و VGG استفاده می‌شود، دو هدف اصلی را دنبال می‌کند:

تغییر نوع ویژگی‌ها (از جزئی به کلی): در لایه‌های ابتدایی، رزولوشن بالا است و شبکه روی ویژگی‌های سطحی و محلی (Low-level) مانند لبه‌ها، رنگ‌ها و بافت‌های ساده تمرکز دارد.با کاهش رزولوشن و افزایش تعداد کانال‌ها در لایه‌های عمیق‌تر، شبکه قادر است ویژگی‌های انتزاعی و پیچیده‌تر (High-level) مانند قطعات اشیاء یا کل یک شیء را شناسایی کند. افزایش تعداد کانال‌ها فضای لازم برای ذخیره‌سازی این الگوهای متنوع و پیچیده را فراهم می‌کند.

ارتباط با افزایش میدان دید (Receptive-Field): کاهش رزولوشن مکانی (معمولاً از طریق عملیات Pooling یا استفاده از Stride در کانولوشن) باعث می‌شود که هر پیکسل در لایه‌های خروجی، ناحیه وسیع‌تری از تصویر ورودی اصلی را پوشش دهد.در واقع، وقتی ابعاد تصویر کوچک می‌شود، یک فیلتر ۳×۳ روی یک نقشه ویژگی کوچک‌شده، معادل پوشش دادن بخش بسیار بزرگی از تصویر اولیه با ابعاد بزرگ است. این افزایش میدان دید برای درک زمینه (Context) و روابط بین اجزای مختلف تصویر ضروری است.