دانشگاه صنعتی شریف
دانشکده‌ی مهندسی کامپیوتر

# یادگیری ماشین

**پاییز و زمستان ۱۴۰۴**

استاد: علی شریفی زارچی
گردآورندگان: میریوسفی - گرامی‌راد

حل تمرین سوم | **شبکه های عصبی** | مهلت ارسال:

۱. (۰ نمره) برای هر یک از شکل‌های زیر شبکه عصبی ای طراحی کنید که در ناحیه خاکستری فعال باشد (نیازی به محاسبه وزن هانیست، شکل شبکه را رسم نمایید)

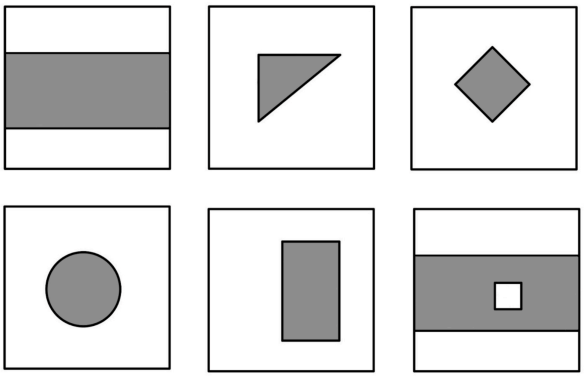

۲. (۰ نمره) برای شبکه عصبی زیر گراف محاسبات (Computation Graph) را رسم نمایید. سپس با استفاده از گراف، الگوریتم پس‌انتشار (Back Propagation) را به صورت برداری انجام دهید.

$$f(x) = \text{Softmax}\left(W_۲ \,\text{ReLU}\left(W_۱ x + b_۱\right) + b_۲\right)$$

۳. (۰ نمره) دو الگوریتم گرادیان کاهشی (Gradient Descent) و ممنتوم مرتبه اول (First Moment) را برای سه مرحله بر روی تابع زیر اجرا کنید. از پارامترهای داده شده استفاده نمایید و تکانه اولیه را صفر در نظر بگیرید ($m_۰ = ۰$).

$$f(x) = \frac{۱}{۳}x^۳, \quad x_۰ = ۲, \quad \alpha = ۰/۵, \quad \beta = ۰/۲$$

۴. (۰ نمره) تابع هزینه مسئله رگرسیون خطی به صورت زیر تعریف می‌شود:

$$\mathbb{L}_۱(w) = \|y - Xw\|_۲^۲$$

همانطور که در درس دیدید، می‌توانیم چند عنصر دیگر به عنوان Regularization Term به این تابع هزینه اضافه کنیم. در این صورت خواهیم داشت:

$$\mathbb{L}_۲(w) = \|y - Xw\|_۲^۲ + \|\Gamma w\|_۲^۲$$

که به $\Gamma$، Tikhonov matrix می‌گویند. این حالت کلی مسئله ridge regression است که در اینجا به جای $\lambda I$، از یک ماتریس استفاده می‌کنیم. برای آموزش مدل رگرسیون خطی خود، می‌خواهیم از تکنیکی به نام dropout استفاده کنیم. این تکنیک برای ورودی $d$ بعدی، هر ویژگی را با احتمال $p$ نگه داشته و در غیر این صورت برابر صفر خواهد شد. با استفاده از این تکنیک، تابع هزینه به شکل زیر تغییر خواهد کرد:

$$\mathbb{L}_۳(w) = \mathbb{E}_{D\sim\text{Bernouli}(p)}[\|y - (D \odot X)\hat{w}\|_۲^۲]$$

توجه کنید در اینجا $\hat{w}$ پارامترهای پیدا شده توسط مدلی است که با dropout آموزش داده شده است. همچنین ضرب $\odot$، ضرب element wise می‌باشد.

آ. ابتدا معادله نرمال برای حل مساله‌ی minimization بدون توجه به dropout به دست آورید. در اینجا شما مانند دیگر مسئله‌های رگرسیون، باید وزن‌های بهینه را با استفاده از مشتق و ... با استفاده از تابع هزینه به دست آورید.

ب. یک شرط ساده، کافی و لازم برای ماتریس $\Gamma$ بیان کنید که تضمین کند تابع هزینه یک جواب منحصر به فرد و بهینه برای $\hat{w}$ دارد.

پ. حال اثبات کنید هنگام استفاده از تکنیک dropout، می‌توان تابع هزینه را به شکل زیر بازنویسی کرد:

$$\mathbb{L}(w) = \|y - pX\hat{w}\|_۲^۲ + p(۱ - p)\|\hat{\Gamma}\hat{w}\|_۲^۲$$

به طوری که $\hat{\Gamma}$ یک ماتریس قطری بوده که عنصر $j$ ام قطری این ماتریس، برابر نرم ستون $j$ ام ماتریس دادگان $X$ می‌باشد.

ت. فرض کنید $\Gamma$ معکوس‌پذیر باشد. با یک تغییر متغیر سعی کنید تا تابع هزینه گفته شده در حالت بدون dropout را به صورت تابع هزینه مسئله ridge regression بازنویسی کنید:

$$\mathbb{L}(\hat{w}) = \|y - \hat{X}\hat{w}\|_۲^۲ + \lambda\|\hat{w}\|_۲^۲$$

۵. (۰ نمره)

فرض کنید بردار پیش‌بینی $z \in \mathbb{R}^k$، بردار برچسب واقعی $y \in \mathbb{R}^k$ و یک ثابت $\delta > ۰$ داده شده‌اند. با در نظر گرفتن نرم $\ell_۲$ به صورت $\|v\| = \sqrt{v^\top v}$، تابع هزینه Huber $\ell_۲$ به صورت زیر تعریف می‌شود:

$$L_\delta(z, y) = \begin{cases} \frac{۱}{۲}\|z - y\|^۲, & \|z - y\| \leq \delta, \\ \delta \cdot (\|z - y\| - \frac{۱}{۲}\delta), & \text{otherwise.} \end{cases}$$

در تصویر پایین، نمودار $L_۱(z, ۰)$ برای $k = ۲$ رسم شده است. این تابع هزینه می‌تواند برای رگرسیون استفاده شود، جایی که تابع رگرسیون یک بردار $k$ـبعدی را برمی‌گرداند.

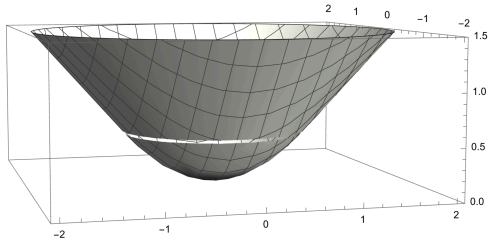

تابع هزینه Huber $\ell_۲$ به گونه‌ای طراحی شده است که شبیه به تابع هزینه $\|z-y\|$ (یعنی فاصله اقلیدسی، که در حالت یک بعدی قدرمطلق نامیده می‌شود) باشد؛ اما برخلاف فاصله اقلیدسی، در نقطه مینیمم $z=y$ هموار (smooth) است. برای یک $y$ ثابت، تابع هزینه Huber $\ell_۲$ در یک ناحیه کوچک نزدیک به $y$ نسبت به $z$ درجه دو (quadratic) است، اما در فواصل دورتر از $y$ شکلی شبیه به مخروط دارد. تابع هزینه Huber $\ell_۲$ پیوسته و محدب است.

آ. گرادیان $\nabla_z L_\delta(z,y)$ برای تابع هزینه Huber $\ell_۲$ (برای $\delta$ و $y$ ثابت) را محاسبه کنید.

ب. اگر $z$ را با استفاده از گرادیان کاهشی (gradient descent) روی $L_\delta$ (برای یک $y$ ثابت) بهینه کنیم، چه نرخ یادگیری یا همان $\epsilon$ تضمین می‌کند که ما نهایتاً به مینیمم دقیق برسیم (به جای اینکه فقط تا ابد به آن نزدیک و نزدیک‌تر شویم)؟ چرا؟

پ. فرض کنید از روش نیوتون (Newton's method) برای یافتن $z$ که تابع هزینه Huber $\ell_۲$ را مینیمم می‌کند استفاده می‌کنیم. (به لحاظ فنی، ماتریس هسین $L_\delta$ نسبت به $z$ در نقاطی که $\|z-y\|=\delta$ است تعریف نشده، اما ما با استفاده از هسین $\frac{۱}{۲}\|z-y\|^۲$ در آن نقاط، این مشکل را برطرف می‌کنیم.)

اگر از نقطه‌ای مانند $z=z_۰$ شروع کنیم که در شرط $\|z_۰-y\|<\delta$ صدق می‌کند، مقدار $z$ بعد از یک گام از روش نیوتون چه خواهد بود؟ چرا؟

ت. اگر از نقطه‌ای مانند $z=z_۰$ شروع کنیم که در شرط $\|z_۰-y\|>\delta$ صدق می‌کند، یک گام از روش نیوتون چه کاری انجام می‌دهد؟ چرا؟ (نکته: برای این سوال و سوال بعدی، ما به دنبال یک پاسخ کیفی هستیم؛ نیازی به محاسبه هسین نیست.)

ث. فرض کنید یک ترم نرمال‌سازی $\ell_۲$ به صورت $\lambda\|z\|^۲$ به تابع هزینه Huber $\ell_۲$ اضافه کنیم (با $\lambda>۰$) و یک گام از روش نیوتون را روی تابع هزینه Huber $\ell_۲$ نرمال‌سازی شده (regularized) اجرا کنیم. پاسخ‌های شما به قسمت‌های (پ) و (ت) چگونه (به صورت کیفی) تغییر می‌کنند و چرا؟